

Doctorat de l'Université de Toulouse

Délivré par l'ISAE-SUPAERO

Comprendre la migration infonuagique : exigences et estimation des coûts d'exploitation

Thèse présentée et soutenue, le 29 mai 2024 par

Antoine AUBÉ

École doctorale

MITT - Mathématiques, informatique, télécommunications

Spécialité

Informatique et Télécommunications

Unité de recherche

ISAE-ONERA MOIS Modélisation et Ingénierie des Systèmes

Thèse dirigée par

Thomas POLACSEK

Composition du jury

M. Iulian OBER, Président, ISAE-SUPAERO

M. Philippe COLLET, Rapporteur, Université Côte d'Azur

Mme Selmin NURCAN, Rapporteur, Université Paris 1 Panthéon Sorbonne

M. Thomas POLACSEK, Directeur de thèse, ONERA

Titre : *Comprendre la migration infonuagique : exigences et estimation des coûts d'exploitation*

Résumé

Le choix d'un hébergement d'un système informatique est lourd d'enjeux pour une organisation. En effet, de cette décision dépendent notamment ses dépenses pour l'exploitation de ce système, la main-d'œuvre allouée à cette exploitation, et la qualité de service rendu par le système informatique. Si, classiquement, cet hébergement était réalisé par les organisations dans leurs locaux, l'émergence d'hébergeurs tiers a initié un changement des pratiques, une migration des systèmes d'information vers l'infrastructure d'une autre organisation. L'informatique en nuage est un tel modèle de délégation de l'infrastructure à un tiers. Ce dernier fournit un nuage informatique, c'est-à-dire un ensemble de services configurables pour mettre à disposition des ressources informatiques. Dans ce contexte de migration vers un nuage informatique (ou migration infonuagique), de nouvelles problématiques apparaissent pour constituer l'hébergement du système informatique, nommé ici *environnement infonuagique*. Notamment, les problématiques liées à la récurrence et la variété des coûts opérationnels sont bien connues dans l'industrie.

Dans ces travaux, nous cherchons à identifier les critères de sélection d'un environnement infonuagique lors d'une migration, et comment il nous est possible d'évaluer la satisfaction des exigences liées à ces critères. À ces fins, nous avons d'abord mené une enquête qualitative auprès d'industriels afin d'identifier les exigences récurrentes des environnements infonuagiques dans l'industrie. Puis, nous nous sommes concentrés sur l'estimation des coûts opérationnels de ces environnements, qui sont très fréquemment évoqués comme un critère à minimiser et qui sont souvent mal compris, étant donné la variété des modèles de tarification de l'informatique en nuage. Ainsi, nous avons développé un modèle conceptuel permettant l'estimation de ces coûts, puis un outil qui implémente ce modèle conceptuel afin d'automatiser cette estimation.

Mots-clefs

Informatique en nuage, Migration infonuagique, Ingénierie des exigences, Modélisation, Estimation des coûts d'exploitation

Title : *To understand cloud migration : requirements and operating costs estimation*

Abstract

Selecting a host for an information system is a major decision for any organization. Indeed, such a decision has consequences on many aspects, such as the operating costs, the manpower allocation to operations, and the quality of service provided by the information system. While the hosting was traditionally carried out by the organizations themselves, in their premises, the emergence of third-party hosting providers initiated a change in practices : a migration of information systems to the infrastructure of another organization. Cloud Computing is such a model for delegating infrastructure to a third party. The latter provides a cloud, which is a set of configurable services to deliver computing resources. In this context of cloud migration, new issues emerge to select information systems hosts, named *cloud environments*. In particular, problems related to the recurrence and variety of operational costs are well-known in the industry.

In this research work, we aim to identify the criteria for selecting a cloud environment during a migration, and how we can evaluate the compliance of the cloud environment with the requirements linked to these criteria. To this end, we first carried out a qualitative study with industrial experts to identify the most recurring requirements of cloud environments in the industry. Then, we focused on estimating the operational costs of these environments, which are frequently mentioned as a criterion to be minimized, and which are often misunderstood, given the variety of pricing schemes of Cloud Computing. We therefore developed a conceptual model for estimating these costs, and then a tool that implements this conceptual model to automate the estimation.

Keywords

Cloud Computing, Cloud Migration, Requirements Engineering, Modeling, Operating costs estimation

Remerciements

En préambule de cet ouvrage, je veux adresser mes remerciements à tous ceux qui m'ont aidé à mener ce doctorat.

Dans un premier temps, je souhaite remercier tous ceux qui ont rendu ces trois années épanouissantes et riches d'enseignements.

En tout premier lieu, je remercie chaleureusement mon directeur de thèse M. Thomas Polacsek, chercheur à l'Office National d'Études et de Recherches Aérospatiales. En effet, inlassablement au cours de ces années, il m'a guidé dans mes travaux de recherche, partagé ses connaissances et ses intuitions, et s'est rendu grandement disponible pour nos sessions de travail et moult discussions passionnantes.

Ensuite, désirant dès le début réaliser un doctorat dans l'industrie, cela a été possible grâce à la confiance que m'a accordé M. Frédéric Volpi, président de Stack Labs, que je remercie grandement. Grand merci également à mon ami M. Clément Duffau, avec qui j'ai défini la mission de recherche et qui a été mon premier tuteur au sein de Stack Labs, ainsi qu'à M. Sébastien Lavayssière, directeur technique de Stack Labs et mon second tuteur industriel.

Merci à M^{me} Selmin Nurcan, professeur des universités à l'Université Paris 1 Panthéon Sorbonne, et M. Philippe Collet, professeur des universités à l'Université de Nice-Sophia Antipolis, d'avoir accepté d'être les rapporteurs de cette thèse, et qui m'ont fait part de précieux conseils autant pour améliorer le tapuscrit que pour la poursuite de mes travaux. Merci aussi à M. Iulian Ober, professeur à l'ISAE-SUPAERO, d'avoir présidé le jury lors de ma soutenance et pour ses retours.

Enfin, merci à mes collègues de l'Office National d'Études et de Recherches Aérospatiales, et de Stack Labs ; en particulier, merci à Bilal, Alexis et Noé qui ont relu le tapuscrit et partagé leurs retours.

Certes, ces années étaient particulièrement stimulantes intellectuellement, mais elles étaient aussi éprouvantes ; c'est pourquoi je profite de ces dernières lignes pour remercier les proches qui m'ont soutenu.

D'abord, bien sûr, merci à mes amis, et tout particulièrement (à nouveau) Clément, sa compagne Mélanie, Thomas et Thomas (!) avec qui j'ai passé de très bons moments, ainsi qu'à mes camarades de l'association L'En-Jeux à l'Isle-Jourdain. Grand merci à mon très cher ami Florian, qui m'a épaulé dans les périodes de doute et grâce à qui je suis allé jusqu'au bout.

Je veux enfin remercier ma soeur, mes parents et mes grands-parents, qui m'ont soutenu tout du long malgré la distance.

Table des matières

I	Motivation et contexte	1
1	Introduction	3
1.1	Contexte et problématique	3
1.2	Contributions	4
1.3	Plan du document	5
1.4	Exemple fil rouge	7
II	État de l’art	11
2	Concepts généraux	15
2.1	Informatique en nuage	15
2.2	Ingénierie des exigences	26
2.3	Conclusion	28
3	Migration infonuagique	31
3.1	Facteurs d’adoption	31
3.2	Stratégies de migration	37
3.3	Méthodologies de migration	42
3.4	Sélection d’un environnement infonuagique	47
3.5	Conclusion	53
4	Évaluation d’un concept d’environnement infonuagique	55
4.1	Évaluation par la simulation	56
4.2	Autres approches d’évaluation	65
4.3	Conclusion	73

III	Contributions	75
5	Identification des exigences de haut niveau dirigeant la sélection d'un environnement infonuagique lors d'une migration	79
5.1	Méthodologie de collecte des données	80
5.2	Corpus	84
5.3	Analyse des entretiens	86
5.4	Résultats	88
5.5	Discussion	99
5.6	Conclusion	107
6	Définition d'un modèle conceptuel pour l'estimation des coûts opérationnels d'une conception préliminaire de système infonuagique	109
6.1	Élicitation des buts	110
6.2	Modèle conceptuel	117
6.3	Satisfaction des buts	139
6.4	Conclusion	140
7	Développement d'un outil d'estimation des coûts opérationnels d'une conception préliminaire de système infonuagique	141
7.1	Détail de l'implémentation d'Ymir	142
7.2	Application à l'exemple fil rouge	158
7.3	Application industrielle	168
7.4	Conclusion	169
IV	Conclusion	171
8	Conclusion et perspectives	175
8.1	Synthèse de ce document	175
8.2	Perspectives	176
8.3	Liste des publications	179
	Résumés d'entretiens	181

Première partie

Motivation et contexte

Chapitre 1

Introduction

1.1 Contexte et problématique

Constituer l'hébergement d'un système informatique est une problématique commune dans l'industrie. L'acquisition d'une infrastructure informatique par les organisations a longtemps été la norme. Néanmoins, cette approche implique la maintenance de cette infrastructure : il s'agit d'un métier à part entière qui n'est pas celui de ces organisations. Par conséquent, l'idée d'une *informatique utilitaire* a émergé : cela consiste à distribuer les ressources informatiques par l'intermédiaire de services, de la même manière qu'est fourni l'électricité, l'eau ou l'internet aux particuliers. L'informatique en nuage¹ est un paradigme de l'informatique utilitaire qui a connu un intense développement dans les deux dernières décennies, sous l'impulsion d'entreprises étasuniennes tels qu'Amazon, Microsoft et Google. En effet, ces organisations ont, d'une part, diversifié l'offre de services infonuagiques, partant d'infrastructures virtuelles à des applications configurables et prêtes à l'usage. D'autre part, l'industrie a très rapidement adopté l'informatique en nuage : encore en 2023, le chiffre d'affaire des fournisseurs de services infonuagiques a crû de 20% par rapport à 2022 (GARTNER, 2023). L'adoption de l'informatique en nuage par l'industrie est donc très rapide, motivée notamment par l'attente d'une réduction des coûts d'hébergement du système informatique.

Cette adoption est concrétisée par l'abandon d'une infrastructure possédée par une organisation au profit de celle d'un tiers, partagée par plusieurs usagers à travers des services infonuagiques : il s'agit d'une migration. En matière de migration, diverses approches sont discutées, autant dans la littérature scientifique que dans des publications industrielles, qui rapportent l'expérience acquise et les recommandations des fournisseurs de services. Malheu-

1. Dans ce document, nous avons choisi d'utiliser les termes français *Informatique en nuage* et *infonuagique* pour désigner respectivement le nom et l'adjectif associés au terme anglais *Cloud Computing*.

reusement, ces approches sont trop souvent suivies mécaniquement dans l'industrie, aboutissant à d'importants décalages entre les attentes des organisations et la réalité. Un exemple de non-conformité connu concerne le coût de la migration. Dans une enquête présentée en 2021, l'entreprise McKinsey & Company conclut que 75% des organisations qui migrent leur système informatique sur un nuage informatique souffrent de dépassement du budget de migration (McKINSEY et COMPANY, 2021). Le coût d'hébergement du système informatique est aussi fréquemment mis en cause ; c'est la raison pour laquelle l'industrie adopte la démarche nommée « *FinOps* » afin de progressivement rétablir la rentabilité des systèmes d'information. *FinOps* est la mise en place de pratiques pour observer le système, et optimiser ce qui peut l'être en se basant sur ces observations. Néanmoins, ces corrections arrivant tard dans le cycle de vie du système informatique, il est trop coûteux d'envisager certaines transformations de fond, qui seraient nécessaire pour réduire considérablement le coût d'hébergement.

C'est le constat réalisé au sein de Stack Labs, société de conseil spécialisée dans l'informatique en nuage : comme certaines possibilités ne peuvent plus être envisagées après la migration, alors elles doivent être explorées dès les phases de conception. Cependant, c'est une tâche pour laquelle les développeurs se sentent démunis ; en effet, ils manquent de moyens (méthodes, outils) pour sélectionner un environnement infonuagique tôt dans la conception. Par conséquent, nous avons étudié les critères de comparaison entre les environnements infonuagiques lors d'une migration, et les moyens techniques d'évaluer ces critères avant même que l'environnement n'existe.

1.2 Contributions

Dans cette section, nous parcourons les contributions de ce doctorat, présentées dans ce document.

Exigences récurrentes des environnements infonuagiques dans les migrations La première contribution est l'identification des exigences les plus récurrentes dans l'industrie vis-à-vis des environnements infonuagiques lors d'une migration, ainsi que les conséquences qu'elles ont eu dans la sélection d'environnements infonuagiques dans divers projets. Connaître ces exigences est intéressant à plusieurs titres. D'abord, certaines exigences n'étaient pas considérées sur leur hébergement d'origine : elles apparaissent car la solution d'hébergement est un environnement infonuagique. De plus, disposer d'une liste d'exigences fréquemment exprimées dans d'autres projets permet de ne pas oublier de les éliciter dans un nouveau projet. Enfin, connaître les décisions prises par d'autres qui ont fait face aux mêmes types d'exigences permet d'assister notre propre prise de décision.

Modélisation de l'estimation des coûts d'un environnement infonuagique Notre deuxième contribution aborde l'une des exigences que nous avons identifiées, au sujet du coût de l'environnement infonuagique. Un environnement infonuagique a des coûts récurrents, facturés tous les mois ; il est donc important d'être en mesure de les estimer pour prendre des décisions qui conviennent au propriétaire du système informatique en cours de migration. Dans un contexte industriel, cette estimation doit être cadrée afin de ne pas faire d'erreur, de ne pas oublier d'élément facturé et de ne pas perdre de temps. Par conséquent, cette deuxième contribution est une modélisation de l'estimation des coûts, telle qu'elle devrait être menée dans l'industrie, c'est-à-dire en tenant compte de ses particularités organisationnelles.

Ymir, une implémentation de notre modèle conceptuel Enfin, notre troisième contribution est Ymir, un logiciel d'estimation des coûts d'un concept préliminaire d'environnement infonuagique. Il s'agit d'un simulateur à événements discrets qui implémente notre modèle conceptuel. Nous avons eu l'occasion de l'expérimenter au sein d'un projet industriel, dans lequel nous avons pu vérifier la précision de ses estimations et l'avantage qu'il donne aux concepteurs : celui de pouvoir expérimenter des variantes d'environnements infonuagiques afin de sélectionner le moins cher.

1.3 Plan du document

Ce document est composé de quatre parties. Ce chapitre introductif constitue la première partie. La deuxième partie est dédiée à l'état de l'art, la troisième aux contributions de la thèse ; enfin, la quatrième partie inclut les conclusions et les perspectives de cette thèse.

Partie II : État de l'art

Chapitre 2 : Concepts généraux Dans ce chapitre, nous donnons une brève introduction à l'informatique en nuage et à l'ingénierie des exigences, dont les concepts sont récurrents tout au long du document. L'objectif de ce chapitre est donc de fournir une compréhension suffisante du contexte de la thèse, ainsi que de rappeler les termes propres à ces domaines.

Chapitre 3 : Migration infonuagique Dans ce chapitre, nous analysons les travaux de la littérature scientifique en lien avec la migration infonuagique. Afin de mettre en lumière la notion d'exigences dans ce contexte, nous avons choisi de séquencer ce chapitre par étape de la migration : des facteurs d'adoption qui amènent une organisation à choisir l'informatique en nuage comme solution d'hébergement jusqu'à la méthode de sélection de l'environnement

infunuagique. Nous y mettons en lumière l'absence de travaux sur l'ingénierie des exigences adaptée à l'informatique en nuage.

Chapitre 4 : Évaluation d'un concept d'environnement infonuagique Dans ce chapitre, nous passons en revue les travaux visant à évaluer un ou plusieurs critères pouvant être l'objet d'une exigence des environnements infonuagiques. Nous comparons ces travaux, aussi bien académiques qu'industriels, puis nous détaillons ce qui leur manque, d'après nous, pour être adaptés à un usage industriel.

Partie III : Contributions

Chapitre 5 : Identification des exigences de haut niveau dirigeant la sélection d'un environnement infonuagique lors d'une migration Dans ce chapitre, nous présentons la démarche que nous avons mise en oeuvre pour identifier les exigences récurrentes dans l'industrie vis-à-vis des environnements infonuagiques lors d'une migration. Cela inclue notre protocole ainsi que le corpus et les résultats que nous avons obtenu. Enfin, nous analysons ces résultats : d'abord, nous les analysons sous le prisme de l'état de l'art au sujet des migrations, et ensuite nous les catégorisons pour faciliter leur analyse dans un contexte industriel.

Chapitre 6 : Définition d'un modèle conceptuel pour l'estimation des coûts opérationnels d'une conception préliminaire de système infonuagique Dans ce chapitre, nous présentons notre démarche d'analyse et de modélisation du processus d'estimation des coûts d'un environnement infonuagique. Ce travail a abouti à la définition d'un modèle conceptuel pour un outil à l'usage de l'industrie pour effectuer ces estimations.

Chapitre 7 : Développement d'un outil d'estimation des coûts opérationnels d'une conception préliminaire de système infonuagique Dans ce chapitre, nous expliquons le modèle de l'outil que nous avons développé en implémentant le modèle conceptuel du chapitre 6. Nous y présentons également les utilisations que cet outil a aujourd'hui dans l'industrie.

Partie IV : Conclusion

Chapitre 8 : Conclusion et perspectives Ce chapitre conclue ce document. Nous y résumons les travaux menés au cours de ce doctorat et nous proposons des perspectives pour les poursuivre.

1.4 Exemple fil rouge

Afin d'illustrer les notions abordées tout au long du document, nous définissons, dans cette section, un exemple fil rouge : la migration d'un segment sol simplifié vers un nuage public.

Cas d'utilisation du système informatique d'un segment sol Dans le domaine de l'observation de la Terre, le segment sol correspond aux équipements sur Terre qui communiquent avec une constellation de satellites. Notamment, il comporte un système informatique chargé de réceptionner, stocker, traiter et mettre à disposition des données satellitaires pour diverses utilisations ultérieures. La figure 1.1 illustre les cas d'utilisations d'un tel système informatique.

Un segment sol fonctionne de concert avec une constellation de satellites, c'est-à-dire un ensemble de satellites identiques répartis autour de la planète afin d'avoir une large couverture de la planète à chaque instant. Dans l'exemple fil rouge, ces satellites ont pour mission l'observation de la Terre : ils la photographient et transmettent ces données à une antenne au sol, celle de la *station terrienne*. Les premiers traitements de ces données ne concernent pas le système informatique : la station terrienne démodule le signal pour constituer des données brutes. Ces données consistent en l'image mais également des métadonnées, telles que la date de capture, la zone de la Terre qui a été photographiée ou l'orbite à laquelle l'image a été capturée. Ensuite, la station terrienne *téléverse ces données brutes* sur le système informatique du segment sol. Ce système informatique *traite automatiquement* ces données brutes. L'*orthorectification* est un exemple de ces traitements : quand une image a été capturée de biais, l'orthorectification élimine l'effet de l'angle de capture et des reliefs afin de présenter l'image comme si elle avait été prise verticalement. Une autre transformation classique est *la transformation d'un format d'image à un autre*. Après avoir réalisé ces traitements, l'image est mise à disposition dans un catalogue : un *client* peut effectuer des *recherches*, basées sur les métadonnées de l'image. Si une image correspond à sa recherche, il peut la *télécharger*.

Changement de solution d'hébergement Le système informatique que nous venons de décrire est initialement hébergé dans les locaux de l'agence spatiale. Cependant, la gestion d'un parc de machines informatiques n'est en rien le cœur de métier de cette organisation. Elle pourrait donc bénéficier de déléguer cette gestion à un tiers.

L'informatique en nuage est, justement, une solution d'hébergement dans laquelle cette gestion est déléguée à un tiers, nommé *fournisseur de services*. L'adoption de l'informatique en nuage par l'agence spatiale nécessite une migration de son système informatique, ce qui inclut la sélection de l'environnement — les ressources — qui compose l'hébergement du système




FIGURE 1.1 – Diagramme de cas d'utilisation du système informatique dédié au traitement et à la mise à disposition des données satellitaires dans un segment sol

informatique chez le fournisseur de services. Cette sélection ne peut se passer, en amont, d'une phase de conception permettant de déterminer les nouvelles exigences que l'agence spatiale a vis-à-vis de l'environnement infonuagique, et si cet environnement les satisfait.

Deuxième partie

État de l'art

Chapitre 2

Concepts généraux

Cette thèse s’inscrit dans le contexte de l’informatique en nuage, et particulièrement de la migration infonuagique. De plus, elle aborde les exigences qui doivent être prises en compte dans ce contexte. C’est pour cette raison que nous dédions ce chapitre à la présentation des concepts de l’informatique en nuage et de l’ingénierie des exigences qui seront utiles à la compréhension de l’ensemble du document.

Le chapitre est organisé comme suit. La section 2.1 présente les bases de l’informatique en nuage. Dans la section 2.2, nous expliquons les termes que nous utilisons pour l’ingénierie des exigences. Enfin, nous résumons le contenu de ce chapitre dans la section 2.3.

2.1 Informatique en nuage

Dès 1997, Chellappa définit l’informatique en nuage comme « *un paradigme informatique dans lequel les limites de l’informatique seront déterminées par la logique économique plutôt que par les seules limites techniques* »¹ (CHELLAPPA, 1997). En d’autres termes, l’utilisation de l’informatique en nuage est davantage limitée par l’argent qu’une organisation consent à dépenser que par des contraintes liées à la gestion de l’infrastructure informatique, son hébergement et son raccordement au réseau. S’il s’agissait d’une première définition d’un paradigme pas encore implémenté, c’est avec les services fournis par Amazon Web Services², Google Cloud Platform³

1. Dans le texte : « *a computing paradigm, where the boundaries of computing will be determined by economic rationale, rather than technical limits alone* ».

2. Amazon Web Services (AWS), une division de l’entreprise Amazon : <https://aws.amazon.com/fr/>.

3. Google Cloud Platform (GCP), une offre de service de l’entreprise Google : <https://cloud.google.com/>.

et Microsoft Azure⁴ que l'appellation *Informatique en nuage* s'impose dans la deuxième moitié des années 2000 (QIAN et coll., 2009). Dès lors, de nombreux travaux se sont attachés à définir clairement ce concept.

En 2009, González et coll. effectuent une revue de vingt définitions proposées dans la littérature pour en tirer une synthèse. Il en sort un consensus quant au fait que l'informatique en nuage est un modèle de distribution de ressources informatiques par l'intermédiaire de services ; l'ensemble des services proposés par une entité, un fournisseur de services, est appelé un *nuage informatique* (GONZÁLEZ et coll., 2009).

Ils comparent ensuite les nuages aux grilles informatiques (en anglais : *Grid Computing*). Cette comparaison est utile car les deux sont fréquemment confondus dans la première décennie de l'informatique en nuage. Par exemple, Achim et coll. affirment que « *dans les milieux scientifiques, nous parlons de services d'hébergement sur grille informatique, tandis que l'informatique en nuage est promue dans le commerce comme une solution pour réduire les coûts* »⁵ (ACHIM, POP et CRISTEA, 2011). Entre les nuages et les grilles, Vaquero et coll. constatent quelques similarités. Par exemple, les deux sont des agrégations de ressources informatiques hétérogènes et permettent la mise à l'échelle de l'infrastructure. Ils mettent également en lumière des caractéristiques propres à l'informatique en nuage, telles que la flexibilité de la tarification, l'utilisabilité ou l'usage systématique de la virtualisation.

Finalement, Mell et Grance du *National Institute of Standards and Technology (NIST)*⁶ proposent en 2011 une définition de l'informatique en nuage qui est aujourd'hui communément acceptée aussi bien dans la littérature scientifique que dans l'industrie (MELL et GRANCE, 2011). D'après cette définition, « *l'informatique en nuage est un modèle permettant un accès réseau ubiquitaire, pratique et à la demande à un ensemble partagé de ressources informatiques configurables (p. ex. réseaux, serveurs, stockage, applications) qui peuvent être rapidement approvisionnées et libérées avec un minimum d'effort de gestion ou d'interaction avec le fournisseur de services.* »⁷.

Dans cette section, nous présentons l'informatique en nuage en nous basant sur les définitions de González et coll. et du *NIST* qui détaillent les rôles, les caractéristiques des services infonuagiques, les modèles de services infonuagiques et les modèles de déploiement des nuages informatiques.

4. Microsoft Azure, une offre de services de l'entreprise Microsoft : <https://azure.microsoft.com/>.

5. Dans le texte : « *In scientific environments we are speaking about Grid Computing infrastructure hosting services while in commercial area Cloud Computing is advertised as solution for reducing costs* ».

6. Le *National Institute of Standards and Technology* est une agence gouvernementale étasunienne qui promeut l'innovation et la compétitivité industrielle des entreprises, notamment en émettant des normes en partenariat avec le secteur industriel.

7. Dans le texte : « *Cloud computing is a model for enabling ubiquitous, convenient, on-demand network access to a shared pool of configurable computing resources (e.g., networks, servers, storage, applications, and services) that can be rapidly provisioned and released with minimal management effort or service provider interaction [...].* »

2.1.1 Rôles dans l'informatique en nuage

Dans leur synthèse de l'informatique en nuage, González et coll. ont identifié trois rôles : les fournisseurs d'infrastructure, les fournisseurs de services, et les usagers des services.

Usager de services infonuagiques Un *usager* utilise des services infonuagiques pour déployer des ressources informatiques⁸. Ces dernières lui permettent d'atteindre ses objectifs.

L'ensemble des ressources informatiques déployées par ces services afin d'héberger un système informatique est appelé un *environnement infonuagique*. La *sélection d'un environnement* est l'ensemble des choix de conception de l'environnement infonuagique par un usager : le ou les fournisseurs de services choisis, les services utilisés et la configuration retenue de ces services.

Fournisseur d'infrastructure Un *fournisseur d'infrastructure* possède une infrastructure matérielle qui héberge des services infonuagiques. Cette infrastructure matérielle se situe dans un ou plusieurs centres informatiques (en anglais : *Data Center*). Parmi les fournisseurs d'infrastructure, nous pouvons citer les fournisseurs de services Amazon Web Services, Microsoft Azure et Google Cloud Platform : ils possèdent entièrement ou partiellement l'infrastructure qui héberge leurs services infonuagiques.

Fournisseur de services Un *fournisseur de services* délivre des *ressources informatiques* à un usager par l'intermédiaire de *services infonuagiques* configurables. Ces services reposent sur l'infrastructure matérielle d'un fournisseur d'infrastructure. Le fournisseur de services est donc en charge de la couche logicielle qui permet d'attribuer des portions de l'infrastructure physique aux usagers.

Dans le paragraphe précédent, nous avons cité des fournisseurs de services qui sont également fournisseurs d'infrastructure ; cette association n'est cependant pas systématique. En effet, une organisation peut utiliser l'infrastructure d'une autre organisation pour délivrer des services infonuagiques. Notons que certains fournisseurs de services qui proposent de nombreux centres informatiques à leurs usagers ne sont pas forcément propriétaires de tous ces centres : par exemple, c'est le cas de Google Cloud qui déclare louer certains de ses centres

8. L'*usager* de services infonuagiques est nommé différemment par ailleurs. Parfois, il est nommé *utilisateur*, certainement car le terme anglais *user* se traduit aussi bien par *usager* que par *utilisateur*. Dans notre contexte, nous devons considérer plusieurs types de *user*, c'est pourquoi nous précisons ici que, dans la suite de ce document, *usager* désigne à l'entité définie dans cette section, tandis qu'*utilisateur* désigne l'entité qui utilise les fonctionnalités mise à disposition par l'*usager*. Un autre terme fréquemment utilisé est *client*, mais ce terme est, d'une part, polysémique, et, d'autre part, il peut ne pas toujours correspondre à la réalité. En effet, si l'*usager* utilise les services infonuagiques d'une entreprise, il est un client au sens du commerce ; mais ce n'est pas le cas si les services infonuagiques sont fournis par une association.

informatiques⁹. Une autre alternative est d'utiliser les services infonuagiques d'une autre organisation pour délivrer un nouveau service infonuagique. C'est le cas, par exemple, de Elastic Cloud¹⁰ qui est un service infonuagique qui délivre le logiciel Elasticsearch à la demande. Elastic Cloud est fourni par l'entreprise Elastic et repose sur les services infonuagiques de divers fournisseurs de services¹¹. Elastic est donc à la fois un fournisseur et un usager de services.

Exemple fil rouge

En adoptant l'informatique en nuage pour héberger son système informatique, l'agence spatiale va être amenée à sélectionner un environnement infonuagique en utilisant les services de divers fournisseurs. Par exemple, elle peut sélectionner un service de stockage de documents pour héberger les images satellitaires, et un autre qui déploie des machines virtuelles pour exécuter les logiciels pour transformer les images. Dès lors, elle sera un *usager* de services infonuagiques.

En outre, les possibles modernisations du système informatique qui ont lieu lors de la migration peuvent amener l'agence spatiale à devenir un *fournisseur de services*. En effet, elle peut par exemple décider de fournir un service de recherche de données satellitaires à la demande, comme un service infonuagique.

Dans cette situation, l'agence spatiale peut également décider d'héberger ses services sur sa propre infrastructure plutôt que de bénéficier des services d'un tiers, auquel cas elle sera un *fournisseur d'infrastructure* au lieu d'être un *usager* de services infonuagiques.

2.1.2 Modèles de déploiement

Un modèle de déploiement d'un nuage informatique définit à quel type d'utilisateurs sont fournis les services de ce nuage. La définition du NIST comporte quatre modèles de déploiement, à savoir les nuages privés, communautaires, publics et hybrides.

Nuage privé Un *nuage privé* fournit ses services à une unique organisation, qui peut comprendre plusieurs utilisateurs. Le fournisseur d'infrastructure peut être cette même organisation ou un tiers.

9. Zones et régions de Google Cloud : <https://cloud.google.com/docs/geography-and-regions>.

10. Documentation de Elastic Cloud : <https://www.elastic.co/fr/cloud>.

11. Centres informatiques disponibles pour Elastic Cloud : <https://www.elastic.co/guide/en/cloud/current/ec-reference-regions.html>.

Nuage communautaire Un *nuage communautaire* fournit ses services à un groupe d'organisations. Le fournisseur d'infrastructure peut être l'une des organisations de ce groupe ou un tiers.

Un exemple de nuage communautaire est celui de l'entreprise Amadeus, qui fournit divers services notamment à l'usage des compagnies aériennes, par exemple pour la réservation de billets d'avion. Ces services sont fournis uniquement à un groupe de compagnies aériennes. Il s'agit donc d'un nuage communautaire.

Nuage public Un *nuage public* fournit ses services à toutes les organisations. Le fournisseur d'infrastructure est nécessairement un tiers.

Google Cloud et Scaleway sont des nuages publics.

Les services des nuages publics ont de nombreux modèles de tarification. En particulier, nombreux sont ceux qui facturent en fonction de l'usage (en anglais : *pay-as-you-go*), ce qui signifie que le montant facturé est proportionnel à l'utilisation des services. Par exemple, un service de stockage de documents facture en fonction de la quantité de données stockées et de la durée de stockage de ces données. D'autres modèles de tarification existent. MAZREKAJ, SHABANI et SEJDIU (2016) en identifient quinze, dont l'abonnement, par exemple quand un usager s'engage auprès du fournisseur de services à utiliser une machine virtuelle pour une longue durée afin d'obtenir un rabais, et l'enchère : plusieurs usagers sont en compétition pour détenir une ressource, qui revient à celui qui paie le plus.

Nuage hybride Un nuage hybride est la combinaison des services de plusieurs nuages, éventuellement avec divers modèles de déploiement.

Un nuage hybride peut résulter de la collaboration de plusieurs fournisseurs de services qui forment une *fédération de nuages*. Sinon, cela résulte de l'utilisation de plusieurs nuages par un usager : dans ce cas, l'environnement est dit *multinuagique* (en anglais : *multi-cloud*) (PETCU, 2013).

Exemple fil rouge

Le choix du modèle de déploiement s'impose à l'agence spatiale, qui doit choisir selon ses besoins.

Afin de garder le contrôle du système, elle peut mutualiser les infrastructures physiques de toutes ses divisions afin de constituer un nuage qui fournit des services à l'ensemble de l'organisation. Ce sera alors un *nuage privé*. Alternativement, elle peut louer un *nuage privé* à un fournisseur d'infrastructure, ce que propose par exemple l'entreprise OVH. Avec un nuage privé, le système est limité par la taille de l'infrastructure

pour lequel l'agence spatiale a investi.

Afin de ne pas être ainsi limité, l'agence spatiale peut préférer utiliser les services d'un *nuage public*. En effet, au lieu d'être contraint par la taille de l'infrastructure, le fournisseur de services d'un nuage public limite l'utilisation de ses services en imposant des quotas, qui peuvent toutefois être négociés. En outre, le coût étant proportionnel à l'usage, prendre en charge des pics de charge occasionnels dans le système informatique sera moins onéreux que d'agrandir l'infrastructure matérielle d'un nuage privé. Cependant, ce choix s'accompagne de nouvelles problématiques notamment pour une organisation manipulant des données sensibles, car l'infrastructure matérielle est partagée par plusieurs organisations et possédée par un tiers.

Pour mitiger ce risque, il est possible d'opter pour un *nuage communautaire* constitué par un groupe d'organisations, dont l'agence spatiale, afin de mettre en commun leurs capacités informatiques. De cette manière, les informations sensibles demeurent dans ce groupe d'organisations, dont nous pouvons supposer qu'elles se sont associées car elles se font mutuellement confiance. Cette possibilité n'est cependant pour l'instant pas très répandue dans l'industrie, à notre connaissance.

Enfin, il est possible de bénéficier des caractéristiques de plusieurs modèles de déploiement, par exemple en hébergeant sur un nuage privé les données sensibles et le reste du système sur un nuage public. Il s'agirait d'un *nuage hybride*. Cette configuration permet de respecter les politiques de confidentialité tout en profitant de ressources moins onéreuses pour les traitements des requêtes. Cependant, l'utilisation de plusieurs nuages s'accompagne de complications pour le développement et la maintenance opérationnelle du système, dû à l'hétérogénéité entre les fournisseurs de services.

2.1.3 Caractéristiques des services infonuagiques

Le *NIST* attribue cinq caractéristiques aux services infonuagiques. Ils sont en (i) libre-service et configurables à la demande, (ii) accessibles à travers le réseau, reposent sur (iii) la mise commun d'une infrastructure physique pour tous leurs usagers, (iv) leur utilisation est mesurée et contrôlée, et ils assurent (v) une élasticité rapide. Il s'agit des caractéristiques perçues par les usagers. Nous les expliquons dans les paragraphes suivants.

Libre-service à la demande (en anglais : *On-demand self-service*) Les services infonuagiques peuvent être configurés à tout moment, sans passer par un intermédiaire humain.

Accès ubiquitaire par le réseau (en anglais : *Broad network access*) La configuration des services infonuagiques se fait par requêtes sur le réseau (Internet, réseau privé) et peut être réalisée depuis divers terminaux (p. ex. serveurs, ordinateurs portable, téléphone).

Mise en commun de l'infrastructure (en anglais : *Resources pooling*) L'infrastructure physique mise à disposition par un service infonuagique est mise en commun pour tous les usagers. Ces derniers n'ont pas de connaissance précise quant aux composants matériels qui leur est alloué. Par exemple, il ne sait pas nécessairement quel est le modèle du processeur ou la localisation exacte des serveurs.

Service mesuré (en anglais : *Measured service*) Les ressources déployées par les services infonuagiques sont contrôlées par diverses métriques propres au type de chaque service. Par exemple, l'espace de stockage utilisé sur un service de stockage de document ou le volume de données qui transite sur le réseau du fournisseur de services.

Les fournisseurs de services peuvent imposer des quotas sur l'utilisation des services (p. ex. limite de bande passante sur le réseau) et se servent de ces mesures pour vérifier si ces quotas sont atteints. Dans le cas des nuages publics, ces mesures servent à appliquer une tarification à l'usage, c'est-à-dire proportionnelle à l'utilisation des services infonuagiques.

Élasticité rapide (en anglais : *Rapid elasticity*) HERBST, KOUNEV et REUSSNER (2013) définissent l'*élasticité* (en anglais : *elasticity*) dans l'informatique en nuage comme « *le degré auquel le système est capable de s'adapter aux variations de la charge de calcul en approvisionnant et désapprovisionnant des ressources automatiquement, de telle manière que les ressources provisionnées correspondent autant que possible au besoin* »¹².

Ils distinguent l'élasticité de la *capacité de mise à l'échelle* (en anglais : *scalability*), qui en est un prérequis et qu'ils définissent comme « *la capacité d'un système à faire face à des charges de calcul croissantes par l'usage de ressources supplémentaires [...]* »¹³. Ils soulignent que la capacité de mise à l'échelle n'a pas de rapport avec l'adéquation entre la quantité de ressources

12. Dans le texte : « *Elasticity is the degree to which a system is able to adapt to workload changes by provisioning and deprovisioning resources in an autonomic manner, such that at each point in time the available resources match the current demand as closely as possible* ».

13. Dans le texte : « *Scalability is the ability of the system to sustain increasing workloads by making use of additional resources [...]* ».




FIGURE 2.1 – Illustration de la mise à l'échelle de l'environnement au fil du temps par différents types de services, afin de satisfaire le besoin en ressources

provisionnées et le besoin en ressources, ni avec le temps que prend l'approvisionnement de ces ressources.

Ainsi, les environnements déployés par des services infonuagiques peuvent être configurés de manière à disposer à tout instant du nombre adéquat de ressources pour satisfaire les besoins des usagers. En outre, les ressources sont infinies de la perspective des usagers.

Cependant, tous les services infonuagiques ne sont pas également élastiques. C'est ce qu'illustre la figure 2.1. La courbe noire est le besoin en ressources pour satisfaire les demandes des clients du système informatique. Ce besoin fluctue dans le temps. Par exemple, un système informatique utilisé par des employés de bureau sur un seul créneau horaire sera davantage sollicité pendant les horaires de bureau que pendant la nuit. Les courbes orange et bleue correspondent aux ressources approvisionnées par des services dotés d'une élasticité différente. La courbe orange correspond à des services tels que ceux de machines virtuelles à la demande. Dans ces services, l'approvisionnement de nouvelles ressources se fait par grands pas : une machine virtuelle comporte plusieurs cœurs *CPU*, une grande quantité de mémoire vive ainsi qu'un ou plusieurs disques durs. C'est pour cette raison que des intervalles apparaissent nettement à chaque mise à l'échelle. De plus, cela cause le surapprovisionnement de l'environnement, c'est-à-dire qu'il contient plus de ressources qu'il n'en a réellement besoin. En outre, l'approvisionnement d'une machine virtuelle est long : il inclut, par exemple, l'allocation des ressources physiques par l'hyperviseur du fournisseur de services, l'installation du système d'exploitation et le démarrage des logiciels utiles pour le système informatique. Pour cette raison, il convient de surapprovisionner l'environnement pour éviter les conséquences d'un pic de charge soudain. Quant à la courbe bleue, elle correspond davantage à des services tels que de conteneur

à la demande. Ces derniers déploient très rapidement des conteneurs qui monopolisent peu de ressources. Il est donc possible de limiter considérablement le surapprovisionnement de l'environnement.

Lors de la conception d'un environnement infonuagique, il est important de tenir compte de la mise à l'échelle automatique de cet environnement. En effet, il en va de la quantité de ressources physiques qu'il va mobiliser à chaque instant, ce qui a des répercussions, d'une part, sur la capacité du fournisseur de services à satisfaire un grand nombre d'utilisateurs¹⁴, et, d'autre part, sur le montant facturé dans un nuage public, car il croît avec la quantité de ressources provisionnées dans le temps.

Exemple fil rouge

Comme évoqué auparavant, l'agence spatiale pourrait désirer migrer son système en faisant de sa fonctionnalité de recherche d'images satellitaires un service infonuagique. Le système devrait alors présenter les caractéristiques que nous venons de détailler.

Cela signifierait que :

- les utilisateurs de ce service n'ont pas à interagir avec un être humain pour chercher des images satellitaires (i);
- les utilisateurs peuvent chercher des images satellitaires via l'internet (ii);
- le stockage des images satellitaires et le traitement des requêtes de tous les utilisateurs emploient le même environnement infonuagique (iii);
- les utilisateurs et l'agence spatiale peuvent suivre en continu diverses métriques propres aux opérations du service, telles que le coût engendré par la recherche des images satellitaires, le bon fonctionnement du service ou l'utilisation de la bande passante (iv);
- les ressources matérielles allouées à chaque requête des utilisateurs s'adaptent rapidement et au fur et à mesure pour assurer qu'elle sera traitée dans un temps raisonnable, que l'image satellitaire sera restituée en une bonne qualité, en d'autres termes : pour assurer un certain niveau de qualité du service (v).

2.1.4 Modèles de services

La définition du *NIST* identifie trois modèles de services infonuagiques : les services d'infrastructure à la demande, de plateforme à la demande et des logiciels à la demande. Dans leur synthèse, González et coll. ont abouti aux mêmes catégories.

14. Pour l'utilisateur, les capacités sont supposées illimitées, mais il demeure la réalité physique qui s'impose au fournisseur de services. Par exemple, tout le matériel dédié à un certain gabarit de machine virtuelle pourrait être en cours d'usage, empêchant la création d'une nouvelle machine virtuelle avec ce gabarit.

Chaque catégorie correspond à un niveau de délégation des responsabilités de l'utilisateur vers le fournisseur de services.

Service d'infrastructure à la demande (IaaS) Un service d'infrastructure à la demande (en anglais : *Infrastructure as a Service, IaaS*) déploie des composants d'une infrastructure. Il peut s'agir, par exemple, de machines, de disques, de composants de mise en réseau, d'accélérateurs graphiques. Tous ces éléments sont virtualisés, ce qui permet au fournisseur de services de fournir des portions de son infrastructure physique à ses usagers, tout en les isolant les uns des autres.

Les préoccupations lors de l'administration d'environnements basés sur des *IaaS* sont similaires à celles pour une infrastructure physique. En effet, il est nécessaire par exemple de surveiller l'occupation des disques durs virtuels et de les remplacer ou d'en ajouter quand ils approchent de la saturation.

Le service de AWS nommé Elastic Compute Cloud ¹⁵ (*EC2*) est un *IaaS*. En effet, il permet le déploiement de machines virtuelles avec un système d'exploitation et des disques virtuels. Les services Nova ¹⁶ d'OpenStack et Google Compute Engine ¹⁷ (*GCE*) sont des *IaaS* qui présentent des fonctionnalités similaires.

Service de plateforme à la demande (PaaS) Un service de plateforme à la demande (en anglais : *Platform as a Service, PaaS*) déploie un logiciel permettant à des développeurs de déployer leurs propres logiciels. Les services infonuagiques déployant des bases de données ou des orchestrateurs de conteneurs applicatifs sont des exemples de *PaaS*.

Utiliser un *PaaS* a des avantages pour une organisation. En effet, tout ou partie de la maintenance opérationnelle de la plateforme est effectuée par le fournisseur de services, qui garantit le fonctionnement dans un contrat de niveau de service. Par exemple, l'utilisateur n'a pas à mettre à jour lui-même le système de gestion de base de données quand il est déployé par un *PaaS* : le fournisseur de services effectue cette mise à jour en suivant les modalités inscrites dans le contrat. Utiliser ces services comporte également des inconvénients. En particulier, utiliser des *PaaS* nécessite d'adapter les logiciels qu'ils exécutent (p. ex. un langage de programmation, une bibliothèque). Or, nombreux sont les services infonuagiques déployant des plateformes que seul le fournisseur de services peut déployer (p. ex. parce que c'est un logiciel propriétaire développé par ce fournisseur de services). Par conséquent, l'utilisateur de ces *PaaS* devra consentir à des développements supplémentaires s'il veut cesser de l'utiliser : c'est l'enfermement pro-

15. Documentation de AWS EC2 : <https://aws.amazon.com/fr/pm/ec2>.

16. Documentation du composant Nova d'OpenStack : <https://docs.openstack.org/nova>.

17. Documentation de GCE : <https://cloud.google.com/compute>.

priétaire.

BigQuery est un exemple de *PaaS* de Google Cloud qui déploie des systèmes de gestion de bases de données avec lesquels l'utilisateur interagit grâce à un dialecte de *SQL*. L'allocation des ressources de calcul et de stockage est effectuée par Google Cloud, qui assure par exemple une disponibilité du service de 99.9% dans son édition Standard ¹⁸.

Service de logiciel à la demande (*SaaS*) Un service de logiciel à la demande (en anglais : *Software as a Service, SaaS*) déploie un logiciel prêt à l'usage. Il ne s'agit pas d'une solution avec laquelle héberger un système logiciel, ce qui le distingue des *PaaS*.

Par exemple, Outlook est un *SaaS* de Microsoft qui délivre des adresses électroniques et du stockage pour les courriels.

Exemple fil rouge

Au cours de sa migration, l'agence spatiale va décider d'une solution pour héberger et rechercher des images satellitaires.

Une première solution serait de déployer une infrastructure virtuelle similaire au système tel qu'il existe sur site, grâce à des *IaaS*. Cependant, cela maintient de nombreuses tâches pour les équipes de maintenance du système informatique, telles que la surveillance et la mise à l'échelle du stockage.

Une alternative serait d'utiliser un service de stockage de documents en *PaaS* tel que Google Cloud Storage. En effet, utiliser ce service consiste uniquement à écrire et lire les images satellitaires sans préoccupation pour l'infrastructure. Néanmoins, ce service ne suffirait pas à implémenter la fonctionnalité de recherche d'images : il faudrait y adjoindre une base de données pour stocker les métadonnées des images satellitaires, ainsi que des ressources pour exécuter un serveur Web pour répondre aux requêtes.

Afin de simplifier le système informatique, elle peut opter (si un tel service existe) pour un *SaaS* de système de gestion d'une base de données d'images satellitaires. Ainsi, toutes les préoccupations techniques sont dissimulées à l'agence spatiale, au prix de limites fonctionnelles : par exemple, l'impossibilité de rechercher une image satellitaire sur certains critères, comme des métadonnées propres à ses images.

18. La garantie de disponibilité fait partie du contrat de niveau de service de BigQuery : <https://cloud.google.com/bigquery/sla>.

2.2 Ingénierie des exigences

Le concept d'exigences dans l'ingénierie logicielle est utilisé au moins dès les années 1960 pour expliquer ce qui est attendu d'un système logiciel (BOEHM, 2006). En 1977, Ross explique que « *la définition des exigences doit indiquer pourquoi un système est nécessaire dans les conditions actuelles ou futures, quelles sont les caractéristiques que ce système doit présenter pour qu'il satisfasse ce contexte, et comment il doit être développé* »¹⁹ (Ross et JR., 1977). Une exigence n'est pas un besoin : le besoin est ce qui est nécessaire à un utilisateur, une exigence est une caractéristique du système qui permet à l'utilisateur du système de satisfaire son besoin.

Le terme *exigence* n'a pas une unique définition consensuelle ; en effet, il a été employé pour désigner des propositions variées (SOMMERVILLE, 2011). Cependant, il est convenu dans la littérature qu'une exigence correctement formulée présente plusieurs qualités ; notamment, elle devrait être atomique (n'aborder qu'un seul élément), vérifiable (il est possible de s'assurer qu'elle est satisfaite dans un système), et concise, ne pas être ambiguë (DOE, 1998).

Les exigences peuvent être de diverses natures. Une classification très répandue distingue les exigences fonctionnelles des exigences non fonctionnelles (KOTONYA et SOMMERVILLE, 1998b). Les exigences fonctionnelles décrivent les capacités du système, les fonctionnalités qu'ils apportent à ses utilisateurs. Quant aux exigences non fonctionnelles, elles sont les propriétés du système, elles précisent dans quelles conditions les fonctionnalités sont fournies à l'utilisateur. Chacune de ces classes peut être raffinée pour préciser le type d'exigence dont il est question.

Exemple fil rouge

Le système informatique de l'agence spatiale doit permettre à ses utilisateurs de chercher des images satellitaires. Il s'agit d'une exigence fonctionnelle.

Cependant, ces images peuvent comporter des données sensibles, telles que des données personnelles de citoyens européens. L'usage de ces données est réglementé par le RGPD : pour pouvoir manipuler ces données, le système doit être en conformité avec ce règlement. Il s'agit d'une exigence non fonctionnelle.

2.2.1 Processus d'ingénierie des exigences

Diverses activités ont lieu au cours du développement afin d'identifier et de tirer profit de la connaissance des exigences du système. Ces activités forment un processus d'ingénierie des

19. Dans le texte : « *requirements definition must say why a system is needed, based on current or foreseen conditions, [...]. It must say what system features will serve and satisfy this context. And it must say how the system is to be constructed* ».

exigences.

SOMMERVILLE (2011) identifie quatre activités de haut niveau, pouvant chacune être raffinées en activités plus précises, et les ordonne dans un processus en mettant en évidence les documents produits par chacune de ces activités. Nous reproduisons le schéma de ce processus dans la figure 2.2. En partant des besoins initialement apportés par les utilisateurs, une *étude de faisabilité* permet d'estimer si des technologies existantes permettent déjà d'y répondre. De plus, elle permet de fournir un premier regard sur les coûts engendrés par le développement et l'exploitation d'un nouveau système répondant à ces besoins. L'ensemble de ces conclusions est consigné dans un *rapport de faisabilité*. Ensuite, une étape d'*élicitation et d'analyse des exigences* permet de découvrir le plus exhaustivement possible les exigences des utilisateurs et des parties prenantes du développement du système, et de déterminer les conflits qu'il peut y avoir entre elles. Divers prototypes et *modèles du système* peuvent être développés à cette étape afin d'aider la spécification du système. Puis, la *spécification des exigences* permet de traduire les informations produites lors de l'analyse en un ensemble d'*exigences du système et des utilisateurs*, c'est-à-dire des exigences de haut niveau pour être comprises par les utilisateurs, et des exigences beaucoup plus détaillées, de bas niveau, destinées aux développeurs du système. Enfin, une étape de *validation des exigences* permet d'assurer que l'ensemble des exigences soit réalisable et complet. À chaque étape, des erreurs peuvent être détectées et nécessiter de revenir à l'étape précédente. Par exemple, si la validation des exigences conclut que le système ainsi spécifié n'est pas réalisable, alors des corrections doivent être apportées en réalisant à nouveau les étapes précédentes. Finalement, l'ensemble de ces activités permet de produire un *référentiel des exigences*, qui se doit d'être complet et cohérent, pour diriger le développement du système.

2.2.2 Ingénierie des exigences orientée buts

Si les exigences prescrivent les caractéristiques du système et de son développement, les *buts*, quant à eux, prescrivent *pourquoi* le système doit être ainsi et doit être ainsi développé. Un but est un objectif qu'un système doit atteindre ; ils sont davantage l'expression d'un souhait qu'une destination exactement définie et à atteindre à tout prix (LAMSWERDE, 2001). Considérer les buts dans un processus d'ingénierie des exigences permet notamment de s'assurer de la pertinence de toutes les exigences qu'il contient (c.-à-d. qu'il ne contient que des exigences réellement utiles pour satisfaire un besoin), d'expliquer les exigences aux parties prenantes, d'aider à la spécification des exigences, d'identifier les conflits entre ces buts, d'aider l'identification de nouvelles exigences.

Tout comme la distinction entre exigences fonctionnelle et non fonctionnelle demeure per-




FIGURE 2.2 – Processus d’ingénierie des exigences (SOMMERVILLE, 2011)

tinente pour les buts, une autre classification commune distingue les buts *durs* des buts *mous* (respectivement en anglais : *hard goal* et *soft goal*) : les buts *durs* ne sont pas ambigus quant à ce qu’il faut atteindre, tandis que les buts *mous* définissent une direction à suivre (DALPIAZ, FRANCH et HORKOFF, 2016; LAMSWEERDE, 2004). Par exemple, en ce qui concerne les finances pour un projet, un but dur fixerait un budget (il est possible à tout moment de dire si le but est respecté ou non) tandis qu’un but mou prescrirait de minimiser les dépenses.

2.3 Conclusion

Dans ce chapitre, nous avons introduit et expliqué les concepts de base de l’informatique en nuage et de l’ingénierie des exigences que nous utilisons tout au long de ce document. Il s’agit, en effet, des deux principales thématiques de cette étude.

Nous avons vu que les environnements infonuagiques ont diverses propriétés remarquables en ce qui concerne leur exploitation. En particulier, leur élasticité permet aux usagers de limiter leurs dépenses ou, en tout cas, l’empreinte de leur système informatique sur l’infrastructure physique qui l’héberge. Cependant, cette élasticité résulte de décisions lors de la conception de l’environnement infonuagique, car tous les services infonuagiques ne sont pas également élastiques. Nous avons également vu que, dans les phases précoces de la conception d’un système, un processus d’ingénierie des exigences permet, par la découverte et l’analyse des buts et exi-

gences des utilisateurs du système, d'identifier précisément ce qui attendu de ce système.

Dans le chapitre suivant, nous présentons la migration infonuagique, qui est un cas de processus de développement nécessitant la conception d'un environnement infonuagique.

Chapitre 3

Migration infonuagique

Au cours de la décennie passée, l’informatique en nuage a été massivement adoptée par l’industrie. Diverses motivations sont à l’origine de l’acceptation de ce paradigme, et aboutissent à la migration du système informatique d’une organisation vers un nuage. Une *migration infonuagique* est un processus de développement qui débute dès l’analyse du système à migrer et de ses contextes de développement, de maintenance et d’utilisation, et qui aboutit à la mise en service de ce système sur un environnement infonuagique.

Dans ce chapitre, nous passons en revue l’état de l’art au sujet des migrations infonuagiques, à commencer par les facteurs qui motivent les migrations, en section 3.1. Nous poursuivons sur les processus de migration. Ils sont décrits dans la littérature à plusieurs niveaux de granularité. Dans un premier temps, en section 3.2, nous détaillons les travaux sur les *stratégies de migration*, qui décrivent des scénarios possibles pour les migrations (p. ex. les services infonuagiques utilisés, les types d’activités menées dans la migration). Puis, dans un second temps, nous détaillons en section 3.3 notre étude des travaux au sujet des méthodologies de migration, qui permettent d’implémenter des stratégies de migration. Nous verrons qu’une activité essentielle de ces méthodologies est la sélection de l’environnement infonuagique. De nombreux travaux ont par ailleurs été menés pour assister cette sélection, ce que nous présentons en section 3.4, avant de conclure dans la section 3.5.

3.1 Facteurs d’adoption

Au préalable d’une migration infonuagique dans une organisation, des motivations incitent des décideurs au sein de cette dernière à adopter l’informatique en nuage. Ces facteurs

d'adoption ont été largement étudiés dans de nombreux contextes. Dans cette section, nous présentons ces travaux en deux temps : d'abord, les travaux qui identifient les facteurs d'adoption de l'informatique en nuage par un individu, puis les facteurs d'adoption pour les organisations. Nous distinguons ces deux catégories car si un individu est dirigé par ses perceptions pour prendre des décisions, une organisation adopte une technologie dans un but stratégique ; cette distinction aboutit à différents facteurs d'adoption.

3.1.1 Adoption de l'informatique en nuage par les individus

Certains travaux se sont concentrés sur l'adoption de l'informatique en nuage par les personnes qui travaillent dans l'informatique, afin de déterminer l'importance de chaque facteur.

Pour cela, l'écrasante majorité de ces travaux étendent le modèle d'acceptation de la technologie (en anglais : *Technology acceptance model*, TAM) développé par DAVIS, BAGOZZI et WARSHAW (1989). Le TAM est une application d'un modèle de psychologie sociale, la théorie de l'action raisonnée de FISHBEIN et AJZEN (1974), qui a pour but d'expliquer le lien entre l'attitude d'un individu (ses croyances, ses intentions) et son comportement. En l'occurrence, le TAM a pour but de prédire et d'expliquer l'acceptation ou le rejet d'une technologie par un individu. À cette fin, le modèle postule que la perception qu'a l'individu de l'utilité et de la facilité d'utilisation de cette technologie sont particulièrement déterminants. Ce modèle est présenté sur la figure 3.1. Les perceptions de l'utilité et de la facilité d'utilisation peuvent être altérées par des variables extérieures, telles que la publicité, et ont de l'influence sur l'attitude de l'individu vis-à-vis de l'utilisation de cette technologie (c'est à dire, ce qu'ils pensent du fait d'utiliser cette technologie et de ceux qui utilisent cette technologie). L'attitude et l'utilité perçues influent sur l'intention qu'a l'individu d'utiliser cette technologie, et cette intention peut mener à une utilisation effective.




FIGURE 3.1 – Modèle d'Acceptation de la Technologie (DAVIS, BAGOZZI et WARSHAW, 1989)

Dans le contexte de l'informatique en nuage, de nombreux travaux concluent à des ex-

tensions du TAM, que ce soit de nouveaux facteurs à considérer ou identifier des variables extérieures.

Sharma et coll. (2016) C'est le cas de SHARMA et coll. (2016) qui ont étudié l'adoption de l'informatique en nuage dans le secteur public au Sultanat d'Oman. Pour cela, ils ont mené une enquête quantitative auprès de personnes en charge de systèmes informatiques dans ce secteur, afin d'évaluer l'influence de cinq facteurs étudiés dans d'autres travaux de recherche menés dans des « *pays développés* » : l'*utilité perçue*, la *facilité d'usage perçue*, la *confiance* (accordée aux fournisseurs de services), le *potentiel d'employabilité*¹ et l'*auto-efficacité*². L'étude conclut que ces cinq facteurs ont une influence positive sur l'adoption de l'informatique en nuage ; le plus important étant le potentiel d'employabilité.

Shahaz et Zahid (2022) De leur côté, SHAHBAZ et ZAHID (2022) ont mené une étude similaire pour le secteur médical afin de déterminer l'influence sur l'utilité et la facilité d'usage perçues des facteurs suivants : la *réduction des coûts*, la *sécurité et confidentialités perçues*, la *compatibilité avec les exigences des organisations*, et le *fait d'être averti des innovations technologiques*³. Leur enquête sous forme d'un questionnaire leur a permis de conclure que ces quatre facteurs ont une influence positive sur les deux facteurs du TAM, c'est-à-dire, par exemple, que d'être averti des innovations technologiques favorise la perception que l'informatique en nuage est utile et facile à utiliser.

Changchit et Chuchen (2018) Enfin, CHANGCHIT et CHUCHUEN (2018) ont étudié l'influence de plusieurs facteurs sur l'intention d'adopter l'informatique en nuage, sans poser de contrainte quant au contexte. Pour ce faire, ils ont mené une étude de la littérature en ce qui concerne l'adoption de l'informatique en nuage dans de nombreux domaines. Ils ont également procédé par l'élaboration et la diffusion d'un questionnaire, qui leur a permis d'établir l'influence positive de ces facteurs, à l'exception de la *rapidité d'accès perçue* qui semble ne pas avoir d'influence significative. Les facteurs qu'ils ont pris en considération sont les facteurs du TAM, à savoir l'*utilité perçue* et la *facilité d'utilisation perçue*, ainsi que la *rapidité d'accès perçue*, la *sécurité perçue* et le *coût d'utilisation perçu*.

1. Le potentiel d'employabilité identifié comme facteur d'adoption par Sharma et coll. est l'ouverture à des offres d'emploi mieux plus nombreux et mieux rémunérées aux informaticiens compétents avec l'informatique en nuage.

2. L'auto-efficacité est la croyance d'un individu en sa capacité à accomplir une tâche ; ici, la confiance que lui donne l'informatique en nuage pour être efficace à son travail.

3. En anglais dans le texte : « *awareness* ».

Il faut noter qu'il ne s'agit là que d'un échantillon d'études. Il existe un très grand nombre d'autres études similaires, qui abordent d'autres contextes et, parfois, d'autres facteurs. Par exemple, nous aurions également pu détailler l'enquête menée par SABI et coll. (2016) quant à l'adoption de l'informatique en nuage dans les systèmes éducatifs, l'étude de la littérature menée par STIENINGER et coll. (2014) ou encore l'enquête menée par C. LOW, Y. CHEN et WU (2011) auprès d'entreprises spécialisées dans les nouvelles technologies. Néanmoins, comme les facteurs d'adoption interviennent avant de considérer la migration infonuagique, nous les présentons ici afin d'expliquer plus largement le processus d'adoption de l'informatique en nuage dans l'industrie. C'est pour cette raison que nous restreignons l'état de l'art à ces quelques travaux que nous jugeons représentatifs de la littérature à ce sujet.

3.1.2 Adoption de l'informatique en nuage par les organisations

D'autres travaux se sont attachés à étudier l'adoption de l'informatique en nuage dans les organisations.

Jamshidi et coll. (2013) Dans une revue systématique des études au sujet des migrations infonuagiques, JAMSHIDI, AHMAD et PAHL (2013) ont, entre autres résultats, mis en lumière six motivations pour migrer un système informatique sur un environnement infonuagique : la *réduction des coûts opérationnels*, la *capacité du système à être mis à l'échelle*, l'*utilisation efficiente des ressources matérielles*, la *maintenabilité*⁴, l'*élasticité dans les périodes d'affluence* et l'*interopérabilité*⁵.

Bremer et coll. (2021) Neuf ans plus tard, BREMER et coll. (2021) mènent à leur tour une revue systématique de la littérature au sujet de la pertinence des méthodes de migration infonuagique pour les petites et moyennes entreprises (PME). Parmi les résultats de leur étude, ils élaborent une liste des facteurs qui influent sur la décision des PME de migrer leur système informatique sur un environnement infonuagique : les *préoccupations de sécurité des données*, la *réduction des coûts*, la *flexibilité vis-à-vis des services infonuagiques*, la *possibilité de se concentrer sur le métier de l'organisation*⁶, la *facilité d'utilisation*, la *dépendance à l'Internet et à la qualité du réseau*, la *transparence du service infonuagique*, la *taille et la structure de l'organisation*, la

4. La maintenabilité caractérise les efforts humains nécessaires à entretenir le bon état de fonctionnement du système informatique : Jamshidi et coll. indiquent que la croyance d'une maintenabilité accrue du système sur un environnement infonuagique, comparé à son hébergement sur site, est un facteur important pour l'adoption.

5. L'interopérabilité désigne, ici, la capacité des composants des environnements infonuagiques à fonctionner ensemble et avec d'autres éléments, notamment les systèmes sur site. Cette caractéristique permet aux organisations de migrer progressivement leurs systèmes et de conserver des parties de leurs systèmes sur site, et semble être un facteur d'adoption important identifié par Jamshidi et coll.

6. En anglais dans le texte : « *focus on the main business* ».

compréhension et connaissance technique de l'informatique en nuage, la *pression compétitive* et la *possibilité d'essayer les services infonuagiques avant l'achat*. Si cette liste comporte des facteurs qui relèvent d'aspects techniques, tels que ceux de Jamshidi et coll., des aspects organisationnels sont également mis en avant, par exemple la *taille et la structure de l'organisation* ou la *pression compétitive*; c'est pourquoi nous supposons qu'avec le temps l'informatique en nuage est davantage perçue comme un avantage compétitif qu'auparavant.

3.1.3 Synthèse

Dans cette section, nous avons passé en revue l'état de l'art au sujet des facteurs d'adoption de l'informatique en nuage. Nombre de travaux reposent sur le modèle d'acceptation de la technologie; ils en montrent la validité et l'étendent avec de nouveaux facteurs propres à l'informatique en nuage. Les facteurs d'adoption recensés dans ces travaux sont rassemblés dans la table 3.1. Il faut noter que les noms des facteurs d'adoption de la première colonne ne sont pas issus textuellement des études. Pour certains, plusieurs études utilisent diverses appellations que nous avons rassemblées. Par exemple, SHARMA et coll. (2016) évoquent la **confiance** (envers le fournisseur de services) tandis que SHAHBAZ et ZAHID (2022) parlent de **confidentialité perçue** et BREMER et coll. (2021), de **transparence du service infonuagique** (vis-à-vis de ses utilisateurs). Ces trois facteurs d'adoption recensés relèvent de la confiance que l'individu ou l'organisation accorde au fournisseur de services. D'où un facteur d'adoption qui les synthétise : « **Confiance accordée au fournisseur de services** ».

Certains travaux étant des revues systématiques de la littérature, il serait peu judicieux de juger l'importance d'un facteur d'adoption au regard de son nombre d'occurrences dans les travaux revus. Cependant, nous pouvons remarquer que certains d'entre eux ont été recensés aussi bien par des études quantitatives que des revues de la littérature. Ces facteurs sont la **facilité d'usage**, la **confiance accordée au fournisseur de services**, la **réduction des coûts**, la **sécurité** et le fait d'être **averti des innovations technologiques**.

Dans le contexte d'une migration d'un système informatique vers un nuage informatique, nous pouvons également souligner que ces facteurs d'adoption de l'informatique en nuage expliquent pourquoi un individu ou une organisation effectuent cette migration, mais ne sont pas des exigences de cette migration. Néanmoins, nous pouvons nous attendre à ce que des exigences de la migration soient liées à ces motivations. Par exemple, il est probable qu'une migration motivée par la réduction des coûts que devrait permettre l'informatique en nuage aie des exigences vis-à-vis des coûts de possession d'un système infonuagique. Une autre hypothèse est que les individus et les organisations motivés par la réduction des coûts perçoivent l'adoption de l'informatique en nuage comme étant, en soi, le moyen de réduire les coûts, peu

Facteur d'adoption	Études
Facilité d'usage (déf. du TAM)	SHARMA et coll. (2016), SHAHBAZ et ZAHID (2022), CHANGCHIT et CHUCHUEN (2018), BREMER et coll. (2021), JAMSHIDI, AHMAD et PAHL (2013)
Utilité (déf. du TAM)	SHARMA et coll. (2016), SHAHBAZ et ZAHID (2022), CHANGCHIT et CHUCHUEN (2018)
Confiance accordée au fournisseur de services	SHARMA et coll. (2016), SHAHBAZ et ZAHID (2022), BREMER et coll. (2021)
Potentiel d'employabilité	SHARMA et coll. (2016)
Auto-efficacité	SHARMA et coll. (2016)
Réduction des coûts	SHAHBAZ et ZAHID (2022), CHANGCHIT et CHUCHUEN (2018), JAMSHIDI, AHMAD et PAHL (2013), BREMER et coll. (2021)
Sécurité	SHAHBAZ et ZAHID (2022), CHANGCHIT et CHUCHUEN (2018), BREMER et coll. (2021)
Être averti des innovations technologiques	SHAHBAZ et ZAHID (2022), BREMER et coll. (2021)
Compatibilité avec les exigences	SHAHBAZ et ZAHID (2022)
Rapidité d'accès	CHANGCHIT et CHUCHUEN (2018)
Capacité de mise à l'échelle	JAMSHIDI, AHMAD et PAHL (2013)
Utilisation efficiente de l'infrastructure	JAMSHIDI, AHMAD et PAHL (2013)
Élasticité	JAMSHIDI, AHMAD et PAHL (2013)
Interopérabilité	JAMSHIDI, AHMAD et PAHL (2013)
Flexibilité	BREMER et coll. (2021)
Concentration sur le métier de l'organisation	BREMER et coll. (2021)
Dépendance à la qualité du réseau	BREMER et coll. (2021)
Taille et structure de l'organisation	BREMER et coll. (2021)
Pression compétitive	BREMER et coll. (2021)
Possibilité d'essai avant l'engagement	BREMER et coll. (2021)

TABLE 3.1 – Facteurs d'adoption recensés dans l'état de l'art

importe les choix de conception pris; auquel cas, aucune exigence ne serait liée à cette motivation (sinon celle d'utiliser un environnement infonuagique). À ce sujet, nous ne pouvons qu'émettre des hypothèses, puisqu'il n'existe, à notre connaissance, pas d'étude des exigences des migrations infonuagiques.

3.2 Stratégies de migration

Une migration infonuagique est un processus visant à changer l'hébergement d'un système informatique pour un environnement infonuagique. Chaque migration diffère des autres car le contexte, les parties prenantes, l'architecture du système diffèrent; néanmoins, des travaux de recherches identifient des stéréotypes de migrations infonuagiques : des *stratégies de migration*. Une stratégie de migration caractérise notamment les choix pris et les tâches réalisées pour une migration donnée. Connaître en amont les stratégies de migration permet à une organisation d'en adopter une qui correspond à sa situation, en comprenant tout à fait les conséquences que cela va avoir. C'est donc une aide pour la conception d'une migration infonuagique.

Dans cette section, nous effectuons une revue des travaux proposant des classifications de stratégies de migration et les comparons entre elles.

3.2.1 Classifications des stratégies de migration

Gartner (2010) En 2010, la société de conseil Gartner a publié un rapport (GARTNER, 2010) dans lequel ils identifient cinq options (surnommées les « 5 R ») qui mêlent deux aspects : les adaptations à apporter au système informatique et les types de services infonuagiques à employer⁷ :

1. « *Re-héberger* » le système informatique sur des *IaaS*, sans lui apporter de modification;
2. « *Réviser* » certains composants du système informatique pour les héberger sur des *PaaS* tandis que le reste demeure sur des *IaaS*;
3. « *Refactoriser* » le système informatique pour l'héberger sur des *PaaS*;
4. « *Reconstruire* » le système informatique pour qu'il tire pleinement parti d'un environnement infonuagique, par exemple en utilisant le plus possible des services sans-serveurs;
5. « *Remplacer* » le système informatique par un *SaaS*. La migration consiste donc en un abandon du système informatique existant et en la migration des données vers le *SaaS*.

7. Ces stratégies sont très connues dans l'industrie par leur dénomination anglaise. Dans le texte et dans le même ordre, les noms des stratégies proposées par GARTNER (2010) sont les suivants : « *Rehost* », « *Revise* », « *Refactor* », « *Rebuild* », « *Replace* ».

Binz et coll. (2011) BINZ, LEYMAN et SCHUMM (2011) distinguent trois stratégies de migration suite à une revue de la littérature. Ces stratégies caractérisent la migration des composants du système informatique et se concentre sur les modifications à apporter au système informatique, sans considération pour l'environnement infonuagique.

La notion de format y est centrale, quoiqu'il s'agisse d'une notion vague. En effet, le format peut, par exemple, désigner le langage de programmation utilisé pour développer les composants du système informatique, le standard utilisé pour les distribuer en tant qu'images de conteneurs ou de machines virtuelles (tel que le format *OVF*⁸), ou les protocoles de communication utilisés (p. ex. *TCP* ou *IP*, *HTTP*, *SOAP*).

Les stratégies qu'ils proposent sont les suivantes⁹ :

1. « *Migration d'un composant avec un format standard* », qui consiste à migrer un composant sans modifier son format. Cela demande d'utiliser un service infonuagique compatible avec ce format ;
2. « *Migration du format d'un composant* », qui consiste à migrer un composant en utilisant un autre format ;
3. « *Migration holistique* », qui consiste à migrer l'intégralité du système informatique, contrairement aux deux autres classes, en migrant chaque composant séparément.

Andrikopoulos et coll. (2013) Quant à ANDRIKOPOULOS et coll. (2013), ils proposent une classification dans laquelle chaque classe indique un degré d'adoption de l'informatique en nuage¹⁰ :

1. « *Remplacer* » un composant du système informatique par un service infonuagique ;
2. « *Migrer partiellement* » les composants du système informatique, en laissant une partie sur l'infrastructure physique ;
3. « *Migrer entièrement le système informatique* » ;
4. « *Nuagifier* » le système informatique, c'est-à-dire le transformer pour qu'il tire partie des possibilités offertes par l'informatique en nuage.

Zhao et Zhou (2014) Suite à une revue des stratégies de migration de la littérature, J. ZHAO et ZHOU (2014) proposent leur propre classification qui combine le type d'adaptation apportée

8. Standard *Open Virtualization Format (OVF)* : <https://www.iso.org/standard/72081.html>.

9. Dans le texte et dans le même ordre, les noms des stratégies proposées par BINZ, LEYMAN et SCHUMM (2011) sont les suivants : « *Standardized Format Migration* », « *Component Format Migration* », « *Holistic Migration* ».

10. Dans le texte et dans le même ordre, les noms des stratégies proposées par ANDRIKOPOULOS et coll. (2013) sont les suivants : « *Replace* », « *Partially migrate* », « *Migrate the whole software stack* », « *Cloudify* ».

au système informatique et les types de services infonuagiques utilisés, de manière analogue à la classification de Gartner ¹¹ :

1. « *Migrer vers un IaaS* », qui consiste à migrer le système informatique sur un environnement infonuagique constitué de *IaaS*;
2. « *Migrer vers un PaaS* », qui consiste à migrer le système informatique sur un environnement infonuagique constitué de *PaaS*;
3. « *Remplacer par un SaaS* », qui consiste à mettre un terme au développement et à la maintenance du système informatique, et à le remplacer par un *SaaS* qui fournit les mêmes fonctionnalités;
4. « *Réviser en utilisant un SaaS* », qui consiste à migrer l'ensemble du système informatique sur un environnement infonuagique et à moderniser certains composants en les remplaçant par des services sans-serveurs;
5. « *Refactoriser en SaaS* », qui consiste à transformer le système informatique pour qu'il devienne un service infonuagique ¹².

Kehrer et Blochinger (2019) KEHRER et BLOCHINGER (2019) ont mené une étude de la littérature sur la migration d'applications qui exigent de hautes performances de calcul. Dans ce contexte, l'environnement doit être sélectionné avec précaution pour satisfaire les exigences quant à la performance. À ce sujet, les auteurs identifient des environnements *standards*, qui comportent divers inconvénients tels que des temps de calcul variables liés au partage du CPU des machines virtuelles. Ils les opposent aux environnements spécialisés pour la haute performance de calcul, qui sont plus coûteux mais qui présentent également plusieurs caractéristiques permettant d'assurer une vitesse de calcul constante et élevée.

Cette étude de la littérature a mis en évidence trois stratégies de migration ¹³ :

1. « *Copier/Coller* » qui consiste à ne pas modifier l'application pour la migration. Les applications migrées de cette manière peuvent souffrir de la bande passante du réseau trop restreinte et la haute latence du réseau dans les environnements standards, ce qui n'a pas été constaté dans les environnements spécialisés pour la haute performance de calcul;

11. Dans le texte et dans le même ordre, les noms des stratégies proposées par J. ZHAO et ZHOU (2014) sont les suivants : « *Migrate to IaaS* », « *Migrate to PaaS* », « *Replace by SaaS* », « *Revise based on SaaS* », « *Reengineer to SaaS* ».

12. Transformer un système informatique pour qu'il devienne un service infonuagique requiert d'identifier les fonctionnalités du système à fournir en tant que service, et d'assurer pour ces services qu'ils possèdent les caractéristiques présentées dans la sous-section 2.1.3.

13. Dans le texte et dans le même ordre, les noms des stratégies proposées par KEHRER et BLOCHINGER (2019) sont les suivants : « *Copy & Paste* », « *Cloud-aware Refactoring* », « *Cloud-aware Refactoring & Elasticity Control* ».

2. « *Refactoriser pour l'informatique en nuage* » qui consiste à adapter l'application pour qu'elle aie conscience de l'environnement infonuagique qui l'exécute. Les auteurs relèvent que cette stratégie a été utilisée exclusivement avec des environnements standards afin de limiter les pertes de performances liées à l'hétérogénéité des ressources et la latence du réseau. Cependant, elle ne peut pas toujours être appliquée, par exemple dans le cas d'applications avec de nombreuses communications et synchronisations dont les performances souffriraient d'une refactorisation ;
3. « *Refactoriser pour l'informatique en nuage et mise en oeuvre de l'élasticité* » qui, au contraire des stratégies précédentes, tire profit de l'élasticité de l'informatique en nuage. Cela demande une refactorisation de l'application pour qu'elle tienne compte d'un nombre variable d'unités de calcul. Cette stratégie permet de minimiser le coût de l'environnement et le temps de calcul.

3.2.2 Synthèse

Dans cette section, nous avons revu les classifications de stratégies de migration proposées dans la littérature. Ces classifications distinguent les migrations par le type d'adaptation apportées au système informatique, le type de services infonuagiques qui seront utilisés pour déployer l'environnement infonuagique et le degré d'adoption de l'informatique en nuage. Nous notons aussi qu'une stratégie de migration concerne parfois un seul composant du système informatique, et parfois le système dans son intégralité.

Par ailleurs, les classes de certaines classifications désignent la même situation. Ces correspondances sont présentées dans la table 3.2. Nous pouvons émettre plusieurs remarques quant à ce comparatif. D'abord, toutes les classifications envisagent la possibilité de retravailler le système informatique pour en faire un système nativement infonuagique (en anglais : « *cloud native* »). Les principaux bénéfices évoqués sont des coûts moindres et la possibilité de tirer un plus grand bénéfice de l'élasticité, ce qui mène à la conception de systèmes capables de traiter un trafic variable dans le temps avec des performances stables. À l'opposé, la possibilité de remplacer le système informatique par un service infonuagique n'est pas évoqué dans deux travaux de recherche : dans le cas de Binz et coll., cela peut s'expliquer par la précocité de ces travaux, à une époque où l'informatique en nuage était bien moins diversifié qu'il ne l'est aujourd'hui. Dans le cas de Kehrer et Blochinger, c'est sans doute dû au cadre de leur étude, les applications exigeant des hautes performances de calcul : elles sont davantage conçues pour répondre aux besoins spécifiques d'une organisation, ce qui exclut l'utilisation d'un *SaaS*, qui se veut suffisamment générique pour répondre aux besoins d'un grand nombre d'organisation. Enfin, les autres stratégies sont présentes dans tous les travaux exceptés dans la classification d'Andriko-

#	Résumé de la stratégie	GARTNER (2010) BINZ, LEYMAN et SCHUMM (2011) ANDRIKOPOULOS et coll. (2013) J. ZHAO et ZHOU (2014) KEHRER et BLOCHINGER (2019)				
1	Migration vers un <i>IaaS</i> , peu ou pas d'adaptations	1	1	-	1	1
2	Migration vers un <i>PaaS</i> , peu d'adaptations	2	1	-	2	2
3	Migration vers un <i>PaaS</i> , nombreuses adaptations	3	2	-	4	2
4	Transformation en système nativement infonuagique	4	2, 3	4	5	3
5	Remplacement par un <i>SaaS</i>	5	-	1	3	-

TABLE 3.2 – Correspondances entre les classes de stratégies de migration (les chiffres sont les indices des stratégies dans leurs listes respectives)

poulos et coll.. En effet, ces derniers se concentrent sur le degré d'adoption de l'informatique en nuage (migration partielle ou complète) tandis que les stratégies restantes mêlent effort d'adaptation et type de services utilisés pour migrer un composant du système informatique. D'une part, la stratégie n°1 est une migration sans adaptation vers un *IaaS* : la limite de la sélection est la compatibilité du composant avec un système d'exploitation. D'autre part, les stratégies n°2 et 3 sont des migrations vers un *PaaS* avec différents efforts d'adaptation : si la stratégie n°2 est une migration opportuniste, bénéficiant d'un *PaaS* compatible avec le composant avec peu d'effort à fournir, la stratégie n°3, elle, implique des modifications importantes.

Pour finir, si certains de ces travaux ont rapporté les conséquences de la stratégie employée sur la migration, l'étendue de ces conséquences n'est pas suffisamment documentée. En outre, il n'existe pas à notre connaissance de méthode pour déterminer la stratégie qu'il convient d'employer pour une nouvelle migration infonuagique. C'est ce que rapporte J. ZHAO et ZHOU (2014) :

« Une méthodologie holistique de migration de systèmes d'information vers l'informatique en nuage est nécessaire. [...] les avantages et les risques qui accompagnent une migration doivent être présentés aux organisations [qui migrent leur système informatique]. Sur la base de ces informations, les organisations pourront faire le choix

d'une stratégie de migration. » ¹⁴

Malgré l'absence d'une méthode de sélection de la stratégie de migration, de nombreux travaux de recherche ont abouti à diverses méthodologies de migration pour les implémenter. Nous les présentons dans la section suivante.

3.3 Méthodologies de migration

Dans cette section, nous passons en revue des travaux au sujet des processus de migration.

Puisque l'informatique en nuage est composée de services, une première piste est la migration de l'architecture des systèmes d'information vers une architecture orientée services (en anglais : *Service-Oriented Architecture*, *SOA*). Cependant, cela ferait abstraction du support qui exécute les logiciels de telles architectures, or cela est important dans l'informatique en nuage car tous les services infonuagiques ne peuvent pas exécuter n'importe quel logiciel.

Pour prendre en compte cette spécificité, de nombreuses méthodologies adaptées à l'informatique en nuage ont été mises au point dès les débuts de ce paradigme afin de migrer un système « hérité » ¹⁵ vers un nuage informatique. Étant donné le très grand nombre de ces méthodologies, nous passerons en revue trois travaux notables qui en proposent une (W. ZHANG et coll., 2009 ; FREY et HASSELBRING, 2010 ; GUNKA, SEYCEK et KÜHN, 2013), avant de présenter une revue de la littérature qui en a, elle, analysé quarante-trois (FAHMIDEH, DANESHGAR, G. LOW et coll., 2016). Enfin, nous présenterons un cadre permettant de prendre du recul sur ces approches, puisqu'il permet de modéliser des processus de migration infonuagique (FAHMIDEH, GRUNDY et coll., 2022).

3.3.1 Description des travaux

Razavian et Lago (2015) RAZAVIAN et LAGO (2015) ont mené une étude systématique de la littérature sur les approches de migration des architectures vers la *SOA* afin de déterminer les activités que cela inclue, dans quel ordre ces activités sont menées et les connaissances nécessaires (p. ex. documentation) pour les réaliser.

Cette étude ne se concentre pas en particulier l'informatique en nuage, les approches revues ne tiennent donc pas nécessairement compte des spécificités de ce paradigme ou même

14. Dans le texte : « *A holistic methodology of migrating legacy systems to the cloud is needed. [...] the advantages and risks accompanying the migration should be advertised. Based on the information, organizations can make decision to migration strategy.* »

15. Un système hérité (en anglais : « *legacy* ») est maintenu depuis longtemps par une organisation. Cette dénomination sous-entend certains stéréotypes liés à cette longévité, par exemple une documentation mal entretenue ou une qualité du code source inégale entre les modules du système.

de l'hébergement du système informatique. Néanmoins, la transformation d'une architecture logicielle en architecture orientée services est une étape fréquemment évoquée dans les méthodes de migration infonuagique, en particulier quand l'objectif de la migration est de créer un nouveau service infonuagique.

Zhang et coll. (2009) W. ZHANG et coll. (2009) ont développé une méthode pour migrer un système monolithique hérité en un *SaaS*, analogue à la méthode en « *fer à cheval* » de KAZMAN, WOODS et CARRIÈRE (1998).

La méthode en « *fer à cheval* » permet de faire évoluer l'architecture d'un système logiciel même s'il n'a pas été documenté au long de son développement. Cela s'effectue en une succession de trois processus que nous pouvons résumer ainsi : constitution d'une représentation de l'architecture du système en partant du code source, puis transformation de cette architecture en une architecture *cible*, et enfin instanciation de l'architecture cible.

Zhang et coll. étendent cette méthode à l'informatique en nuage : le modèle de l'architecture cible peut servir à générer le code source de services Web qui appellent les fonctionnalités du système informatique à migrer. Une fois le code généré, l'environnement infonuagique est sélectionné conformément aux exigences du système et les services Web sont déployés sur cet environnement.

CloudMIG FREY et HASSELBRING (2010) proposent une méthode de migration, CloudMIG, qui consiste pour l'essentiel en la sélection d'un environnement infonuagique capable d'exécuter le système logiciel. Cette méthode est une succession de six activités résumées ci-suit :

1. *Extraction* de l'architecture initiale du système logiciel à migrer et d'un modèle de consommation des ressources ;
2. *Sélection* d'un environnement infonuagique et instanciation de cet environnement dans un métamodèle d'environnement infonuagique qui fait partie de CloudMIG ;
3. *Génération* de trois artefacts : une architecture cible pour le système logiciel, un modèle d'association entre les composants de l'architecture initiale et ceux de l'architecture cible, et un modèle qui caractérise les violations de contraintes imposées par l'environnement infonuagique. Ces éléments peuvent être générés semi-automatiquement par transformation des modèles de l'architecture initiale et de l'environnement infonuagique. En outre, les auteurs proposent un algorithme basé sur des heuristiques pour construire l'architecture cible en optimisant l'affectation des composants de l'architecture initiale ;

4. *Adaptation* manuelle de l'architecture cible générée pour la rendre conforme à des exigences qui n'ont pas été prises en compte lors de l'activité précédente ;
5. *Évaluation* des modèles produits lors des deux activités précédentes afin d'assurer qu'ils satisfont les exigences de la migration. Le processus prévoit de revenir aux étapes précédentes en cas d'insatisfaction ;
6. *Transformation*, ou migration effective du système logiciel vers un environnement infonuagique.

Notons que la notion d'exigences qui apparaît dans ces activités n'est pas détaillée : elles sont supposées connues avant la migration et leur nature n'est pas discutée dans ce travail.

Au sujet des violations de contraintes détectées lors de l'étape de *Génération*, FREY, HASSELBRING et SCHNOOR (2013) expliquent que tous les environnements infonuagiques ne sont pas également adéquats pour un système logiciel. Cela est dû à des contraintes inhérentes à cet environnement infonuagique. Par exemple, certains ports de communication peuvent être interdits ou un des services infonuagiques utilisés ne supporte qu'un nombre limité de langages de programmation. En outre, ces contraintes se voient associées à un niveau de sévérité, correspondant à l'effort requis pour régler la violation de cette contrainte lors de la migration. La détection de ces violations peut être automatisée grâce à une analyse statique des modèles de l'architecture cible et de l'environnement infonuagique. Cette analyse permet d'attribuer un niveau de compatibilité de l'architecture cible à l'environnement infonuagique que FREY et HASSELBRING (2011) étalent sur cinq niveaux : *incompatible avec l'environnement* (il existe au moins une violation de contrainte de niveau *rupture*), *compatible avec l'environnement* (pas de violation de contrainte de niveau *rupture*), *prêt à être déployé sur l'environnement* (pas de violation de contrainte), *aligné avec l'environnement* (la migration diminue la consommation des ressources), *optimisé pour l'environnement* (le système infonuagique est élastique et tire profit de l'élasticité).

Gunka et coll. (2013) GUNKA, SEYCEK et KÜHN (2013) proposent une méthodologie de migration vers un environnement multinuage dans le cadre du projet MODAClouds. Ils prônent une approche qu'ils qualifient d'« *évolutionnaire* », une migration en trois étapes qui aboutissent chacune à un système infonuagique utilisable : le système est migré dès la première étape et est modernisé ensuite.

La première étape est de migrer l'ensemble du système logiciel sur un *IaaS*, en commençant par collecter les caractéristiques de l'infrastructure sur site, puis sélectionner un *IaaS* qui présente ces caractéristiques. Cette sélection peut être simplifiée grâce aux outils intégrés à l'environnement de développement du projet MODAClouds. La seconde étape introduit l'équi-

librage de charge. Il s'agit, en effet, du moyen privilégié dans l'informatique en nuage pour mettre le système à l'échelle. Cependant, il s'accompagne de contraintes ; en particulier, équilibrer la charge entre composants qui gardent un état (p. ex. une session) introduit un risque d'incohérence (p. ex. un utilisateur devant s'authentifier sur chaque instance du composant qui garde une session). L'introduction de l'équilibrage de charge requiert donc une première adaptation des logiciels du système informatique. Finalement, la troisième étape modernise le système en migrant les composants sur des *PaaS*, ce qui requiert à nouveau des adaptations pour que chaque composant satisfasse les contraintes imposées par les services infonuagiques ciblés.

Cette approche de la migration est encouragée par Amazon Web Services dans son programme d'accélération des migrations ¹⁶ ; en effet, elle permet au fournisseur de services d'acquiescer immédiatement un nouvel usager sans que cela ne change drastiquement les pratiques industrielles de ce dernier.

Fahmideh et coll. (2016) FAHMIDEH, DANESHGAR, G. LOW et coll. (2016) ont procédé à une étude de la littérature des méthodes pour migrer un système logiciel vers un nuage afin de déterminer les approches mises en oeuvre dans ces méthodologies et les critères qui sont attendus de ces méthodologies.

Leur étude s'est portée sur quarante-trois publications à ce sujet, qui présentent autant d'approches différentes de la migration infonuagique. Une étude préliminaire de la littérature leur a permis de construire un cadre d'évaluation des méthodologies. Ce cadre compte onze critères génériques pour le génie logiciel (p. ex. « *Clarté du processus* », « *Langage de modélisation* », « *Traçabilité* ») et dix-sept critères spécifiques à l'informatique en nuage (p. ex. « *Compréhension du système hérité* », « *Résolution des incompatibilités* », « *Sélection du service infonuagique ou de la plateforme* »). Ces critères ont été identifiés dans la littérature et correspondent aux attentes de divers auteurs quant aux qualités d'une méthodologie de migration infonuagique.

Cette étude a produit de nombreux résultats. D'une part, l'étude a montré que, si la majorité des approches ne reposent pas sur des fondements théoriques particuliers, l'ingénierie dirigée par les modèles est prépondérante dans les autres approches. D'autre part, l'analyse des travaux au regard des vingt-huit critères identifiés a abouti à plusieurs remarques d'intérêt, dont nous n'abordons que quelques points ci-après. D'abord, si une méthodologie de développement se doit d'être adaptée à la situation (ici, à un scénario de migration), il s'avère que la quasi-totalité des approches étudiées se présentent comme des solutions universelles, adaptées à chaque scénario de migration. Aucune approche ne donne de guide pour construire

16. Recommandations de AWS pour la migration : <https://aws.amazon.com/fr/cloud-migration/how-to-migrate/>.

une méthode adaptée à une migration en particulier. En outre, une seule étude présente les rôles qui interviennent dans la migration et les activités qu'ils réalisent : il s'agit des travaux de CHAUHAN et BABAR (2012) qui identifient les analystes du système et du métier, les responsables de projet, les architectes du système et les développeurs comme étant partie prenante de la migration. Ces rôles sont empruntés au développement logiciel et n'incluent pas de rôle spécifique à l'informatique en nuage (FAHMIDEH, DANESHGAR et RABHI, 2016). De plus, plus de la moitié des études n'envisage pas d'activité d'analyse du contexte précédant la migration (p. ex. les équipes de développement et de maintenance, les utilisateurs du système) et seulement un tiers considèrent une activité d'élicitation et d'analyse des exigences. Enfin, les principaux critères de sélection de l'environnement identifiés dans ces études sont les suivants : la *variété de modèles de services fournis* (pour choisir un fournisseur de services), le *modèle de coût*, le *contrat de niveau de service*, l'*existence de services additionnels*, l'*observabilité*, la *mise à l'échelle automatique*, les *mécanismes de sécurité*, les *technologies compatibles avec le fournisseur de services*, les *plateformes de développement disponibles*, l'*accès à la journalisation*, les *localisations des centres informations*, la *durabilité* (dans le même sens que dans « développement durable »), la *durée d'engagement avec le fournisseur de services*, les *objectifs métier*, le *degré d'automatisation*, les *mécanisme de chiffrement pour les données stockées*, l'*existence de kits de développement*, l'*effort requis pour la configuration de l'environnement*, la *vitesse de déploiement*, l'*expérience de développement* et la *bande passante du réseau*.

MLSAC, Fahmideh et coll. (2022) Suite à leur étude de 2016, FAHMIDEH, GRUNDY et coll. (2022) ont mis au point MLSAC, un cadre pour créer, maintenir et partager des méthodes de migration infonuagique adapté à chaque scénario de migration.

MLSAC comprend un métamodèle des concepts mobilisés lors d'une migration, organisés en trois phases (FAHMIDEH, DANESHGAR, RABHI et BEYDOUN, 2019). La première phase, de *planification*, implique l'étude de faisabilité de la migration, l'élicitation, l'analyse des exigences fonctionnelles et non fonctionnelles du système et la préparation des activités de la migration du système. Lors de la seconde phase, de *conception*, les parties prenantes conçoivent l'environnement infonuagique et modélisent comment les composants à migrer seront hébergés sur cet environnement. Enfin, la troisième phase est dite d'*activation* : il s'agit de la migration effective du système.

Ce métamodèle peut être instancié en suivant un ensemble de règles, qui est un autre composant de MLSAC. Le modèle qui en résulte représente un processus de migration avec notamment les tâches que les équipes de développement doivent réaliser et les artefacts qu'ils doivent générer.

3.3.2 Synthèse

Dans cette section, nous avons passé en revue les travaux traitant de méthodologies de migration infonuagique. Nous avons vu qu'en la matière les alternatives sont nombreuses, et qu'il est possible de les modéliser.

Une question demeure : comment choisir ou construire une méthodologie de migration adaptée à un scénario de migration ? La plupart des travaux de recherche proposant une méthodologie n'abordent pas cette question : ils ne discutent, en effet, pas des conditions d'application, des scénarios ou stratégies de migration auxquelles la méthodologie est adaptée. En outre, si une majorité de méthodologies proposées n'abordent pas l'élicitation et l'analyse des exigences de la migration, toute contient une étape de sélection de l'environnement infonuagique.

3.4 Sélection d'un environnement infonuagique

Lors de la conception d'un système infonuagique, il convient de judicieusement sélectionner l'environnement, c'est-à-dire choisir les fournisseurs de services, les services infonuagiques et la configuration de ces services afin de satisfaire les exigences du système. Or, cette sélection peut être une activité ardue, car les combinaisons sont très nombreuses et il n'est pas aisé d'évaluer la satisfaction de certaines exigences. Dans la littérature, il existe de nombreux travaux qui abordent le problème de la sélection de l'environnement sous différents angles, en particulier en le formulant comme un problème d'optimisation ou en s'appuyant sur des modèles tels que des ontologies.

3.4.1 Modélisation comme un problème d'optimisation

Une large partie des travaux qui traitent de la sélection d'un environnement infonuagique l'abordent comme un problème d'optimisation. Selon le ou les exigences prises en compte dans chaque étude, il s'agira de minimiser ou maximiser une ou plusieurs fonctions objectif sur l'ensemble des sélections possibles de l'environnement.

Maximisation de la qualité de service

Nombre de ces travaux cherchent à maximiser la qualité de service. Il s'agit d'un problème multiobjectif, puisque les aspects couverts par la qualité de service sont nombreux : par exemple, minimiser la latence de réponse, maximiser la disponibilité du service ou le nombre de requêtes auxquelles le système peut répondre simultanément.

Hayyolalam et Kazem (2018) HAYYOLALAM et KAZEM (2018) ont effectué une revue des travaux sur la sélection d'environnements infonuagiques qui maximisent la qualité de service. Dans les cinquante travaux qu'ils ont analysés, ils ont constaté que la plupart d'entre eux abordent ce problème multiobjectif en combinant les fonctions objectif en une seule. Finalement, très peu traitent le problème en distinguant les fonctions d'objectif, ce qui permettrait d'identifier clairement les répercussions de l'optimisation d'un critère sur les autres. En outre, la majorité des études abordent la sélection d'environnements multinuagiques, mais les auteurs ne relèvent pas de particularité liée à la multiplication des nuages qui constituent un environnement. Par exemple, nous pourrions supposer qu'effectuer un transfert du réseau interne d'un nuage à celui d'un autre causerait une dégradation de la qualité de service suffisante pour être considérée dans ces études. Enfin, ces études reposent sur des ensembles de données tels que *QWS (Quality of Web Service)*, construit par AL-MASRI et MAHMOUD (2007) en effectuant des mesures sur les services infonuagiques.

Liu et coll. (2019) LIU et coll. (2019) s'intéressent à la sélection de types de machines virtuelles dans un environnement multinuage. Ils cherchent à minimiser le coût de l'environnement et la latence du réseau, et à maximiser la capacité de calcul, c'est-à-dire le nombre d'opérations calculable par unité de temps. Après avoir modélisé ce problème comme un problème d'optimisation multiobjectif qu'ils résolvent à l'aide d'un algorithme génétique.

Ramamurthy et coll. (2020) Outre la diversité des critères à optimiser, il existe aussi des contraintes à prendre en compte. Une de ces contraintes vient des lois qui régulent la localisation des données. Un exemple en Union Européenne est le règlement général sur la protection des données (*RGPD*) qui impose des restrictions quant à la localisation et aux traitements qu'il est possible de faire aux données personnelles de résidents de l'Union Européenne. Afin de tenir compte de ce genre de contraintes, RAMAMURTHY et coll. (2020) ont développé une méthodologie qu'ils qualifient d'holistique pour la sélection d'environnements multinuages basés sur des *IaaS*. Celle-ci est composée de quatre étapes : (i) sélection des machines virtuelles, (ii) sélection des centres informatiques, (iii) classement des fournisseurs de services et (iv) sélection des fournisseurs de services. Le problème de sélection des machines virtuelles a été modélisé en un problème d'optimisation linéaire en nombre entiers dans lequel il faut minimiser le coût total de l'environnement tout en satisfaisant des contraintes de minimum de mémoire vive des machines virtuelles et d'espace disque. Quant à la sélection des centres informatiques, le choix doit respecter les lois de régulation des données ainsi que des exigences de latence du réseau ; pour y parvenir, les auteurs décrivent un algorithme permettant de sélectionner le centre informatique le moins coûteux qui satisfait à la fois ces lois et le maximum de latence admissible.

Finalement, pour le classement et la sélection des fournisseurs infonuagiques, des tuples d'un ou plusieurs fournisseurs de services candidats sont générés et évalués sous trois prismes : la sécurité, l'utilisabilité et la facilité de gestion ; ces trois critères sont évalués individuellement pour chaque fournisseur de service et une règle permet de les combiner pour affecter un score par tuple. L'environnement sélectionné est celui qui est déployé par le tuple avec le score le plus haut.

Maximisation des *SLA*

Évaluer la satisfaction des exigences en prenant des mesures sur un environnement infonuagique présente des limites, comme le soulignent GESVINDR, BUHNOVA et GASIOR (2017). Parmi ces limites, nous pouvons citer l'importance des coûts engendrés par les environnements pour les évaluations, qui limitent drastiquement le nombre d'évaluations envisageables. Une autre limite considérable est la non-répétabilité des mesures, car la qualité de service dépend de l'état du centre informatique et des composants d'infrastructure alloués à l'environnement, et cela peut changer continuellement. Par exemple, l'infrastructure du nuage peut être très hétérogène, et il n'y a pas de garantie que l'environnement infonuagique utilise à chaque instant le même matériel dans cette infrastructure. De même, les composants de l'infrastructure peuvent être renouvelés.

Afin de contourner ces limites, certains travaux se sont concentrés sur les engagements du fournisseur de services en ce qui concerne la qualité de service. Les fournisseurs de services s'engagent, en effet, à respecter un *accord de niveau de service* (en anglais, *Service-Level Agreement*, *SLA*). Cet accord indique les objectifs du fournisseurs de services à propos de divers indicateurs. Par exemple, le service de stockage de document Google Cloud Storage assure divers minimum de disponibilité selon la configuration du stockage, tel que 99.9% de disponibilité mensuelle pour la classe de stockage *Standard* dans une région (ce qui permet un dénis de service de 43 minutes et 50 secondes chaque mois)¹⁷. En cas de non-conformité du fournisseur de services à son *SLA*, il s'engage à verser des contreparties.

Comme les *SLA* assurent un minimum de qualité de service, des études ont pris le parti de maximiser les *SLA* des services utilisés pour déployer l'environnement.

Zhao et coll. (2015) Z. ZHAO, JIANG et X. ZHAO (2015) ont développé une méthode pour sélectionner un service infonuagique qui satisfasse au mieux les attentes en matière de *SLA*. Cette méthode est composée de deux étapes. D'abord il faut calculer les optimums de Pareto sur les critères de qualité de service retenus par les auteurs et en se basant sur les *SLA*. Néanmoins,

17. *SLA* de Google Cloud Storage : <https://cloud.google.com/storage/sla>.

Zhao et coll. considèrent que ce calcul seul est vague car les optimums de Pareto ne sont pas comparables entre eux. Ils proposent donc de les discriminer en appliquant *PROMETHEE*, une méthode d'aide à la décision multiobjectif développé par BRANS, VINCKE et MARESCHAL (1986), qui permet d'évaluer à quel degré un candidat est meilleur qu'un autre, ici en matière de qualité de service. Dans la seconde étape, il faut sélectionner le meilleur service candidat. Pour cela, les auteurs proposent un algorithme qui admet pour entrée les optimums de Pareto associés à leur rang calculé avec *PROMETHEE*.

HS4MC, Farokhi et coll. (2014) Alors que la méthode de Zhao et coll. place tous les *SLA* sur un pied d'égalité, la pratique montre que certains *SLA* sont plus importants que d'autres, cela dépend de l'utilisateur. Par exemple, il peut être requis d'avoir un certain minimum pour tel *SLA*, mais toute augmentation supérieure à ce minimum est sans importance. En outre, il est possible que des exigences de *SLA* soient incompatibles, étant donné le catalogue de services disponibles. FAROKHI et coll. (2014) ont identifié ces problématiques et proposent une méthode, nommée *HS4MC* (*Hierarchical SLA-based service selection for multi-cloud environments*, pour la sélection d'environnements multinuages qui maximise les *SLA*. Elle est aussi composée de deux étapes. La première étape consiste à analyser le *SLA* du service que veut fournir l'utilisateur. Ces *SLA* sont agnostiques de tout fournisseur infonuagique et il en existe deux types. En effet, à l'issue de cette étape, l'utilisateur aura identifié un *méta-SLA*, qui concerne le système dans son ensemble, et un *sous-SLA* par composant de l'environnement infonuagique. L'environnement est sélectionné dans la seconde étape à l'aide d'un algorithme. Celui-ci admet, en entrée, le catalogue des services disponibles ainsi que le *méta-SLA* et les *sous-SLA* calculés lors de la première étape. Il calcule la sélection de l'environnement qui satisfait le mieux les *SLA*.

3.4.2 Autres modélisations

Bien que le problème de sélection d'un environnement infonuagique soit modélisé comme un problème d'optimisation dans beaucoup de travaux, d'autres modélisations sont proposées dans les travaux présentés dans cette sous-section.

Projet MODAClouds Le projet européen MODAClouds (ARDAGNA et coll., 2012) avait pour objectif de développer une approche basée sur l'ingénierie dirigée par les modèles (*IDM*) pour le développement et la maintenance opérationnelle de systèmes d'information hébergés sur des environnements multinuages. Cette approche assiste les parties prenantes à plusieurs phases du cycle de vie du système infonuagique (NITTO et coll., 2013).

Lors de la conception avec cette approche, les composants du système informatique sont d'abord modélisés dans un modèle indépendant de l'informatique en nuage. Cette modélisation

mobilise les composants classiques pour les systèmes constitués de services (p. ex. services, compositions de services, parties prenantes), et inclut diverses contraintes et exigences non fonctionnelles (p. ex. un minimum de disponibilité pour les données). Puis, ce modèle est traduit dans un modèle conscient de l'informatique en nuage mais agnostique de tout nuage. Ce second modèle comporte les concepts relatifs aux *IaaS*, *PaaS* et *SaaS*. Enfin, ce modèle est traduit en un modèle spécifique à un ensemble de fournisseurs de services, qui comporte les détails pour la configuration de l'environnement.

Les traductions d'un modèle à l'autre sont partiellement automatisées grâce à un outillage intégré à l'environnement de développement. Cet outillage comprend notamment un cadriciel, nommé « *Cloud Modelling Framework* » (FERRY, SONG et coll., 2014). Ce cadriciel a deux composants. D'une part, un langage spécifique au domaine, nommé *Cloud Modelling Language*, pour permettre à un développeur d'exprimer les deux modèles conscients de l'informatique en nuage (FERRY, ROSSINI et coll., 2013). D'autre part, un environnement *model@runtime* qui traque les évolutions du modèle spécifique à un ensemble de fournisseur de services afin de mettre à jour la configuration des services infonuagiques : l'environnement infonuagique est donc toujours conforme à ce modèle.

CloudRecommender, Zhang et coll. (2012) Zhang et coll. qui ont développé *CoCoOn*, une ontologie des services infonuagiques qui, dès la publication de leurs premiers travaux en 2012 et jusqu'à la dernière version en date, en 2019, modélise les services d'infrastructure à la demande, leurs tarifs et leurs performances (M. ZHANG et coll., 2012; Q. ZHANG, HALLER et Q. WANG, 2019). À l'aide de *CoCoOn*, ils ont développé *CloudRecommender*, un système de recommandation pour les environnements basés sur des *IaaS*. En entrée de *CloudRecommender*, le concepteur de l'environnement décrit les composants de son infrastructure (p. ex. les machines virtuelles, les disques) ainsi que des données liées à diverses exigences (p. ex. la taille des disques, la mémoire vive des machines, la volumétrie de données entrant et sortant du réseau). En retour, *CloudRecommender* parcourt *CoCoOn* pour déterminer la sélection de l'environnement qui minimise son coût.

COCA-PT, Belli et coll. (2016) Si *CloudRecommender* permet effectivement de minimiser le coût d'allocation de ressources déployées par des *IaaS*, il n'est pas simple de fournir les informations qui lui sont nécessaires. En effet, les métriques telles que la volumétrie de données qui parcourt le réseau sont le fruit des interactions des clients du système informatique avec l'environnement, et requièrent par conséquent une analyse du métier du système informatique. Pour contourner cette limite, BELLI, LOOMIS et ABDENNADHER (2016) ont développé *COCA-PT*. Il s'agit d'un outil de recommandation pour sélectionner un environnement basé sur des *IaaS*

à coût minimal. Pour ce faire, *COCA-PT* requiert deux éléments. D'une part, il lui faut les tarifs des *IaaS*. Cependant, il n'existe pas de standard partagé par les fournisseurs de services pour exprimer les tarifs de leurs services infonuagiques, c'est pourquoi les auteurs proposent un schéma, agnostique, permettant de normaliser les tarifs collectés. D'autre part, il lui faut le contexte d'utilisation du système informatique, que les auteurs formalisent en un modèle de consommation des ressources (*MCR*) qui comprend, notamment, les éléments d'infrastructure mobilisés dans l'environnement, leur temps d'allocation, ainsi que la taille et la fréquence des requêtes entrant dans le système et leurs réponses. Pour ce faire, les auteurs ont développé un composant de *COCA-PT*, nommé *SlipStream*, qui surveille un environnement infonuagique pour construire le *MCR*. Grâce aux tarifs et au *MCR*, *COCA-PT* évalue le coût d'environnements similaires déployés par divers fournisseurs de services, afin de sélectionner le moins coûteux.

SALOON, Quinton (2014) L'ensemble des travaux évoqués ci-avant se concentrent sur les *IaaS*. Cependant, intégrer des *PaaS* dans un environnement infonuagique peut être bénéfique, par exemple pour diminuer les efforts de maintenance. Au cours de son doctorat, [QUINTON \(2014\)](#) a automatisé la sélection et le déploiement d'environnements comportant aussi bien des *IaaS* que des *PaaS*. Pour cela, il a développé *SALOON*, un outil basé sur les lignes de produits logiciels. [NORTHROP \(2002\)](#) définit une ligne de produits logiciels comme « *un ensemble de systèmes logiciels qui partagent des caractéristiques communes satisfaisant les besoins spécifiques d'un domaine et qui sont développés à partir d'un ensemble commun de composants selon une méthode prescrite* ». Ces caractéristiques (en anglais : *features*) peuvent être communes à tous les systèmes de la ligne de produits logiciels ou être une variation présente dans certains d'entre eux. Les *feature models* permettent d'identifier ces points communs et de variation sur l'ensemble de la ligne de produits logiciels, ainsi que les incompatibilités entre caractéristiques. Dans *SALOON*, deux types d'acteurs interviennent pour la sélection de l'environnement. D'une part, des *architectes du domaine*, chacun expert d'un nuage, dont ils modélisent les caractéristiques dans un *feature model*. Puis, les architectes du domaine rassemblent leurs connaissances pour créer un modèle de connaissances des nuages, qui rassemble toutes les caractéristiques utilisées dans les *features models*. D'autre part, un *développeur* d'un système informatique, qui est l'utilisateur final de *SALOON*, sélectionne dans le modèle de connaissance les caractéristiques requises pour héberger le système informatique. Par exemple, le développeur peut indiquer qu'un logiciel du système informatique requiert un serveur d'application Tomcat. Enfin, *SALOON* sélectionne un environnement en cherchant les *feature models* qui présentent les caractéristiques requises, analyse les environnements retenus (évaluer leurs coûts, par exemple), et génère un script pour automatiser son déploiement.

3.4.3 Synthèse

Dans cette section, nous avons passé en revue l'état de l'art des travaux sur la sélection des environnements infonuagiques. Nous avons vu qu'ils se concentrent essentiellement sur la **qualité de service**, que ce soit en effectuant des mesures ou en se basant sur les *SLA*, et les **coûts de l'environnement**. Certains critères tels que le **respect des politiques de régulation des données** sont abordés ponctuellement.

Deux remarques s'imposent :

- Une très large partie de ces travaux se concentrent sur les *IaaS*. C'est une limite aujourd'hui, car l'industrie s'oriente de plus en plus vers les *PaaS* pour diminuer les efforts de maintenance en condition opérationnelle.
- Les travaux revus considèrent uniquement un sous-ensemble de critères de sélection. Or, les organisations ont diverses préoccupations et contraintes qui doivent être prises en compte simultanément. Par exemple, une petite organisation avec peu de moyens financiers peut être particulièrement attentive aux coûts de l'environnement, sans pour autant négliger la qualité de service et divers autres critères. À notre connaissance, il n'existe pas de travaux de recherche qui identifient les principaux critères de sélection des environnements infonuagiques; cela peut expliquer l'absence d'approche qui les prennent en compte tous à la fois.

3.5 Conclusion

Dans ce chapitre, nous avons passé en revue l'état de l'art au sujet des migrations infonuagiques.

Nous avons vu que les approches de sélection de l'environnement infonuagique existantes abordent l'optimisation de certains critères, cependant l'essentiel des méthodologies de migration dans lesquelles elles s'inscrivent n'incluent pas d'éllicitation et d'analyse des exigences de la migration. Ces exigences pourraient être liées aux nombreux facteurs d'adoption qui ont motivé la migration, mais ce lien n'a pas été étudié, à notre connaissance. Enfin, nous avons vu que l'absence d'une telle analyse des exigences est un frein pour la sélection d'une méthodologie et une stratégie de migration adaptée aux besoins de chaque organisation.

Dans le chapitre suivant, nous nous concentrons sur l'évaluation des critères pour la sélection de l'environnement infonuagique.

Chapitre 4

Évaluation d'un concept d'environnement infonuagique

Comme nous l'avons vu dans le chapitre précédent, évaluer divers critères (p. ex. les coûts, la qualité de service, le respect de la réglementation) est important dans la sélection d'un environnement, et donc dans la migration infonuagique. Par conséquent, nous dressons dans ce chapitre l'état de l'art de l'évaluation d'un concept d'environnement infonuagique. Par *concept d'environnement infonuagique*, nous parlons de l'état de cet environnement avant qu'il ne soit construit et mis en opérations. Nous présentons différentes approches, qui ont été implémentées de différentes manières afin d'évaluer différents critères.

Notons que nous ne nous intéressons pas ici aux travaux traitant d'optimisation d'un environnement existant. Par exemple, un problème d'optimisation de l'informatique en nuage fréquemment approché est le juste approvisionnement des ressources sur un environnement, c'est-à-dire assurer qu'il y ait, à chaque instant, ni trop et ni trop peu de ressources pour traiter les charges de calcul tout en assurant un *SLA*. Pour résoudre ce problème, AMIRI et KHANLI (2017) suggèrent une approche d'apprentissage automatique pour minimiser le nombre de machines virtuelles allouées au fur et à mesure. CHARD et coll. (2017) proposent *SCRIMP*, un intergiciel multinuage qui surveille un environnement infonuagique pour créer un profil d'utilisation (qui inclue, p. ex., l'utilisation des coeurs *CPU* et de la mémoire des machines virtuelles) et automatiquement adapter les ressources d'après ce profil. Quant à CHAISIRI, LEE et NIYATO (2012), ils ont développé un algorithme basé sur un modèle stochastique permettant d'approvisionner un environnement en maximisant la réservation de machines virtuelles ¹

1. La réservation de machines virtuelles est proposée par certains fournisseurs de services. Il s'agit d'un engagement fait longtemps en avance d'utiliser une machine virtuelle. Généralement, les fournisseurs de services

Si ces travaux abordent l'optimisation des coûts, d'autres se concentrent sur divers critères, comme JIN et coll. (2021) qui ont développé un outil d'observation et d'optimisation pour certains mécanismes de cybersécurité. Tous ces travaux se concentrent sur l'optimisation *à la volée* d'un environnement infonuagique existant ; cependant, ils n'évaluent à aucun moment un critère : par exemple, les travaux qui optimisent les coûts de l'environnement n'évaluent pas les coûts que générera le système suite à son optimisation. Or, les concepteurs lors d'une migration ont besoin d'être aidés dans leurs décisions pour sélectionner l'environnement infonuagique. C'est pour cette raison que, dans ce chapitre, nous ne nous intéressons qu'à l'évaluation et non à l'optimisation d'un environnement existant.

Comme elle peut être utilisée sans environnement infonuagique réel, l'évaluation par simulation est une approche très répandue qui a donné lieu à de nombreux travaux et implémentations logicielles que nous présentons dans la section 4.1. Dans la section 4.2, nous présentons d'autres approches d'évaluation des environnements infonuagiques. Enfin, nous concluons dans la section 4.3.

4.1 Évaluation par la simulation

Dans cette section, nous passons en revue les travaux de la littérature sur la simulation des systèmes infonuagiques. Ces travaux ont abouti au développement de logiciels, des simulateurs, que nous présentons dans une première sous-section, avant de les comparer, dans une seconde sous-section.

4.1.1 Outils de simulation

CloudSim CALHEIROS, RANJAN, ROSE et coll. (2009) ont développé CloudSim, un simulateur de nuages informatiques proposant un service de machines virtuelles à la demande.

L'infrastructure physique des centres informatique a une place importante dans CloudSim ; tous les services infonuagiques sont construits en partant de cette infrastructure physique simulée. Il est possible de modéliser diverses politiques d'ordonnancement des machines virtuelles² sur les hôtes. Cela peut servir d'aide à la décision aux fournisseurs de services pour construire leurs centres informatiques.

accordent une remise sur l'utilisation de machines virtuelles réservées.

2. Un algorithme d'ordonnancement de machines virtuelles est chargé de choisir la machine physique qui exécute une machine virtuelle. Il peut être amené à déplacer une machine virtuelle d'une machine physique à une autre, ce qui est appelé une migration.

Pour les usagers, un environnement infonuagique modélisé dans CloudSim est un ensemble de machines virtuelles sur lesquels des utilisateurs exécutent des tâches, chacune d'entre elles étant constituée d'instructions. Le résultat de la simulation contient, notamment, la durée de complétion de chaque tâche. CloudSim permet donc d'évaluer les performances de calcul d'un environnement infonuagique constitué de machines virtuelles, mais nécessite pour cela de connaître les détails d'infrastructure physique sous-jacents (CALHEIROS, RANJAN, BELOGLAZOV et coll., 2011).

Divers travaux ont entrepris d'étendre les critères que peut évaluer CloudSim. Par exemple, BELOGLAZOV, ABAWAJY et BUYYA (2012) se sont servis de ce simulateur afin d'évaluer des heuristiques pour l'allocation de machines virtuelles sur l'infrastructure physique dans le but de minimiser la consommation électrique des centres informatiques. De leur côté, ALVES et coll. (2016) ont développé un module d'extension pour CloudSim afin d'évaluer les coûts causés par l'allocation des machines virtuelles.

Enfin, d'autres efforts ont été investis pour étendre les possibilités de simulation pour les environnements infonuagiques en simulant des *PaaS* et *SaaS*. C'est ce que proposent, par exemple, JEON et coll. (2019) dans un module d'extension permettant de simuler des services de fonctions à la demande distribués³ dans CloudSim.

NetworkCloudSim Le simulateur CloudSim ne modélise pas le réseau des centres informatiques (BUYYA, RANJAN et CALHEIROS, 2009). Or, il s'agit d'un aspect particulièrement important dans le cas des systèmes distribués comme le sont les systèmes infonuagiques. En effet, la vitesse de traitement d'une charge de travail peut être réduite à cause de la bande passante, ou les coûts plus élevés à cause de transferts sur le réseau entre régions éloignées. C'est pour cela que GARG et BUYYA (2011) ont développé NetworkCloudSim, une extension de CloudSim.

En plus du modèle de CloudSim, le modèle simulé contient la topologie du réseau. Les temps de transferts sur le réseau sont ainsi calculés et ajoutés au temps de traitement des charges de calcul que simulaient déjà CloudSim.

CDOSim *Cloud Deployment Option simulator* (CDOSim) est un simulateur capable d'évaluer les coûts, le temps de réponse et les violations du *SLA* d'un environnement infonuagique (FITTKAU, FREY et HASSELBRING, 2012b ; FITTKAU, FREY et HASSELBRING, 2012a). Il est basé sur CloudSim, que Fittkau et coll. ont étendu avec plusieurs fonctionnalités, notamment pour permettre la

3. Les services de fonctions à la demande permettent de déployer des applications en tant que code source d'une seule fonction, en faisant l'abstraction complète des préoccupations opérationnelles de l'exécution d'un tel code source. Les services de fonctions à la demande *distribués* sont une proposition de CIAVOTTA et coll. (2021) d'étendre le concept de service de fonction à la demande au paradigme d'informatique en périphérie de réseau (en anglais : *Edge Computing*).

simulation de l'élasticité, ajouter des modèles de coût et les interactions entre machines virtuelles.

Pour simuler l'élasticité, ils ont ajouté la possibilité de démarrer et d'éteindre des machines virtuelles à la demande et créé des règles d'adaptation similaires à ce que les services de machines virtuelles à la demande proposent dans les groupes d'instance : par exemple, allumer une nouvelle machine virtuelle si l'utilisation du *CPU* excède un seuil. En outre, le temps d'allumage d'une machine virtuelle est également simulé afin de rendre compte du comportement réel d'un fournisseur de services.

EMUSIM CALHEIROS, NETTO et coll. (2013) remarquent qu'il peut être difficile de créer un modèle de simulation fidèle à la réalité ; c'est pour cette raison qu'ils proposent EMUSIM. L'exécution de cet outil a deux phases : une première d'émulation, et une seconde de simulation.

Pour l'émulation, EMUSIM utilise un cadre nommé *Automated Emulation Framework (AEF)*, qui émule des systèmes distribués. Il déploie des machines virtuelles, un réseau entre ces machines, et les prépare en installant les fichiers et en exécutant les applications nécessaires. Lors de l'activité d'émulation, l'infrastructure du fournisseur de services est émulée, et une application est exécutée plusieurs fois avec divers paramètres afin d'en constituer un profil. Ce profil documente les performances de l'application, par exemple son temps d'exécution ou le nombre de tâches exécutées en parallèle.

Pour la simulation, EMUSIM repose sur CloudSim et sur le profil de l'application. Les résultats proposés par EMUSIM sont de la même nature que ceux de CloudSim ; seulement, la phase d'émulation a assisté dans la création d'un modèle à simuler fidèle à la réalité.

TeachCloud TeachCloud est un simulateur développé par JARARWEH et coll. (2013) dans le but de fournir un outil d'expérimentation pour leurs étudiants.

Il repose sur CloudSim, que nous avons présenté précédemment, auquel il ajoute une interface graphique, un générateur de charge de travail, et divers modules pour modéliser la topologie des environnements et des charges de travail.

ContainerCloudSim Si la plupart des simulateurs de cette revue se concentrent sur les *IaaS* uniquement, ContainerCloudSim, lui, a été développé afin de simuler des *PaaS* de conteneurs à la demande (PIRAGHAJ et coll., 2016). Il s'agit d'une extension de CloudSim : elle ajoute les modélisations pour la simulation de conteneurs, par exemple l'ordonnancement des conteneurs sur les machines virtuelles. Cet outil permet, en plus de ce que permet de comparer CloudSim,

de comparer des algorithmes d'ordonnancement des conteneurs ⁴.

CloudSimScale ELAHI et coll. (2020) constatent que les simulateurs existants — que nous avons précédemment présentés — ne peuvent pas être exécutés dans un environnement distribué. Cela constitue un frein technique important dans l'optique de réaliser un très grand nombre de simulations. Par conséquent, il ont développé CloudSimScale, un outil de simulation distribué.

Cet outil repose sur CloudSim et permet d'effectuer des simulations similaires et d'évaluer les mêmes critères.

SPECI *Simulation Program for Elastic Cloud Infrastructures (SPECI)* est un simulateur de l'infrastructure d'un nuage qui est utilisé pour évaluer des stratégies de vérification et de rétablissement du bon fonctionnement d'une telle infrastructure (SRIRAM, 2009). En effet, les composants d'une infrastructure interagissent et, dans un nuage informatique, le nombre de composants est très important et croît pour répondre à de nouveaux besoins. Or, ces composants peuvent tomber en panne, que ce soit temporairement ou de manière permanente ; cela peut mener à des dysfonctionnements de l'ensemble du système.

Pour vérifier l'état de l'infrastructure, des stratégies de vérification sont mises en œuvre. Le choix d'une telle stratégie a des conséquences, par exemple sur l'utilisation du réseau, la rapidité de détection des défaillances ou la maintenance de cette stratégie dans le cas où un très grand nombre de composants cessent de fonctionner concurremment. Afin d'évaluer les conséquences de ces stratégies de vérification, *SPECI* simule un centre informatique avec tous ses composants, les dispositifs permettant la vérification du bon fonctionnement, et introduit des perturbations afin d'évaluer la capacité du système à se rétablir.

CloudAnalyst Suite au développement de CloudSim, WICKREMASINGHE, CALHEIROS et BUYYA (2010) ont mis au point CloudAnalyst.

Comme CloudSim, l'infrastructure physique est au cœur de la simulation. De plus, et contrairement à CloudSim, le réseau y est également modélisé. Ils intègrent notamment la localisation géographique des centres informatiques et des utilisateurs, les politiques de routage au sein du nuage ainsi que sur l'Internet, et la bande passante.

En outre, les bases d'utilisateurs y sont plus détaillées. Effectivement, CloudAnalyst permet de créer des scénarios d'utilisation d'un environnement infonuagique avec des périodes d'affluence et des périodes de creux.

4. Là où les algorithmes d'ordonnancement pour les machines virtuelles décident et révisent quelle machine physique héberge une machine virtuelle, ceux pour les conteneurs décident quelle machine virtuelle exécute le conteneur.

Grâce aux résultats qu'il génère à la fin d'une expérimentation, CloudAnalyst peut évaluer le temps de traitement des requêtes et les coûts causés par les machines virtuelles et les transferts sur le réseau. Il a également permis, par exemple, à EL KARADAWY, MAWGOUD et RADY (2020) d'étudier le comportement de plusieurs stratégies d'équilibrage des charges entre les machines virtuelles et évaluer laquelle permet de minimiser le temps de traitement des requêtes.

GroudSim GroudSim est un simulateur à événements discrets pour les applications scientifiques déployées sur des grilles et des nuages informatiques (OSTERMANN et coll., 2010). Ce simulateur se distingue de CloudSim de part sa conception qui lui permet de garder des temps d'exécution raisonnables quand il simule de très grandes infrastructures. En effet, il exécute une simulation sur un seul fil d'exécution (*thread*), tandis que chaque entité dans les premières versions de CloudSim (p.ex. machine) a un fil d'exécution dédié.

Tout comme dans CloudSim, les ressources modélisées sont les machines virtuelles, et les utilisateurs soumettent des charges de travail que le système doit traiter, et le résultat d'une simulation est une évaluation des coûts de l'environnement.

GDCSim Gupta et coll. ont, quant à eux, développé *Green Data Center Simulator* (GDC-Sim) (GUPTA, R. R. GILBERT et coll., 2011 ; GUPTA, BANERJEE et coll., 2014). Ce simulateur a pour but d'évaluer des architectures de centres informatiques et d'algorithmes de gestion des ressources. Une simulation couvre l'exécution d'un ensemble de charge de travail à traiter par le système infonuagique, prévues en amont de la simulation.

Les algorithmes de gestion des ressources à évaluer sont de plusieurs natures : certains affectent aux charge de travail une date de début de traitement et une machine hôte, d'autres gèrent l'état de consommation d'énergie des composants du système, et enfin d'autres algorithmes décident de la configuration du thermostat du centre informatique.

Les critères d'évaluation sont divers, par exemple la satisfaction du *SLA*, la quantité d'énergie utilisée, l'efficacité énergétique, la température maximale atteinte dans le centre informatique. La modélisation intègre notamment la climatisation des centres informatiques en simulant l'énergie qui lui est allouée et en répercutant ses effets sur la température des composants de l'infrastructure.

iCanCloud iCanCloud est un simulateur spécialisé pour simuler l'utilisation de services de machines virtuelles à la demande (NUÑEZ, VÁZQUEZ-POLETTI, CAMINERO, CARRETERO et coll., 2011 ; NUÑEZ, VÁZQUEZ-POLETTI, CAMINERO, CASTAÑÉ et coll., 2012). Il permet d'évaluer les coûts et les performances de calcul d'un environnement infonuagique.

Ses modèles sont fortement influencés par le service *Amazon EC2*. De ce fait, l'infrastructure physique du centre informatique en est omise : l'environnement infonuagique est constitué de machines virtuelles, de disques virtuels, et d'un réseau virtuel. En outre, des applications peuvent être déployées sur ces machines et elles implémentent différents modèles de logiciels qui caractérisent leur comportement.

Cependant, iCanCloud repose sur un outil de simulation d'infrastructures informatiques physiques (NUÑEZ, FERNÁNDEZ et coll., 2008). Les machines virtuelles simulées par iCanCloud reposent donc sur la simulation d'un centre informatique.

GreenCloud KLIAZOVICH, BOUVRY et KHAN (2012) ont développé un simulateur pour étudier l'efficacité énergétique des centres informatiques, GreenCloud. La consommation énergétique d'un centre informatique n'est pas imputable qu'à l'alimentation des serveurs, il faut aussi compter l'électricité allouée au matériel de mise en réseau ainsi que celle qui est utilisée pour la climatisation ou qui est perdue par dissipation thermique sans avoir été productive.

GreenCloud simule le traitement d'un ensemble de charge de travail dans un centre informatique. Une charge de travail est modélisée comme une liste de processus, qui sont eux-même des ensembles de tâches ; chaque tâche peut être indépendante des autres ou nécessiter la terminaison d'autres tâches. Au cours de la simulation, des modèles énergétiques spécifiques à chaque type d'élément sont utilisés pour évaluer la consommation énergétique de chaque élément du centre informatique. Ainsi, un serveur allumé consomme plus d'énergie quand il traite une charge de travail que quand il est au repos. Cette consommation calculée permet à un fournisseur d'infrastructure d'évaluer l'efficacité énergétique de son centre informatique.

DCSim *Data Center Simulator* (DCSim) est un simulateur de centre informatique développé afin d'évaluer l'efficacité d'algorithmes d'ordonnancement de machines virtuelles sur une infrastructure physique (TIGHE et coll., 2012). Les centres informatiques y sont réduits aux machines hôtes de l'infrastructure physique. En revanche, il modélise finement les étapes de l'allocation d'un hôte à une machine virtuelle et de la migration d'une machine virtuelle d'un hôte à un autre afin de rendre compte notamment du temps que prennent ces opérations. De plus, DCSim prend en compte les interactions et les dépendances qu'il existe entre les machines virtuelles et qui sont dues aux applications qu'elles exécutent, puisque la migration de machine virtuelle peut causer des retards dans le traitement d'une charge de travail. Au sujet des applications exécutées par les machines virtuelles, DCSim se distingue de CloudSim en se concentrant sur des applications de type serveur Web, alors que CloudSim modélise des lots de tâches de calcul. Le simulateur surveille plusieurs critères pour documenter une simulation : les violations du *SLA*, le nombre de machines hôtes actives dans l'infrastructure physique, le temps d'activité

des machines hôtes, l'utilisation du *CPU* des machines hôtes, le nombre de migrations réalisées et la consommation énergétique.

SimIC SOTIRIADIS, BESSIS et ANTONOPOULOS (2013) proposent *Simulating the Inter-Cloud* (SimIC) comme une alternative à CloudSim pour simuler des environnement multinuages.

En plus de considérer les algorithmes d'ordonnancement au sein des centres informatiques, SimIC embarque le concept de *meta-brokers*, qui dirigent les charges de travail vers un centre informatique.

Il évalue les temps d'exécution des charges de travail de ces environnements, et permet ainsi d'évaluer l'efficacité d'algorithmes d'ordonnancement et de *meta-brokers*.

FlexCloud XU et coll. (2015) proposent un simulateur, FlexCloud, afin d'évaluer des algorithmes de d'ordonnancement de machines virtuelles dans un centre informatique. Il se veut moins complexe que d'autres simulateurs bien établis tels que CloudSim ou iCanCloud. Tout comme ces simulateurs, le modèle simulé de FlexCloud comporte le centre informatique composé de machines physiques, auxquelles s'ajoutent d'autres composants, notamment pour le stockage et la mise en réseau. Les critères évalués par ce simulateur sont la rapidité de traitement des charges de travail ainsi que la consommation énergétique du centre informatique.

DISSECT-CF DISSECT-CF est un autre simulateur de centres informatiques. Il permet d'évaluer la consommation électrique de l'infrastructure physique d'un nuage informatique (KECSKEMETI, 2015).

Il se distingue des autres simulateurs par sa modélisation du partage des ressources de l'infrastructure, qui permet notamment de simuler les interactions entre l'ordonnancement de plusieurs exécutions de logiciels sur une machine physique (ce que les auteurs nomment *groupe d'influence*), et par sa modélisation de la consommation énergétique qui est découplée de la simulation des ressources de l'infrastructure, afin de permettre l'expérimentation d'algorithmes d'ordonnancement des tâches et des machines virtuelles.

CloudSched TIAN et coll. (2015) ont développé un simulateur, CloudSched, afin d'expérimenter des algorithmes d'ordonnancement des ressources en tenant compte de la localisation géographique des centres informatiques et des charges de travail à traiter. Il permet d'évaluer l'efficacité énergétique du centre informatique, ainsi que l'utilisation au cours du temps des ressources physiques de l'infrastructure (*CPU*, mémoire vive, bande passante).

Contrairement à CloudSim et CloudAnalyst, CloudSched se concentre sur l'analyse au niveau du *IaaS* plutôt qu'au niveau des tâches à exécuter : le traitement de chaque nouvelle requête requiert la création d'une machine virtuelle, et non pas l'allocation d'une portion de

machine virtuelle existante. Ces machines virtuelles sont créées en se basant sur un stéréotype de machine sélectionné aléatoirement parmi un ensemble donné en paramètre de la simulation. De même, le taux d'arrivée des requêtes des utilisateurs fait partie des paramètres de la simulation.

GloudSim DI et CAPPELLO (2015) ont développé un simulateur, GloudSim, pour simuler un centre informatique. Pour cela, ils utilisent un ensemble de données publié par *Google* contenant les traces d'exécution de leur système d'ordonnancement des machines virtuelles au sein de l'un de leurs centres informatiques. De ces traces, ils extraient notamment le comportement du système face aux tâches qu'il a eu à traiter, afin de rejouer le traitement de tâches similaires. Avec ces données, GloudSim peut simuler fidèlement un centre informatique de *Google* afin d'évaluer l'efficacité d'un algorithme d'ordonnancement.

Vondra et Šedivý (2017) VONDRA et SEDIVÝ (2017) ont étudié les conséquences du choix d'une stratégie de mise à l'échelle automatique sur les coûts et les performances de calcul d'un environnement constitué de machines virtuelles. Ils affirment qu'aucun simulateur existant étant adapté à une telle étude, en particulier à cause de l'imprécision de leurs évaluations, ils en ont développé un autre.

Ce simulateur est basé sur un réseau de file d'attente plutôt que sur la simulation à événements discrets. Au lieu d'avancer d'événement en événement, le simulateur avance par pas de temps, au cours duquel le modèle de réseau de file d'attente simulé est recalculé. La latence du réseau de file d'attente recalculé est la valeur d'entrée de l'algorithme de mise à l'échelle automatique expérimenté dans la simulation, qui indique le nombre de machines virtuelles requises au pas de temps suivant.

4.1.2 Discussion

Suite à cette revue de vingt-et-un simulateurs de systèmes infonuagiques de la littérature, nous proposons une synthèse dans laquelle nous discutons de leurs points communs, de leurs différences, et des difficultés que l'utilisation de ces simulateurs posent pour un usager de services infonuagiques.

Type d'applications La plupart des simulateurs que nous avons présenté ici possèdent une modélisation des applications en charge de travail décomposées en tâches. L'utilisateur qui a besoin de traiter une charge de travail a accès au *IaaS* et peut exécuter son application sur une machine virtuelle existante ou en créer une nouvelle. Comme le soulignent OSTERMANN et coll. (2010), cette approche s'inspire des besoins en calculs pour la recherche et de l'usage en

vigueur dans les grilles informatiques. Cependant, ça ne semble pas être la pratique commune dans l'industrie.

Tout comme les développeurs de CDOSim (FITTKAU, FREY et HASSELBRING, 2012a), nous y observons davantage l'utilisation du paradigme service, dans lequel l'utilisateur interroge un service Web pour exécuter et obtenir le résultat du traitement de la charge de travail. La mise à l'échelle du système est le fait d'un automatisme qui mesure diverses métriques et prend la décision d'allumer ou d'éteindre des instances de machines virtuelles, comme ce qu'ont étudié VONDRA et SEDIVÝ (2017). Pour nous, un outil à l'adresse des usagers dans l'industrie devrait permettre la modélisation de ce genre d'applications et des particularités qu'elles ont (p. ex. les sessions, la parallélisation du traitement des requêtes, la consommation des ressources au repos).

Niveau d'information requis La difficulté de créer un modèle de simulation crédible, suffisamment proche de la réalité, est une difficulté qui accompagne l'approche par simulation. Afin de l'assister pour le modèle des applications, CALHEIROS, NETTO et coll. (2013) proposent l'usage de l'émulation ; cela permet de constituer un profil de chaque application du système à simuler avec les consommations de ressources, la durée d'exécution, les interactions avec les autres composants de l'environnement.

Cependant, une aide pour modéliser les applications n'est pas suffisante. En effet, quasiment tous les simulateurs que nous avons revu exigent la connaissance de l'infrastructure physique du ou des centres informatiques. Cela peut se restreindre aux modèles et le nombre de machines physiques, comme par exemple dans CloudSim (CALHEIROS, RANJAN, ROSE et coll., 2009), jusqu'à des modélisation très fines que proposent des outils comme GreenCloud qui inclut la topologie du réseau physique (KLIASOVICH, BOUVRY et KHAN, 2012) ou GDCCSim qui tient compte de la disposition de l'infrastructure au sein du centre informatique (GUPTA, R. R. GILBERT et coll., 2011). Même les simulateurs qui proposent des modélisations de l'environnement qui font abstraction de cette infrastructure physique, tels que CDOSim ou iCanCloud, reposent sur des outils de simulation qui en requièrent la modélisation. Or, cette information n'est parfois pas accessible à tous. Par exemple, dans le contexte des nuages publics, l'architecture des centres informatiques n'est souvent pas diffusée au grand public, bien au contraire : cela demeure secret dans de nombreux cas, notamment pour des raisons de sécurité. Par conséquent, ces simulateurs sont destinés à ceux qui détiennent la connaissance de la composition de l'infrastructure : les fournisseurs de services et les fournisseurs d'infrastructure. Ils ne sont pas à l'usage des usagers de services infonuagiques.

Prépondérance des *IaaS* Nous constatons que la très large majorité des outils présentés simulent des systèmes basés sur des machines virtuelles. Très peu, finalement, s'intéressent aux *PaaS*. Nous pouvons citer JEON et coll. (2019) qui ont modélisé les services de fonctions à la demande distribués sur CloudSim, et ContainerCloudSim pour les services de conteneurs à la demande (PIRAGHAJ et coll., 2016). Cependant, dans ces deux cas, la modélisation des *PaaS* repose sur l'utilisation de *IaaS*. Or, il n'est pas toujours possible de savoir comme le fournisseur de services procède pour délivrer ses *PaaS*. S'il est possible qu'il utilise ses propres services infonuagiques pour en proposer d'autres, il se peut également qu'une couche logicielle s'ajoute ou soit omise : un conteneur déployé par un service de conteneurs à la demande peut être déployé directement sur une machine physique (et non virtuelle), mais peut aussi être déployé par un logiciel d'orchestration de conteneurs exécuté par une machine virtuelle. Selon la solution technique employée par le fournisseur de services, l'utilisateur peut constater d'importantes différences de vitesses de traitement (liées, par exemple, à la virtualisation). Ceci est un second argument en faveur de la destination de ces outils aux fournisseurs de services, qui sont ceux qui possèdent la connaissance technique de leurs services.

4.1.3 Conclusion

Nous avons vu que les simulateurs de systèmes infonuagiques sont nombreux, permettent l'évaluation de divers critères sans nécessiter la création d'un centre informatique ou le déploiement d'un environnement infonuagique. Ils permettent notamment aux fournisseurs de services et d'infrastructure d'expérimenter des architectures de centres informatiques et divers algorithmes d'ordonnancement, que ce soit pour allouer des machines virtuelles à un hôte, ou des tâches à une machine virtuelle de traitement. Tout cela permet à ces acteurs de minimiser leurs dépenses, par exemple en permettant de prévoir la consommation énergétique et la satisfaction du *SLA*.

Cependant, ces simulateurs ne sont pas pertinents pour les usagers des services infonuagiques car ils ne possèdent pas les informations nécessaires pour réaliser des simulations suffisamment proches de la réalité. Par conséquent, la section suivante est dédiée à d'autres approches d'évaluation pour les systèmes infonuagiques.

4.2 Autres approches d'évaluation

Diverses autres approches sont utilisées pour évaluer les caractéristiques d'un système infonuagique. Nous les présentons dans cette section en distinguant, d'une part, les approches

issues de travaux de recherche et, d'autre part, celles développées au sein de l'industrie.

4.2.1 Approches académiques

Martens et coll. (2012) MARTENS, WALTERBUSCH et TEUTEBERG (2012) proposent d'importer le concept de *coût total de possession* (en anglais : *Total Cost of Ownership, TCO*) à un système infonuagique sur nuage public. Ce concept est très commun pour l'analyse des coûts du cycle de vie d'une infrastructure physique ; elle inclut par exemple le coût du matériel, le loyer des locaux, diverses factures et les salaires du personnel qui entretient cette infrastructure physique. Cependant, de tels critères ne rentrent pas en compte pour un environnement infonuagique sur nuage public du point de vue d'un usager de services infonuagiques.

Ils proposent une typologie des coûts d'un tel environnement, qui inclut les coûts : de la prise de décision stratégique pour le choix de la stratégie de migration, de l'évaluation et de la sélection de l'environnement infonuagique, des factures régulières des services infonuagiques, de la migration, du support, de la formation des équipes, de la maintenance et de l'évolution du système, des pannes du système, de l'éventuelle migration depuis le nuage vers une autre solution d'hébergement (fin du cycle de vie du système infonuagique).

Les autres travaux que nous présentons dans ce chapitre n'ont trait qu'à l'évaluation des caractéristiques du système infonuagique (dans le *TCO*, il s'agit des coûts des factures régulières). Cependant, le concept de *TCO* met en évidence que cela peut ne pas être suffisant. En l'occurrence, pour les coûts, certaines organisations pourraient avoir besoin d'évaluer le coût de leur adoption de l'informatique en nuage avant de prendre la décision de migrer.

Ferretti et coll. (2014) FERRETTI et coll. (2014) ont étudié les services de bases de données à la demande basés sur des *IaaS*. Ils ont pris la perspective d'utilisateurs d'un tel service et se sont intéressés à sécuriser les communications et le stockage de données. Pour cela, ils proposent une architecture de service ainsi qu'une discussion sur l'évaluation des coûts et des performances de calcul de cette architecture.

D'une part, pour les coûts, ils proposent une approche analytique permettant l'estimation sans déployer d'environnement infonuagique. Leur formulation des coûts dépend de trois variables : le temps durant lequel le service de base de données à la demande est utilisé, le tarif pour l'allocation des ressources informatiques, et l'usage en ressources informatiques (p. ex. le nombre d'heures d'allocation d'une machine virtuelle). Vis-à-vis du tarif, ils distinguent les coûts de facturation, qui correspondent à ce que coûtent les ressources *à la demande*, des coûts de réservations. En effet, il est possible pour un usager de s'engager à utiliser une ressource : il la réserve et paie en amont pour son utilisation future. Ils mettent également en lumière deux

types de fonctions de facturation : *linéaire*, c'est-à-dire que le coût évolue à la même vitesse que l'usage (p. ex. 1€ par heure d'allocation d'une machine virtuelle), ou *échelonné*, qui est une fonction linéaire par morceau (p. ex. 1€ par heure d'allocation d'une machine virtuelle pour les dix premières heures, puis 0.80€ par heure). Vis-à-vis de l'usage, ils identifient des difficultés à estimer l'usage du stockage (la taille des données stockées par la base de données) et celui du réseau (la taille des données entrantes et sortantes). En effet, cela dépend de plusieurs paramètres, par exemple du chiffrement ou du nombre d'interactions avec la base de données. Quant à l'estimation de l'usage pour l'allocation des ressources, elle est considérée triviale.

D'autre part, pour l'évaluation des performances, ils procèdent par des bancs de test de performance en émulant le service de bases de données à la demande.

Aoshima et Yoshida (2020) AOSHIMA et YOSHIDA (2020) proposent une méthode d'estimation des coûts pouvant être appliquée dès les premières étapes de la conception du système. Dans cette méthode, ils modélisent un environnement infonuagique en graphe dirigé acyclique, dans lequel les sommets sont les applications, et les arcs, les relations entre les applications. Les arcs ont un poids correspondant au nombre de requêtes envoyées au sommet incident lors d'une exécution de l'application correspondant au sommet sortant. Par exemple, deux sommets pourraient être un serveur Web et un *SGBD*, et un arc entre les deux symbolise le fait que le serveur Web lise ou écrive une fois dans la base de donnée. Pour estimer le coût des nœuds, il est nécessaire d'estimer la fréquence des événements (p. ex. une requête *HTTP* au serveur Web) et les ressources nécessaires pour effectuer le calcul (p. ex. un certain gabarit de machine virtuelle).

Cette modélisation permet d'estimer les coûts liés au réseau et aux interactions entre les ressources de l'environnement. C'est effectivement important car, si certains types de services infonuagiques n'ont pas de surcoût à l'exécution d'une application (notamment les *IaaS* : la ressource est allouée même si aucune application n'est exécutée), la plupart des *PaaS* génèrent des coûts qu'à cette occasion. C'est ce qu'Aoshima et Yoshida illustrent dans une autre publication dans laquelle ils se concentrent sur les services de fonctions à la demande (AOSHIMA et YOSHIDA, 2022). Ces services n'allouent aucune ressource lorsqu'il n'y a pas de requête à traiter, et en allouent autant que nécessaires dès qu'un calcul est demandé. Ils ont montré que cette méthode permet d'estimer les coûts de ces services en tenant compte de leur mise à l'échelle.

Binnig et coll. (2009) Dans une publication des débuts de l'informatique en nuage, BINNIG et coll. (2009) proposent une discussion sur la création d'un banc de test dédié à l'évaluation des services infonuagiques. Ils élicitent les exigences pour un tel banc de test, mettant en avant la nécessité d'évaluer l'élasticité des services infonuagiques, leurs coûts et leur tolérance aux

pannes.

En analysant un banc de tests usuel, *TPC-W*, ils montrent des décalages entre ce banc de tests et les attentes qu'il est légitime d'avoir vis-à-vis d'un service infonuagique. Par exemple, *TPC-W* requiert de la cohérence forte des données stockées par le système, c'est-à-dire que toutes lectures des données doivent rendre compte des modifications antérieures. Cependant, il est attendu d'une base de données hébergée dans un nuage informatique qu'elle puisse être mise à l'échelle, pour s'adapter au nombre de requêtes à traiter et à l'espace de stockage réellement utilisé. Cela requiert un partitionnement des données sur chaque instance hébergeant la base de données. Or, d'après le théorème de Brewer, il n'est pas possible de garantir en même temps la cohérence forte des données, la disponibilité de la base de données et la tolérance au partitionnement (S. GILBERT et LYNCH, 2002). Par conséquent, les bases de données sur un nuage informatique présentent une cohérence faible, c'est-à-dire que les données deviennent cohérente au bout d'un certain temps. Un banc de test adapté à l'informatique en nuage devrait prendre en considération cette particularité, et toutes les autres, afin de pouvoir évaluer de manière pertinente un service infonuagique.

Bancs de tests : Open Cirrus et OCT Plusieurs initiatives ont pour but de mettre au service de la recherche des bancs de tests pour mener des expérimentations. Ces initiatives sont motivées par le besoin d'effectuer diverses évaluations et de pouvoir accéder aux détails de bas niveau d'un centre informatique pour pouvoir comprendre et expliquer. En effet, les fournisseurs de services industriels ne permettent pas d'acquérir un tel niveau de détail.

Parmi ces initiatives, nous pouvons citer Open Cirrus (CAMPBELL et coll., 2009 ; AVETISYAN et coll., 2010) et *Open Cloud Testbed (OCT)* (GROSSMAN et coll., 2009 ; ZINK et coll., 2021). Open Cirrus est fondé par plusieurs grandes entreprises (Yahoo!, HP, Intel) et plusieurs universités, qui chacune met à disposition un centre informatique pour créer un nuage communautaire. Quant à *OCT*, elle est financée par la *National Science Foundation*, une agence gouvernementale étasunienne, et dispose de plusieurs centres informatiques aux États-Unis d'Amérique.

Ces projets se concentrent sur les *IaaS* et les services dédiés aux traitement des données massives.

Weber et coll. (2014) Afin d'analyser l'élasticité des *IaaS*, WEBER et coll. (2014) proposent une méthodologie de tests, et des métriques afin de quantifier l'élasticité de tels services infonuagiques. Les tests consistent à faire varier la charge d'utilisation d'un service, c'est-à-dire envoyer des requêtes à ce service à diverses fréquences. Les métriques qu'ils surveillent sont la vitesse de mise à l'échelle, la précision de la mise à l'échelle (c.-à-d. la mise à l'échelle sans suraprovisionnement) et l'élasticité.

Belli et coll. (2016) Nous avons précédemment présenté les travaux de Belli et coll. dans la section 3.4. Nous y avons expliqué que, pour la sélection d'un environnement infonuagiques, ils proposent une méthode en deux étapes : d'abord, surveiller une infrastructure existante afin de construire un modèle de consommation, puis utiliser ce modèle de consommation afin de calculer les coûts d'un environnement similaire chez divers fournisseurs infonuagiques (BELL, LOOMIS et ABDENNADHER, 2016). Cela requiert au préalable de standardiser l'expression des tarifs à travers un schéma agnostique du fournisseur infonuagique. Nous retrouvons l'idée de standardiser les tarifs également dans *CoCoOn*, qui intègre une modélisation similaire (Q. ZHANG, HALLER et Q. WANG, 2019).

Duan (2017) DUAN (2017) a effectué une revue de la littérature au sujet de l'évaluation de la performance des services infonuagiques. Les méthodes d'évaluation qu'il a revu sont basées soit sur des mesures, soit sur des modèles analytiques.

Les méthodes basées sur des mesures requièrent le déploiement d'un environnement infonuagique. Des expériences sont menées pour mesurer des métriques ; ces expériences considèrent généralement le service comme une boîte noire : seules ce que constate l'utilisateur de ces services importe. Les métriques utilisées dans ces travaux sont le temps de réponse du service, la quantité de tâche qu'il peut traiter par unité de temps, sa disponibilité, la quantité de ressources qu'il utilise, sa stabilité quand il subit une charge importante, sa capacité de mise à l'échelle, et son élasticité. Ce sont cependant des approches coûteuses car elles nécessitent la mise en place d'un environnement.

Une grande partie des méthodes basées sur des modèles analytiques reposent sur la théorie des files d'attente. Ces travaux permettent de modéliser des comportements comme l'impact de la virtualisation sur les performances d'un service, ou celui de l'utilisation d'une machine hôte dédiée comparée à un hôte partagé par plusieurs machines virtuelles. D'autres approches reposent sur la construction d'un profil à partir du *SLA* ou d'autres modèles stochastiques.

Gesvindr et coll. (2017) GESVINDR, BUHNOVA et GASIOR (2017) abordent également l'évaluation des performances d'un service infonuagique, mais se concentrent sur les *PaaS*. Ils relèvent les particularités de cette évaluation, notamment la complexité cachée des *PaaS* (il est souvent impossible de savoir comment ils sont implémentés), le partage de l'infrastructure pour plusieurs usagers (qui peuvent causer des perturbations), et les mises à jour de l'environnement (mises à jour de l'infrastructure physique mais aussi des logiciels). Toutes ces raisons rendent l'utilisation de modèles analytique peu fiable pour l'évaluation des performances, ce qui amènent à mener des campagnes de tests avec des prototypes. Un prototype est, ici, une version simplifiée de l'application déployée par un *PaaS*. Les auteurs proposent une méthode

d'évaluation des performances reposant sur des prototypes, utilisable dès les phases préliminaires de la conception d'un système infonuagique. Cette méthode est automatisée avec un outil, *PaaSArch* (GESVINDR et BUHNOVA, 2019), qui génère le code source de prototypes sur la base d'un modèle qui décrit l'application (p. ex. *PaaS* qui l'héberge, type d'application, tâches réalisées lorsque l'application est exécutée), le compile, le déploie et prépare le système infonuagique pour l'évaluation.

4.2.2 Approches industrielles

Calculatrices de coûts des fournisseurs de services Plusieurs fournisseurs de services ont développé une calculatrice de coût pour évaluer les coûts d'un environnement infonuagique utilisant leurs services. C'est le cas, par exemple, de Amazon Web Services⁵ et Google Cloud⁶. L'usage de telles calculatrices est très répandu dans l'industrie.

Pour illustrer ces outils, nous présentons une capture d'écran de la calculatrice de Google Cloud sur la figure 4.1. Une calculatrice de coûts est un formulaire, les champs à renseigner diffèrent selon le service infonuagique dont il faut estimer les coûts. Sur la figure, le service infonuagique est Google Cloud Functions, un service de fonctions à la demande, qui alloue de petites quantités de ressources de calcul à des instances pour exécuter une application à chaque requête reçue. Une fois l'exécution achevée, les ressources de l'instance sont très vite libérées; ce type de services permet donc d'adapter finement l'environnement infonuagique au besoin présent. La facture pour ce service est dépend, pour l'essentiel, de coûts de réseau pour l'utilisation de la bande passante, et de coûts liés à l'utilisation des ressources pour chaque instance⁷. Ces derniers sont calculés d'après la quantité de ressources allouées et leur temps d'allocation.

Sur la figure, nous constatons que le gabarit alloué à chaque exécution est d'abord indiqué : passé le nom de la fonction, le formulaire requiert de renseigner la localisation des ressources, ici la région *europa-west1* qui réunit plusieurs centres informatiques en Belgique, et leur quantité : ici, chaque exécution est faite sur une instance qui possède 128 mégaoctets de mémoire et un coeur *CPU* avec une fréquence de 200 mégahertz. Dans les champs suivants, il est demandé de renseigner des métriques par exécution d'une application : le temps d'exécution et la bande passante utilisée. Puis, il faut renseigner le nombre d'exécutions mensuelles de l'application : grâce à cette information, le calcul des usages devient apparemment trivial. Enfin, il est possible d'indiquer la nécessité de conserver un minimum d'instances allouées. Cette fonctionnalité permet de réduire la latence perçue par l'utilisateur : sans instance allumée, le

5. Calculatrice de coûts de AWS : <https://calculator.aws>.

6. Calculatrice de coûts de Google Cloud : <https://cloud.google.com/products/calculator>.

7. Tarifs de Google Cloud Functions : <https://cloud.google.com/functions/pricing>.

temps d'allocation et de mise en place de l'application à exécuter s'ajoute au temps d'exécution. Conserver une telle instance allouée coûte de l'argent : cette instance est facturée pour le mois entier, avec cependant un taux différent des autres instances quant elle n'est pas en train d'exécuter l'application.

Si renseigner ces informations permet à la calculatrice de Google Cloud de calculer une estimation du coût, cette dernière doit être considérée avec précaution. En effet, nous pouvons souligner deux risques d'altération de la fiabilité de cette évaluation. D'une part, il n'est pas facile pour un utilisateur de renseigner certains champs. Par exemple, pour le temps d'exécution d'une application, cela ne peut pas être estimé simplement : si l'application envoie une requête à un autre composant et attend sa réponse pour poursuivre, alors le temps d'exécution est tributaire de cet autre composant. D'autre part, il existe plusieurs mécanismes qui interviennent lors de l'exécution d'une application sur Google Cloud Functions, et qui peuvent aboutir à différents coûts selon le contexte d'exécution de cette application ; or, le formulaire ne fournit aucune aide pour en tenir compte. Par exemple, une instance déployée pour l'exécution d'une application n'est pas immédiatement libérée à la fin de l'exécution : elle demeure allouée pour une durée configurable afin d'exécuter une autre requête d'exécution si nécessaire ; de plus, une instance peut traiter plusieurs exécutions en parallèle, le nombre maximum d'exécutions parallèles est également configurable.

Notons, enfin, que ces calculatrices ne permettent pas de comparer des fournisseurs de services entre eux, puisque chacune évalue les services infonuagiques d'un seul fournisseur de services et que les formulaires sont très différents d'une calculatrice à l'autre.

Calculatrices de coûts agnostiques d'un fournisseur Afin de comparer les fournisseurs de services entre eux, certaines calculatrices ont été développées en se concentrant sur un type de services infonuagiques particulier.

CostStorage⁸ est une telle calculatrice, dédiée aux services de stockage de documents tels que Google Cloud Storage et Amazon S3. Il s'agit également d'un formulaire, mais il ne contient pas d'information spécifique à un service infonuagique en particulier. Par exemple, plutôt que de désigner un centre informatique, il faut renseigner une région du monde telle que l'Europe. Pour résultat, il calcule le coût de diverses configurations de divers services infonuagiques, ce qui permet d'en comparer le coût.

D'autres outils proposent d'autres visualisations qu'un simple formulaire. Nous pouvons citer Holori⁹ et Brainboard¹⁰ qui permettent de décrire l'environnement sous la forme d'un

8. Page Web de CostStorage : <http://coststorage.com>.

9. Site Web de Holori : <https://holori.com>.

10. Site Web de Brainboard : <https://www.brainboard.co>.

FIGURE 4.1 – Capture d’écran de la calculatrice de coûts de Google Cloud

graphe et qui associe à chaque noeud, chaque ressource déployée, un coût.

Cependant, ce type de calculatrices partage les limites des calculatrices dédiées à un fournisseur de services, à savoir la difficulté d’estimer les valeurs à renseigner dans le formulaire et l’omission de mécanismes des services infonuagiques qui peuvent influencer sur les coûts.

Évaluation basée sur les outils de déploiement de l’environnement La démocratisation de l’informatique en nuage a été accompagnée par des outils nommés *Infrastructure en tant que code* (en anglais : *Infrastructure as Code*). Ces outils reposent sur un plan de déploiement, qui consiste en une description textuelle de l’environnement infonuagique, pour déployer un environnement infonuagique de manière reproductible. Un outil d’infrastructure en tant que code très répandu est Terraform¹¹.

Comme ces outils sont très utilisés dans l’industrie, l’évaluation des environnements basée sur les fichiers qu’ils emploient a été envisagée, en particulier pour le calcul des coûts. C’est ce que fait, par exemple Infracost¹², qui évalue le coût d’un plan de déploiement Terraform. Pour cela, il repose sur les tarifs publics des fournisseurs de services et requiert, tout comme les calculatrices, de données supplémentaires afin d’évaluer les coûts liés à l’élasticité.

Si ces outils s’intègrent aux outils utilisés par les développeurs, les données supplémentaires requises pour évaluer les coûts liés à l’élasticité demeurent néanmoins difficiles à estimer.

11. Site Web de Terraform : <https://www.terraform.io>.

12. Site Web d’Infracost : <https://www.infracost.io>.

4.3 Conclusion

Dans ce chapitre, nous avons passé en revue les travaux académiques et industriels qui traitent de l'évaluation de systèmes infonuagiques.

Plusieurs approches sont utilisées pour évaluer diverses caractéristiques. Nous avons vu que, parmi ces approches, la simulation de systèmes infonuagiques est très répandue. Cependant, les nombreux simulateurs développés requièrent des connaissances de l'infrastructure physique ; en cela, ils sont adressés aux fournisseurs d'infrastructure et de services. Dans les autres approches que nous avons revu, nombreuses sont celles qui évaluent un service infonuagique isolé du reste de l'environnement, ou qui posent des contraintes importantes sur la constitution de l'environnement. Nous remarquons, en effet, la prépondérance des *IaaS* dans les travaux de recherche. Enfin, nous constatons pour les travaux qui traitent de l'évaluation des coûts qu'ils ne prennent pas en compte l'élasticité des environnements, qui est pourtant une caractéristique importante dans l'utilisation industrielle de l'informatique en nuage.

Troisième partie

Contributions

Chapitre 5

Identification des exigences de haut niveau dirigeant la sélection d'un environnement infonuagique lors d'une migration

Dans le chapitre 3, nous avons vu que de nombreux travaux traitent de méthodes de sélection de l'environnement infonuagique. Cependant, chacun de ces travaux n'aborde qu'une exigence ou qu'une liste réduite d'exigences. Or, il est vraisemblable que de nombreuses exigences soient à prendre en compte lors d'une migration infonuagique : c'est l'ensemble de ces exigences qui devraient diriger la sélection de l'environnement. Nous n'avons pas trouvé de travaux qui élicite les exigences les plus fréquentes des migrations infonuagiques, ce qui peut expliquer l'absence d'une méthode qui les prenne toutes en compte.

Néanmoins, les facteurs d'adoption de l'informatique en nuage ont été très largement étudiés. Certains de ces facteurs d'adoption font référence à des caractéristiques techniques du système infonuagique ; dès lors, nous pouvons supputer que certaines exigences de la migration en découlent. Ainsi, si une organisation migre son système informatique pour diminuer les coûts d'infrastructure, il serait raisonnable qu'elle fixe un budget pour l'environnement infonuagique. Dans les faits, ce n'est pas si simple. En effet, des organisations considèrent que l'adoption de l'informatique en nuage répond à leurs attentes, sans considération pour l'environnement infonuagique sélectionné. De fait, les facteurs d'adoption ne sont pas des exigences : ils sont les motivations pour une organisation d'adopter l'informatique en nuage, et non ce

qu'elle attend de l'informatique en nuage.

En somme, il est intéressant d'identifier les exigences récurrentes dans les migrations et qui ont des conséquences sur la sélection de l'environnement. Pour y parvenir, nous avons mené une enquête qualitative sous la forme d'entretiens semi-dirigés auprès d'industriels qui ont pris part à des migrations infonuagiques. Cela nous a permis de recenser les exigences de chacune de ces migrations, que nous avons ensuite généralisées en exigences de haut niveau afin de mettre en lumière les critères qui importent dans ce contexte.

Dans ce chapitre, nous détaillons l'étude qualitative que nous avons mené, à commencer par la méthodologie de collecte des données auprès des participants, dans la section 5.1. En mettant en œuvre cette méthodologie, nous avons constitué un corpus, présenté dans la section 5.2. Puis afin d'identifier les exigences de haut niveau, nous avons analysé les entretiens, ce que nous présentons en section 5.3, suivi des résultats de l'étude en section 5.4. Finalement, nous discutons de ces résultats dans la section 5.5 et concluons en section 5.6.

5.1 Méthodologie de collecte des données

Notre étude a pour but de répondre à la question de recherche suivante : « *Quelles sont les exigences de haut niveau qui dirigent la sélection d'un environnement infonuagique lors d'une migration ?* ».

Pour ce faire, nous avons mené une enquête qualitative. POPE et MAYS (1995) définissent le but des enquêtes qualitatives comme étant de « *développer des concepts pour nous aider à comprendre les phénomènes sociaux dans leur contexte naturel (plutôt que des contextes expérimentaux), en mettant l'emphasis sur les significations, les expériences et les points de vue de tous les participants* »¹. Les réponses qu'elles apportent sont exprimées dans le langage naturel plutôt que par des mesures (SCHWARTZ et JACOBS, 1979); elles répondent donc à des questions commençant, par exemple, par « *Comment... ?* » ou « *Pourquoi... ?* », mais pas par « *Combien... ?* ». Il s'agit d'une approche commune dans de nombreux domaines de recherche, tels que la médecine (DiCICCO-BLOOM et CRABTREE, 2006) ou les sciences sociales (SCHWARTZ et JACOBS, 1979).

Nous avons choisi de mener des entretiens semi-dirigés, c'est-à-dire des conversations avec un panel de participants, que nous avons encadrées à l'aide d'un guide d'entretien tout en leur laissant la liberté de développer la conversation à leur convenance. Le guide d'entretien que nous avons défini fixe les phases des entretiens et liste les questions posées à chaque partici-

1. Dans le texte : « *The goal of qualitative research is the development of concepts which help us to understand social phenomena in natural (rather than experimental) settings, giving due emphasis to the meanings, experiences, and views of all the participants* ».

pant. Ces questions sont ouvertes (c.-à-d. que la réponse attendue n'est pas *oui* ou *non*). En effet, l'objectif n'est pas de montrer que certaines exigences sont récurrentes dans le contexte d'une migration infonuagique ou non, mais bien de découvrir les exigences qui sont élicitées dans ce contexte. Une question ouverte permet alors aux participants d'expliquer en profondeur leur expérience. Afin de guider notre démarche d'entretiens semi-dirigés, nous avons suivi les recommandations du groupe d'intérêt spécial sur l'ingénierie logicielle de ACM (SIGSOFT, 2022).

Dans cette section, nous commençons par présenter nos critères d'échantillonnage des participants à l'étude, dans la sous-section 5.1.1, puis nous décrivons notre guide d'entretien dans la sous-section 5.1.2.

5.1.1 Échantillonnage des participants

Nous avons interrogé des participants ayant une connaissance pratique de la migration infonuagique, autrement dit : nous avons choisi des participants qui avaient pris part aux phases initiales d'au moins une migration.

En sus, et comme le recommande McCracken (1988), nous avons cherché des profils de participants variés tout en conservant la proximité avec notre question de recherche. Ainsi, nous avons cherché à diversifier les profils sur plusieurs critères afin de ne pas collecter les exigences propres à un seul stéréotype de migration. D'abord, nous cherchions une diversité de rôles, c'est-à-dire que nous voulions à la fois des profils techniques (p. ex. des développeurs de logiciels, des opérateurs, des architectes de systèmes infonuagiques) et des profils fonctionnels (p. ex. des responsables de produit ou *Product Owners*, des analystes fonctionnels), afin de ne pas limiter la collecte des exigences aux préoccupations particulières d'un seul rôle. De plus, nous souhaitions que les participants aient effectué des migrations dans des organisations dans divers secteurs d'activité. En effet, certains secteurs d'activité pourraient ne se focaliser que sur certains types d'exigences, or nous voulons lister les exigences pertinentes tous secteurs compris. Enfin, nous avons cherché de la variété dans la taille des organisations dans lesquelles les participants ont effectué une migration, à nouveau pour ne pas collecter d'exigences propres uniquement à des petites ou de très grandes entreprises.

5.1.2 Guide d'entretien

Réalisation des entretiens

La durée des entretiens est d'environ une heure. Ils sont réalisés en face à face avec chaque participant, et se déroulent en trois parties.

Dans la première partie, le chercheur présente au participant le contexte de l'entretien. À cet effet, il lui explique l'objectif de l'étude et la démarche. Le but de cette partie est de rassurer le participant quant aux intentions du chercheur et de l'informer de ce qui est attendu de lui au cours de l'entretien.

Dans la seconde partie, le participant explique le contexte de la migration à laquelle il a participé. C'est à cette occasion qu'il présente l'organisation propriétaire du système informatique migré, en apportant des informations telles que la taille de l'équipe de développement ou les motivations qu'avait l'organisation à adopter l'informatique en nuage. Cette partie est informelle, non dirigée. Son but est de fournir au chercheur les informations nécessaires au suivi de l'entretien. En outre, cette partie permet d'établir des données démographiques utiles pour estimer la diversité des participants.

Enfin, dans la troisième partie, les deux interlocuteurs discutent des exigences de la migration. Pour ce faire, le chercheur pose des questions d'entretien ouvertes pour diriger la discussion. Ces questions sont tirées d'un ensemble préétabli, et elles sont posées dans le même ordre pour tous les participants. Ces questions étant ouvertes, il est possible que le participant s'écarte du sujet ; le chercheur peut alors poser des questions supplémentaires pour recentrer la discussion sur le sujet de l'entretien. Par ailleurs, le participant peut évoquer un sujet pouvant laisser penser qu'un type d'exigences a été élicité dans la migration et n'avait pas été envisagée par le chercheur ; charge à ce dernier de poser des questions supplémentaires pour amener le participant à développer ce sujet.

Questions d'entretien

Notre guide d'entretien compte dix questions. Nous avons limité le nombre de questions afin d'avoir des entretiens d'une durée raisonnable. Elles sont listées dans la table 5.1.

Ces questions ont été choisies en reposant sur plusieurs sources bibliographiques et à diverses fins, que nous présentons dans les paragraphes suivants.

Pratiques pour l'élicitation des exigences En premier lieu, la partie semi-dirigée de l'entretien débute par les questions Q_1 , Q_2 et Q_3 avec lesquelles nous voulions amener le participant à se remémorer l'étape d'élicitation des exigences pour le système à migrer. L'intention de ces questions était de laisser le participant mettre en avant les exigences les plus importantes qu'il a dû satisfaire, en particulier avec la question Q_1 . La question Q_2 se concentre sur les exigences du système avant sa migration ; étant donné qu'elles devront être satisfaites également après

la migration. Quant à la question Q_3 , elle interroge la satisfaction des exigences avant la migration : si elles n'étaient pas satisfaites avant, peut-être que la migration devait permettre de les satisfaire.

Utilisateur du système informatique Ensuite, la question Q_4 aborde l'importance des utilisateurs du système informatique. En effet, leur nombre et la fréquence de leur utilisation du système informatique va amener l'environnement infonuagique à s'adapter, grâce à son élasticité. De son côté, l'élasticité est une donnée importante à prendre en compte dans l'estimation des coûts de l'environnement et de ses performances (au sens large : par exemple, la latence de réponse aux requêtes et les impacts environnementaux). En outre, l'organisation a peut-être conclu un accord avec ces clients, un *SLA*, ce qui l'engage à sélectionner l'environnement infonuagique de telle manière que ce *SLA* soit respecté.

Exigences propres à la migration Tandis que les questions Q_1 à Q_3 s'intéressaient à l'existant, la question Q_5 aborde les nouvelles exigences qui viennent avec la migration infonuagique. En effet, la migration a pu être motivée par un nouveau besoin, ou demande de prendre en compte des exigences qui n'avaient pas lieu d'être dans un contexte autre que l'informatique en nuage.

Types d'exigences élicitées Quant aux questions Q_6 , Q_7 , Q_8 , Q_9 et Q_{10} , elles interrogent l'existence de certains types d'exigences dans le corpus d'exigences élicitées pour la migration. Les types d'exigences que nous avons sélectionnés dans ces questions ont plusieurs sources.

D'abord, la question Q_6 interroge les aspects de la qualité de service qui ont donné lieu à des exigences. En effet, de nombreux travaux de recherche ont abouti à des méthodes de sélection de l'environnement qui optimisent certains aspects de la qualité de service ; il s'agissait ici de constater si ces méthodes auraient pu être envisagées ou si elles ont été mises en œuvre.

À propos de la question Q_7 , dont le sujet est l'efficacité environnementale du système, elle nous semblait intéressante étant donné l'essor des préoccupations écologiques dans la dernière décennie : dans une synthèse publiée en 2022, l'INSEE affirme que près de 40% des français sont particulièrement préoccupés par le changement climatique en 2020, contre un peu plus de 15% en 2010 (INSEE, 2022). En particulier pour l'informatique en nuage, la population pourrait être sensible aux émissions de gaz à effet de serre liées à la fabrication et l'alimentation de l'infrastructure d'un *IP*. Par conséquent, nous nous demandions si, à l'occasion d'adopter un nouvel hébergement pour leur système informatique, les organisations tenaient compte de ces préoccupations dans la sélection de l'environnement.

Enfin, certains types d'exigences ayant donné lieu à des questions sont dérivés de facteurs

N°	Question d'entretien
Q ₁	Comment avez-vous analysé les composants du système à migrer ? Quelles étaient les informations importantes à extraire ?
Q ₂	Sous quelle forme avez-vous pu consulter les exigences auxquelles se conformait le système avant la migration ? De quelles exigences s'agissait-il ?
Q ₃	Avez-vous pu vérifier que le système satisfaisait ses exigences avant la migration ? Si oui, comment avez-vous procédé et qu'en avez-vous conclu ?
Q ₄	La façon dont l'utilisateur se sert du système était-elle un élément important à capturer ? Si oui, comment avez-vous procédé ?
Q ₅	Comment avez-vous élicité les exigences propres à la migration infonuagique ?
Q ₆	Avez-vous élicité des exigences vis-à-vis de la qualité de service ? Si oui, quels aspects ?
Q ₇	Avez-vous élicité des exigences vis-à-vis de l'efficacité environnementale du système ? Si oui, quels aspects ?
Q ₈	Avez-vous élicité des exigences vis-à-vis du coût de la main-d'œuvre qui effectue la maintenance opérationnelle du système ?
Q ₉	Avez-vous élicité des exigences vis-à-vis du coût de l'environnement infonuagique ? Si oui, comment étaient-elles exprimées et à quelle granularité (p. ex. pour le système entier, par unité fonctionnelle) ?
Q ₁₀	Avez-vous élicité des exigences vis-à-vis des adaptations à apporter au système informatique ?

TABLE 5.1 – Liste des questions d'entretien

d'adoption que nous avons listé dans la table 3.1. Ainsi la question Q₈ renvoie à la *facilité d'usage* et la question Q₉, à la *réduction des coûts*. Il s'agit des facteurs les plus fréquemment reportés dans les travaux que nous avons étudiés. Enfin, la question Q₁₀ réfère à plusieurs facteurs d'adoption : l'*auto-efficacité* et la *rapidité d'accès*; il s'agit de facteurs d'adoption lié à des problématiques organisationnelles.

5.2 Corpus

Nous avons mené onze entretiens auprès d'employés de la société Stack Labs. Il s'agit de consultants qui sont intervenus auprès de diverses organisations en France pour les accompagner dans leur adoption de l'informatique en nuage. Dans la deuxième partie de chaque entretien, nous leur avons demandé de se présenter ainsi que le contexte de leur migration; un résumé de ces informations démographiques est récapitulé dans la table 5.2.

Le participant P₉ a effectué une migration dans une entreprise qui propose un service de *monétisation de l'audience* à destination de sites Web et applications de téléphone portable pour qu'ils génèrent des revenus en fonction de leur fréquentation (nombre de visiteurs, profils des

N°	Secteur d'activité	Rôle	Exp. (années)
P_1	Imagerie satellitaire	Responsable de projet	18
P_2	Imagerie satellitaire	Architecte de systèmes infonuagiques	10
P_3	Imagerie satellitaire	Ingénieur des données	17
P_4	Agriculture	Développeur	19
P_5	Industrie nucléaire	Opérateur de systèmes informatiques	4
P_6	Autorités locales	<i>Cloud Enabler</i>	16
P_7	Commerce en grande surface	<i>DevOps</i>	1
P_8	Commerce en grande surface	Responsable de projet	8
P_9	Monétisation de l'audience	<i>Cloud Enabler</i>	15
P_{10}	Ministère	Opérateur de systèmes informatiques	1
P_{11}	Santé	<i>DevOps</i>	8

TABLE 5.2 – Informations démographiques des participants à l'étude

visiteurs). Le participant P_2 est un *architecte de systèmes infonuagiques* : il a pour rôle de sélectionner l'environnement infonuagique ; tandis que le participant P_3 est *ingénieur des données* (en anglais : *Data Engineer*) : il modélise les données de l'organisation et s'en sert pour effectuer des analyses (p. ex. analyser des données satellitaires pour aider les agriculteurs à minimiser les épandages de pesticides). En outre, deux appellations pour des rôles n'ont pas été traduites : *Cloud Enabler* et *DevOps*. D'un côté, les participants P_6 et P_9 sont *Cloud Enabler* (littéralement *Activateur de nuage informatique*). Ils accompagnent l'adoption de l'informatique en nuage dans une organisation sur le long terme, ce qui inclut — sans s'y limiter — la formation du personnel, le choix de la stratégie de migration, la sélection de l'environnement. De l'autre côté, les participants P_7 et P_{11} se sont présentés comme *DevOps*, du nom de la méthodologie éponyme : ils interviennent à la fois sur le développement et sur la maintenance opérationnelle de systèmes infonuagiques, et mettent en place des outils et des pratiques pour accélérer les cycles de développement.

Pour finir, nous estimons être parvenus à diversifier les profils des participants d'après nos critères, conformément aux recommandations de McCracken (1988). En effet, les migrations évoquées dans les entretiens ont eu lieu dans des organisations de tailles variées et dans divers secteurs. Suite aux entretiens, nous notons que la taille de l'organisation est moins importante que la taille des équipes qui développent et administrent le système informatique pour comprendre les migrations. En effet, certaines migrations rapportées ont eu lieu dans de très grandes entreprises d'envergure internationale, et le système informatique à migrer était pourtant développé et administré par une même équipe de quatre personnes ; cette taille réduite de l'équipe a posé des contraintes sur la sélection de l'environnement tandis que la grande taille de l'organisation, aucunement. En outre, les participants ont occupé divers rôles techniques et

fonctionnels ; et ils ont une expérience de l'industrie variant d'une année d'expérience à près de vingt ans, quoique la plupart d'entre eux ont plus de dix ans d'expérience de l'industrie, ce qui devrait témoigner d'un certain recul sur les sujets d'importance quant aux migrations.

5.3 Analyse des entretiens

Afin d'extraire les exigences de haut niveau des entretiens, nous avons procédé inductivement, c'est-à-dire que nous avons identifié les thèmes apparaissant dans les entretiens au fur et à mesure.

Pour ce faire, nous avons mis en œuvre la technique de « *découpage et tri* »² suggérée par RYAN et BERNARD (2003). En outre, nous avons analysé directement les enregistrements, sans les avoir préalablement transcrit ; cependant, d'après FARLEY, HURLEY et AITKEN (2020), cela ne devrait pas aboutir à des résultats significativement différents.

Ainsi, nous avons écouté chaque enregistrement pour en extraire les phrases qui témoignent d'une exigence qui a été prise en compte pour sélectionner l'environnement infonuagique, puis avons étiqueté ces phrases afin d'en conserver l'essentiel. Par exemple, nous avons extrait la phrase suivante de l'entretien avec P_5 :

« [...] ils voulaient surtout que leur système reste en France [...] »

Cette phrase témoigne, en effet, d'une exigence quant à l'hébergement du système, d'où l'étiquette : « *Centre informatique en France* ».

Une fois l'entièreté du corpus analysée, nous avons rassemblé les étiquettes qui nous semblaient liées. Les groupes d'étiquettes ont formé les thèmes qui sont apparus dans les entretiens : les exigences de haut niveau. En reprenant l'exemple, nous avons trouvé d'autres étiquettes très similaires, en cela que seul le pays diffère, telles que « *Centre informatique en Chine* » ; il nous semble évident que ces étiquettes fassent partie du même thème. Nous les avons rassemblées avec d'autres étiquettes ayant trait aux lois que suivent le fournisseur de services plutôt qu'au centre informatique, par exemple « *Fournisseur de services sous législation européenne* » ou « *Fournisseur de services pas sous législation étasunienne* ». En effet, toutes ces étiquettes apparaissent dans un même contexte : des lois posent des contraintes sur l'hébergement de certains logiciels ou données. Ces lois protègent les citoyens et le patrimoine des États, d'où le nom apposé à ce thème : la *souveraineté numérique*.

2. Dans le texte : « *Cutting and Sorting* ».

Traitement des données manquantes

Au cours des entretiens, nous avons constaté l'absence dans le discours d'informations que nous savions exister, mais que les participants n'ont pas mentionné. En effet, à de nombreuses reprises nous avons discuté des décisions prises lors de la migration sans les relier à une exigence de la migration.

Une telle situation n'est pas étonnante. BOGDAN et TAYLOR (1975) expliquent en effet qu'un participant peut éviter des sujets, intentionnellement ou pas, et qu'il convient de rester alerte à ces sujets car cet évitement constitue une information en soi. L'absence de données dans les entretiens peut notamment signifier que le participant n'en a pas connaissance, qu'il ne fait pas confiance au chercheur ou que le participant pense que ces données sont évidentes (RYAN et BERNARD, 2003). Dans notre situation, nous pensons que les rôles techniques qu'occupent la majeure partie de nos participants les amènent à davantage considérer des problèmes à résoudre, que des besoins à satisfaire. Pour nous, cela explique l'emphasis mise sur la description de problèmes vécus par les équipes avant la migration, et comment leurs décisions pour la migration ont permis de résoudre ces problèmes; ceci au détriment des exigences, qui sont plutôt l'apanage des rôles fonctionnels.

Afin d'identifier malgré tout ces exigences, nous avons procédé en analysant les expressions en relation avec (i) les problèmes rencontrés avant la migration — ils sont, en quelques sortes, la justification des exigences dans le contexte de la migration — et avec (ii) les conséquences des exigences sur la sélection de l'environnement. À partir de ces deux types d'expression, nous avons été capables d'identifier l'exigence dans de nombreux cas. Par exemple; P_7 a relaté les faits suivants :

« Ils utilisaient plusieurs plateformes, certaines [sur site], d'autres sur [nuages] publics et privés, et en plus c'était à chaque fois des [technologies] différentes [...]. C'était l'enfer pour les équipes Ops [...] du coup le but de la migration était de tout rassembler sur une seule plateforme et un seul gestionnaire de conteneurs pour tous les projets [de l'organisation] [...] »

Cet extrait explique que (i) l'hétérogénéité des solutions techniques des projets de l'entreprise rendaient la mission des opérateurs difficile et que, par conséquent, la migration a consisté à (ii) imposer une seule plateforme pour tous les projets. Bien que l'exigence qui a amené à cette solution n'ait pas été présentée, ces deux informations nous ont permis de conclure : l'exigence était de réduire les efforts pour maintenir les systèmes d'information.

5.4 Résultats

L'analyse des entretiens nous a permis d'identifier onze exigences de haut niveau qui peuvent être considérées dans une migration infonuagique et qui ont des conséquences sur la sélection de l'environnement. Elles sont présentées dans les paragraphes suivants et sont ordonnées par ordre décroissant d'occurrence dans les entretiens. Nous y illustrons chaque exigence de haut niveau par un résumé d'entretien à son sujet ; d'autres sont disponibles dans l'annexe 8.3.

Minimiser les efforts de maintenance opérationnelle (E_1)

Une préoccupation évoquée dans tous les entretiens est de réduire autant que possible les efforts de maintenance opérationnelle, c'est-à-dire les activités visant à assurer le bon fonctionnement du système informatique une fois qu'il est en ligne. Cette exigence est apparue dans les migrations rapportées car l'organisation voulait minimiser la masse salariale en lien avec la maintenance opérationnelle, ou pour soulager une équipe d'une partie de ses tâches.

Avec l'informatique en nuage, il est en effet possible de déléguer au fournisseur de service une partie des tâches liées à la maintenance opérationnelle. Certains services infonuagiques prennent plus de tâches en charge que d'autres. Par exemple, si le système informatique qu'une organisation migre comporte un système de gestion de base de données (*SGBD*), plusieurs choix d'hébergement s'offrent pour la base de données. Un premier choix pour l'organisation serait d'exécuter le *SGBD* sur une machine virtuelle (*IaaS*), auquel cas elle aura à sa charge les mêmes tâches que si le système était hébergé sur site. Sinon, elle peut opter pour un service de base de données à la demande (*PaaS*). Dans ce cas, le fournisseur de service prend à sa charge diverses tâches, comme de s'assurer qu'il demeure suffisamment d'espace libre sur le disque, mettre à jour le *SGBD* ou mettre en oeuvre une stratégie de réplication des données. Ainsi, l'organisation aura délégué une partie de ses tâches de maintenance opérationnelle au fournisseur de services, mais cela peut s'accompagner de contraintes. Une contrainte évidente est que la plupart des *SGBD* ne sont pas fournis *à la demande* par un service, d'autant plus que de nombreux services de stockage de données sur les nuages publics utilisent des protocoles propriétaires, non-interopérables avec des *SGBD* disponibles hors des nuages publics. Ainsi, sélectionner un service de base de données à la demande peut nécessiter d'adapter le système informatique pour qu'il utilise un autre *SGBD*, ce qui demande notamment la connaissance des équipes de ce *SGBD* et des tâches de développement. Cela étant, cet effort n'est pas toujours requis (s'il existe un service qui déploie ce *SGBD*).

Entretien avec P_4

Avant la migration à laquelle a participé P_4 , de nombreuses procédures étaient effectuées manuellement. Dans les meilleurs cas, des scripts existaient et les opérateurs les exécutaient sur leur ordinateur ; dans le pire des cas, ces opérateurs exécutaient ces procédures étape après étape. Ce mode de fonctionnement était évidemment chronophage et source d'erreurs humaines. Ainsi, la migration avait pour but d'industrialiser les processus de l'organisation.

Pour ce faire, P_4 a utilisé un *PaaS* déployant Apache Workflow^a à la demande, une plateforme de gestion des flux de travail. En sélectionnant ce service, l'exécution des procédures ne dépend plus des ordinateurs des opérateurs et ces derniers se concentrent sur l'exploitation de leurs résultats. En revanche, cela a nécessité des développements pour porter les scripts existants sur Apache Workflow et automatiser les autres procédures.

a. Page Web de présentation de Apache Workflow : <https://airflow.apache.org>.

Exemple fil rouge

Afin de minimiser la maintenance opérationnelle pour le stockage des données satellitaires, l'agence spatiale peut opter pour un *PaaS* de stockage de documents tel que Google Cloud Storage. En effet, cela lui ôte diverses responsabilités telles que de sécuriser ce stockage ou d'assurer que l'infrastructure dispose toujours de suffisamment d'espace de stockage. En revanche, il est très probable qu'il faille adapter les logiciels du système informatique pour qu'ils utilisent ce service, ce qui peut se concrétiser par exemple en utilisant une bibliothèque cliente de ce service.

D'autres composants pourraient être également modernisés, par exemple en utilisant des services de conteneurs à la demande pour l'exécution des composants logiciels appartenant à l'agence spatiale. Dans ce cas, un processus de réarchitecture du système peut être requis afin d'utiliser de tels services (p. ex. s'il s'agit d'un système monolithique).

Minimiser le coût de l'environnement infonuagique (E_2)

Les coûts récurrents de l'environnement infonuagique sont un sujet fréquemment évoqué dans les organisations. En effet, il s'agit pour certaines d'entre elles de sommes d'argent très importantes.

Les entretiens montrent qu'il s'agit davantage d'une direction, d'un critère d'optimisation. Aucun participant n'a identifié de budget alloué pour l'environnement infonuagique dans leur

migration. À ce sujet, nous pouvons supposer que cette observation est liée à la profession des participants : ils sont tous des consultants. Dès lors, nous avons deux hypothèses. La première est qu'il n'est pas dans l'intérêt de l'organisation cliente du consultant de révéler son budget, car sinon la solution proposée pourrait utiliser complètement ce budget alors qu'une solution moins onéreuse pourrait exister. La seconde est que l'organisation, étant cliente du consultant, manque d'expertise quant au coût des nuages publics, et ne se juge pas pertinente à définir un budget pour un environnement infonuagique.

Si de nombreux entretiens évoquent l'importance de minimiser les coûts, seul P_9 en a fait une priorité.

Entretien avec P_9

L'organisation pour laquelle P_9 est intervenu met en place une nouvelle plateforme pour chacun de ses clients. En outre, l'organisation voulait éviter qu'une grande utilisation du système par un client impose une dégradation de la performance pour les autres clients. Pour ce faire, chaque plateforme est hébergée sur une partie de l'infrastructure isolée des autres. Cette solution était très coûteuse :

« Pour chaque projet, ou client, ils devaient déployer une nouvelle plateforme, ce qui veut dire que, sur site, ils mettaient en place un serveur, ou deux, ou X, ça dépend de la charge. Évidemment, [l'informatique en nuage] colle à la situation, surtout que leur infrastructure [sur site] leur coûtait extrêmement cher [...] »

La migration avait donc pour but de réduire le coût d'hébergement du système. Surprenamment, cela n'a pas eu de conséquence sur la sélection de l'environnement, car P_9 a fait face à des résistances au changement au sens de l'équipe de développement :

« Nous[, l'équipe DevOps] avons eu affaire à des développeurs dogmatiques, ils ne voulaient pas utiliser de [PaaS]. Rien que de passer sur [un IaaS], ça a été difficile pour eux de l'accepter. »

Par conséquent, P_9 estime que la solution choisie est un compromis sur l'exigence de minimiser le coût de l'environnement afin qu'elle soit acceptable du point de vue de l'équipe de développement. En effet, le développement et l'administration de *IaaS* ressemble à ce que cette équipe a connu avant la migration. Cependant, P_9 aurait préféré employer des services *sans-serveur*, qui auraient selon lui grandement diminué les coûts tout en isolant les clients les uns des autres.

Exemple fil rouge

Étant donné les grands volumes de données qui transitent vers le système informatique du segment sol et en son sein, ajouté au grand nombre de ressources requises pour effectuer des transformations, il est normal pour l'agence spatiale de s'inquiéter du coût de l'environnement.

Il lui faudra analyser l'utilisation du système informatique pour déterminer le type de service adéquat pour minimiser ce coût.

Maximiser la fiabilité du système (E_3)

Dans plusieurs entretiens — ceux de P_1 , P_2 , P_3 et P_4 — l'organisation a initié une migration suite à des incidents qui ont eu des conséquences sur la satisfaction de ses clients.

En effet, ces organisations n'avaient pas de politique de *maintien en condition opérationnelle* (MCO). Il s'agit de l'ensemble des mesures permettant de maintenir le fonctionnement du service tout au long de son cycle de vie. Or, de nombreux incidents peuvent survenir. Ils sont d'origines diverses : des aléas (p. ex. un tremblement de terre, un cyclone), des incidents d'origine humaine (p. ex. un incendie criminel des locaux, débranchement de câble par inadvertance) ou liés à l'usure de l'infrastructure matérielle.

Afin de réagir efficacement suite à un tel incident, les organisations mettent en place un *plan de reprise d'activité* (PRA). Ce dernier détaille les procédures nécessaires à la remise en état de fonctionnement du système. Cependant ces procédures dépendent de l'incident : une procédure adaptée pour réagir à une coupure de courant ne sera pas adaptée pour réagir à un incendie des locaux. Aussi, une organisation qui héberge son système informatique dans ses locaux est impuissante face à certains incidents, c'est pourquoi une organisation peut être incitée à adopter l'informatique en nuage.

En effet, les nuages publics sont typiquement distribués sur plusieurs *zone de disponibilité*, indépendantes géographiquement les unes des autres, qui correspondent chacune à un centre informatique. De plus, ils automatisent la réplication des ressources sur plusieurs centres informatiques, ce qui simplifie la mise en place d'un PRA et en réduit le coût. Par exemple, les *IaaS* de plusieurs fournisseurs de services permettent la définition de *groupes de machines virtuelles* qui contiennent plusieurs machines virtuelles identiques et distribuées sur plusieurs zones de disponibilité. De même, les classes de stockage des services de stockage de document englobent plusieurs zones de disponibilité et ont une stratégie de réplication des données pour éviter que la compromission d'une zone entraîne une perte de données. Il est donc possible de définir des PRA couvrant davantage d'incidents sur un nuage public que sur site.

D'après les entretiens, les organisations qui ont des exigences vis-à-vis de la fiabilité fa-

vorisent les *PaaS sans-serveur*, car ils permettent de facilement redéployer des ressources dans divers centres informatiques et sans interruption significative du service.

Entretien avec P_2

L'organisation dans laquelle est intervenue P_2 n'avait pas mis en place un *PRA* suffisamment robuste. Par conséquent, cela prenait un temps considérable pour redéployer le système quand un incident compromet l'infrastructure :

« Le but [de la migration], c'était de rendre le système robuste [...] Notre premier objectif, ça a été de le rendre fiable parce qu'à la base, tout reposait sur quelques machines et un ingénieur qui administrait le tout. [...] C'était difficile pour eux de récupérer suite à un incident. »

Par conséquent, P_2 a favorisé l'utilisation de services infonuagiques *sans-serveur*, car il est aisé de redéployer ces derniers dans divers centres informatiques, sans interruption importante du service.

Minimiser la latence de réponse aux requêtes (E_4)

La recherche scientifique a exploré la sélection d'un environnement infonuagique de manière à minimiser la latence du réseau. Néanmoins, les entretiens ont plutôt mis en lumière le besoin de minimiser la latence perçue par l'utilisateur du système informatique : cela inclut la latence du réseau entre l'utilisateur et les ressources de l'environnement, mais également, et entres autres, la rapidité de traitement des calculs et les transferts qui ont lieu à l'intérieur de l'environnement.

Cette exigences a influencé les migrations de diverses manières, qui incluent le juste dimensionnement du système pour qu'il effectue les calculs demandés le plus rapidement possible, la réplication du système dans plusieurs centres informatiques afin de réduire la latence du réseau, l'utilisation de l'élasticité afin de délivrer un service constant peu importe le nombre de requêtes simultanées, et l'optimisation des logiciels développés par l'organisation.

Entretien avec P_5

Pour migrer une forge logicielle, P_5 devait trouver un compromis entre les coûts et les performances de calcul, c'est pourquoi il a opté pour une solution basée sur un *IaaS* qui déploie des machines physiques, sans virtualisation (ce sont des services dits « *baremetal* » en anglais) :

« Nous avons deux possibilités : soit utiliser un Kubernetes [infogéré], soit

l'[infogérer] nous-même. On a fait le second choix pour la [performance], parce que les machines derrière le Kubernetes [infogéré] n'avaient pas les caractéristiques que nous voulions, ou alors ça aurait été trop cher [...] »

Minimiser le besoin de nouvelles compétences (E_5)

Lors d'une migration, divers choix sont pris dans la sélection de l'environnement et peuvent entraîner des adaptations à apporter aux logiciels et données du système informatique. Cela exige éventuellement de nouvelles compétences, que ce soit de développement ou d'administration du système, aux équipes de l'organisation. Or, certaines organisations désirent limiter le nombre de nouvelles compétences à acquérir. En effet, la formation peut coûter de l'argent et nécessite du temps pendant lequel la performance des employés est dégradée.

Dans les entretiens, cette exigence a été évoquée par des participants qui ont migré des systèmes développés et administrés par des équipes réduites ou qui comptent une grande part de membres spécialisés dans un autre domaine que le génie logiciel. Ces équipes manquent de temps pour se former et ses membres ont peu d'intérêt à l'acquisition de certaines compétences étrangères à leur domaine. En outre, leur organisation n'a pas la volonté ou les moyens d'embaucher de nouveaux membres pour ses équipes ni se passer de la connaissance du métier et de l'expérience des membres en place.

La satisfaction de cette exigence dépend avant tout des compétences disponibles au sein des équipes. Par exemple, si un membre a eu une expérience professionnelle avec un certain fournisseur de services par le passé, alors ce fournisseur de services sera favorisé. En outre, elle encourage à minimiser le nombre d'adaptations à apporter au système informatique. Ainsi, si un logiciel est écrit dans un langage, l'environnement sélectionné devrait ne pas exiger du logiciel qu'il soit réécrit dans un autre langage.

Entretien avec P_2

P_2 est intervenu dans une équipe très réduite : elle ne compte que quatre personnes, responsables à la fois du développement et de la maintenance opérationnelle de leur système. Parmi ces quatre personnes, l'une d'entre elles est un développeur qui contribue à plusieurs projets dans l'organisation ; les trois autres personnes sont des *Data Scientists*, des spécialistes de la gestion et l'analyse de données massives. Ces derniers développent le système en Python, un langage familier des *Data Scientists*, mais ils ne sont en revanche pas des spécialistes du développement et de l'administration de systèmes. Ainsi, P_2 a indiqué :

« Ça devait être maintenu par eux, en termes de développement [...] Par exemple, leurs scripts étaient écrits en Python, et on ne pouvait pas leur demander de les réécrire en Go, puisque les développeurs étaient des Data Scientists. Ils connaissent Python, c'est extrêmement utilisé dans leur domaine, et ça aurait trop difficile de passer à un autre langage du jour au lendemain. »

Par conséquent, l'environnement sélectionné a permis de conserver Python comme langage de développement. À noter que Python étant un langage très répandu, P_2 souligne que la contrainte n'a pas demandé de faire de compromis pour la satisfaire car de nombreux services l'acceptent ; c'eût été plus difficile avec un langage moins utilisé dans l'industrie.

Assurer la souveraineté numérique (E_6)

La souveraineté numérique a été évoquée à plusieurs reprises et s'explique de plusieurs manières.

D'une part, elle est imposée par les lois de régulation des données. Un exemple bien connu en Union Européenne est le *Règlement Général sur la Protection des Données*³ qui, notamment, impose diverses contraintes (p. ex. limites géographiques, transparence) pour le stockage et le traitement des données personnelles de citoyens européens. Des lois similaires au *RGPD* existent dans d'autres pays de par le monde (p. ex. la Chine ou la Russie).

D'autre part, l'existence de lois intrusives dissuade l'utilisation de certains fournisseurs de services. En particulier, les participants ont relevé la loi *CLOUD Act* aux États-Unis d'Amérique qui permet aux instances de justice étasuniennes d'obtenir l'accès à des données stockées par un fournisseur de services étasunien partout dans le monde. Pour cette raison, plusieurs participants ont rapporté le souhait de l'organisation de ne pas faire héberger leur système informatique par un fournisseur de services étasunien.

Les exigences liées à la souveraineté numérique restreignent les fournisseurs de services envisageables, soit parce qu'ils ne respectent pas la bonne législation, soit parce qu'ils ne disposent pas de centre informatique dans certaines régions du monde.

Entretien avec P_6

L'organisation de laquelle P_6 a migré le système informatique étant liée aux autorités locales (p. ex. mairies, communautés de communes), elle avait pour exigences de confier

3. Présentation du *RGPD* par la CNIL : <https://www.cnil.fr/fr/rgpd-de-quoi-parle-t-on>.

ses données à un fournisseur de services sous législation française.

Cependant, un fournisseur de services étasunien convenait parfaitement aux autres exigences de l'organisation. Ainsi, P_6 a proposé un compromis : chiffrer les données stockées par ce fournisseur de services étasunien sans lui confier la clé de chiffrement :

« Ils voulaient stocker leurs données sur un [nuage] souverain, donc on leur a proposé un compromis : ils hébergent leurs données (chiffrées) sur [un fournisseur de services étasunien] et la clé de chiffrement, sur [un fournisseur de services français]. »

Exemple fil rouge

Les images satellitaires peuvent contenir des informations sensibles, cruciales pour les États. Elles peuvent, par exemple, contenir des vues sur des bases militaires qui doivent demeurer secrètes pour le grand public et les autres États. Pour cette raison, diverses mesures doivent être mises en place afin d'assurer que ces informations ne soient accessibles qu'aux personnes habilitées et qu'elles ne soient pas stockées ou transmises en des points du monde qui mettent en péril la confidentialité de ces informations.

Maximiser la sécurité (E_7)

Étrangement, peu d'entretiens ont mentionné la sécurité comme une exigence qui dirige la sélection de l'environnement infonuagique, alors que la sécurité dans l'informatique en nuage est un thème de recherche qui a donné lieu à de nombreux travaux. Une hypothèse est que les organisations en général estiment qu'adopter l'informatique en nuage est un moyen de satisfaire leurs exigences de sécurité, sans considération de l'environnement sélectionné.

Entretien avec P_6

La migration de P_6 a été réalisée en plusieurs étapes. D'abord, le système a été migré sur un environnement constitué uniquement de *IaaS*, puis plusieurs phases de modernisation ont été menées pour tirer profit de services infonuagiques plus intéressants. Dans ces phases de modernisation, P_6 a exclu d'utiliser plusieurs services infonuagiques car cela aurait eu des répercussions sur la topologie du réseau du système. Or, cette topologie a été établie et validée lors de la première phase comme étant suffisamment sûre. Cette sécurité est en effet nécessaire pour ce projet : elle est exigée par l'État français dans le cadre du *programme de protection du potentiel scientifique et technique de la*

Nation^a qui exige la mise en oeuvre de protections contre l'espionnage et le piratage.

a. Protection du potentiel scientifique et technique de la Nation : <http://www.sgdsn.gouv.fr/missions/protection-du-potentiel-scientifique-et-technique-de-la-nation/>.

Exemple fil rouge

Pour les mêmes raisons de sensibilité des données manipulées par l'agence spatiale, il est nécessaire d'assurer une haute sécurité du système informatique. En effet, les informations en question peuvent être de grande valeur pour un État concurrent (espionnage, sabotage) et le système informatique est donc sujet à des cyberattaques.

Maximiser ou minimiser l'adhérence au fournisseur de services (E_8)

Malgré l'existence de nombreux travaux de recherche visant à limiter les conséquences de l'enfermement propriétaire, les entretiens nous ont indiqué que l'industrie a suivi une autre voie. En effet, deux approches semblent s'imposer. D'un côté, certaines organisations refusent l'enfermement propriétaire pour demeurer libre de changer d'hébergement sans surcoût. Cela limite la sélection de services infonuagiques : ne sont conservés que les plateformes pouvant être déployées sur site et par divers fournisseurs de services. De l'autre côté, des entreprises acceptent l'enfermement propriétaire dans un compromis avec divers critères, par exemple la simplicité d'utilisation. Parmi ces entreprises, certaines vont plus loin en exigeant l'utilisation des services d'un fournisseur de services en particulier. Cela peut être dû par exemple à la confiance accordée à ce fournisseur de services ou à l'existence d'un écosystème incluant le nuage informatique et d'autres produits.

Entretien avec P_5

L'entreprise dans laquelle P_5 est intervenu avait pour politique de minimiser l'enfermement propriétaire. En effet, ils voulaient pouvoir changer de fournisseur de services avec un effort minimal en cas de changement des tarifs ou de conditions d'utilisation. Pour cela, ils ont exclusivement utilisé des logiciels utilisables par ailleurs, tel que le SGBD PostgreSQL ou Kubernetes^a :

« Nous avons choisi Kubernetes parce que c'est open source et un standard dans l'industrie [...] ça permet à l'entreprise d'être plus indépendante d'autres entreprises. »

a. Présentation de Kubernetes : <https://kubernetes.io/docs/concepts/overview/>.

Entretien avec P_1

Le choix de Google Cloud était évident pour l'entreprise conseillée par P_1 puisqu'elle utilisait déjà d'autres produits de l'entreprise Google.

Minimiser le coût de la migration (E_9)

Certaines organisations ont des contraintes quant à l'exécution de la migration et, en particulier, quant au coût de la migration. Ce coût est celui du personnel qui intervient dans la migration.

Il est possible que cette exigence soit liée à la situation de l'organisation. Ainsi, nous nous attendons à ce qu'une petite entreprise ou une association soit davantage vigilante au coût de la migration qu'une grande entreprise. Cependant, nous devons souligner que la profession des participants à l'enquête, qui étaient tous des consultants, a pu influencer les organisations. En effet, il n'est pas rare qu'une organisation désireuse de migrer son système informatique demande une estimation à plusieurs sociétés de conseil afin de les mettre en concurrence ; dans cette situation, proposer une migration moins onéreuse est un point fort pour remporter un contrat.

Entretien avec P_2

Comme expliqué précédemment, P_2 a migré son système en utilisant un *PaaS* qui n'a pas demandé d'adaptation du système informatique. Aucune investigation n'a été menée pour déterminer s'il s'agissait de la solution la plus performante. Par exemple, il ne s'agissait peut-être pas de la solution la plus économe. Le critère de sélection, en outre de la délégation de préoccupation de maintenance opérationnelle au fournisseur de services, était de minimiser le nombre d'adaptations pour que la migration soit bon marché.

Par ailleurs, le reste du système, qui ne pouvait être déployé sur ce *PaaS*, a été hébergé sur des machines virtuelles (*IaaS*), car cela ne nécessitait pas d'adaptation.

Minimiser la durée de la migration (E_{10})

Les participants ont rapporté une autre contrainte quant à l'exécution d'une migration : minimiser sa durée. Nous l'avons surtout rencontré dans des projets de migration qui devaient aboutir avant une date donnée.

Nous soulignons qu'il ne s'agit pas de la même contrainte que de minimiser le coût de la migration, puisqu'il est ici envisageable d'allouer davantage de développeurs pour accélérer la

migration tout en satisfaisant d'autres exigences. Néanmoins, la conséquence de cette exigence de haut niveau est la même que E_9 : minimiser le nombre d'adaptations apportées au système informatique.

Entretien avec P_4

L'organisation dans laquelle P_4 a effectué une migration propose des services à destination des agriculteurs afin qu'ils surveillent la pousse des plantes dans leurs champs. Ainsi, ils peuvent adapter l'arrosage et les épandages. Cette organisation s'est spécialisée dans un certain type de culture, qui demande une attention particulière sur des fenêtres de quelques semaines, deux fois par an.

Pour cette raison, la migration devait être aboutie avant le début de la saison suivante :

« Comme leur activité est saisonnière, on devait finir la migration avant le début de la saison suivante. »

Par conséquent, ils ont abandonné des modernisations qui avaient été envisagées, mais qui n'auraient pas pu être implémentées dans le temps imparti. Par exemple, ils avaient l'intention d'utiliser un service de base de données à la demande (*PaaS*) qui aurait été moins onéreuse que d'héberger un *SGBD* sur une machine virtuelle, mais les adaptations que cela aurait entraîné auraient été trop longue à développer.

Minimiser les impacts environnementaux (E_{11})

Comme évoqué précédemment, les préoccupations environnementales sont importantes, au moins en France. En outre, l'efficacité écologique des systèmes d'information est une thématique de recherche qui existe depuis longtemps, avec par exemple en 2008, les propositions de A. J. CHEN, BOUDREAU et WATSON (2008) pour parvenir à concevoir des systèmes d'informations durables et écologiquement efficaces. Néanmoins, seul un entretien a mis en lumière une organisation qui tient compte des impacts environnementaux de son système informatique au moment de concevoir son hébergement.

L'informatique en nuage est, en soi, une opportunité de réduire l'empreinte environnementale des organisations, puisqu'il s'agit d'un modèle de mutualisation des infrastructures. Dans les nuages publics, différentes raisons qui ne sont pas liées à l'environnement incitent tous les rôles à diminuer leur empreinte environnementale. En effet, les fournisseurs d'infrastructure possèdent des infrastructures conséquentes dont ils peuvent diminuer la consommation électrique, et ils peuvent mettre en place une politique d'achat pour le matériel ; ces deux actions ayant pour but d'augmenter leurs marges. Les fournisseurs de services ont intérêt à satisfaire leurs usagers, c'est-à-dire fournir un service en respectant leur *SLA*, en utilisant l'infrastructure

la plus réduite possible : ils réduisent ainsi leurs paiements aux fournisseurs d'infrastructure. Enfin, les usagers doivent tirer profit de l'élasticité des services infonuagiques pour limiter les factures qu'ils règlent aux fournisseurs de services ainsi que leur empreinte d'utilisation de l'infrastructure des fournisseurs d'infrastructure.

Cela mis à part, force est de constater que les fournisseurs de services publics fournissent actuellement peu d'indicateurs permettant de discriminer des solutions sur des critères environnementaux. Il existe également peu de standard : chaque fournisseur de services fournit des indicateurs qui lui sont propres. Nous pouvons citer certains centres informatiques de Google Cloud qui sont étiquetés « *bas carbone* », ou Scaleway qui communique en continu le *PUE*⁴ de ses centres informatiques⁵.

Entretien avec P_8

Dans la migration à laquelle P_8 a participé, minimiser les impacts environnementaux était une exigence de premier plan :

« [...] ils avaient une autre préoccupation, écologique. Pour eux, c'était vraiment la chose la plus importante [...] Ils ne nous ont pas dit pourquoi; je pense que c'est pour leur image de marque ou bien c'est demandé par leurs actionnaires. »

Pour la sélection de l'environnement infonuagique, cette exigence a mené à la sélection d'un fournisseur de services et de centres informatiques « écologiques » : par exemple, alimentés par des énergies « bas carbone » (énergies renouvelables et énergie nucléaire), et dotés d'un refroidissement efficace. En outre, cela a encouragé la collocation des données et des traitements pour limiter l'utilisation du réseau.

5.5 Discussion

Dans cette section, nous proposons une discussion vis-à-vis de l'étude qualitative et de ses résultats. Dans un premier temps, nous discutons la validité de cette étude, puis nous analysons les résultats au regard des travaux de recherche précédents. Enfin, nous proposons des catégorisations de ces exigences de haut niveau avant de conclure ce chapitre.

4. *PUE* (en anglais : *Power Usage Effectiveness*) : une mesure standard de l'efficacité avec laquelle un centre informatique consomme de l'électricité.

5. Documentation de Scaleway sur la performance environnementale de ses centres informatiques : <https://www.scaleway.com/en/environmental-leadership/>.

5.5.1 Validité de notre démarche

Nous avons identifié plusieurs menaces à la validité externe de cette étude.

D'abord, le corpus pourrait être qualifié de restreint. Il ne compte effectivement que onze entretiens, tandis que certaines études qualitatives en sociologie peuvent reposer plus d'une centaine d'entretiens. Cependant, nous pensons que multiplier les entretiens n'aurait pas été utile. En effet, nous avons constaté qu'après le sixième entretien, seule une exigence de haut niveau a émergé de nos discussions. Ainsi, nous pensons que l'étude est proche de la saturation.

Ensuite, tous les participants ont comme point commun d'être des consultants auprès d'autres entreprises. Cela a pu avoir des conséquences sur leur compréhension des besoins de ces entreprises. Par exemple, nous avons relevé dans la section précédente une absence de budget pour l'environnement infonuagique, et nous pensons que cette absence résulte très justement de la position de consultant des participants. Ainsi, nous avons peut-être manqué des exigences dont auraient pu témoigner d'autres profils de participants.

Enfin, un seul codeur a analysé l'intégralité du corpus. De ce fait, les résultats peuvent avoir été influencés par ses connaissances et ses ressentis. Le même processus de codage devrait être mis en œuvre par d'autres personnes sur le corpus afin de diminuer l'impact de l'interprétation d'une seule personne, et aboutir à un consensus.

5.5.2 Discussion en rapport avec l'état de l'art

Facteurs d'adoption de l'informatique en nuage

Après avoir passé en revue les facteurs d'adoption de l'informatique en nuage, une hypothèse restée en suspens était qu'il existe peut-être un lien entre ces facteurs d'adoption et les exigences de la migration qu'ils motivent.

La teneur des entretiens ne permet pas de déterminer quels étaient les facteurs d'adoption pour chaque organisation. En effet, étant des consultants intervenus postérieurement à la décision d'adopter l'informatique en nuage, ils n'avaient pas nécessairement connaissance de ces facteurs d'adoption. En revanche, nous pouvons rapprocher les exigences et les facteurs d'adoption par lien sémantique. Par exemple, la *facilité d'usage* évoque la réduction de la charge de travail pour la maintenance opérationnelle, tout comme la *réduction des coûts* : un moindre effort nécessaire pour maintenir le système signifie que moins de personnel est dédié à cette tâche ; enfin, la *concentration sur le métier de l'organisation* a été évoquée dans plusieurs entretiens : comme l'organisation investit moins dans des préoccupations techniques, et en particulier la maintenance de l'infrastructure qui héberge le système informatique, alors elle peut investir plus largement dans son cœur de métier. En tenant compte de ces constats, nous concluons que ces facteurs sont liés à l'exigence E_1 , de minimisation de l'effort de maintenance

opérationnelle. Nous avons procédé de même avec les autres facteurs d'adoption identifiés dans l'état de l'art et avons répertorié les associations dans la table 5.3, à partir de laquelle nous faisons plusieurs observations.

D'abord, la majorité (sept exigences sur onze) sont associables à des facteurs d'adoption. Notons que l'association que nous faisons ne signifie pas que les organisations dans lesquelles sont intervenus les participants de l'enquête considéraient tel ou tel facteur d'adoption, seulement que nous trouvons vraisemblable qu'un facteur d'adoption qui a motivé une migration aie comme répercussion des exigences qui lui sont associées. Par exemple, il serait attendu d'une organisation qui adopte l'informatique en nuage pour sa *flexibilité* qu'elle aie des exigences sur l'agnosticisme de son système informatique vis-à-vis du fournisseur infonuagique (E_8), très justement pour être flexible et changer d'hébergement à faible coût financier et temporel. La possibilité que cette flexibilité soit perçue comme satisfaite peu importe l'environnement infonuagique sélectionné ne nous permet pas de conclure sans étude plus approfondie de cette question. En outre, nous notons une association particulière : celle de E_3 avec la *Dépendance à la qualité du réseau*, qui est le seul facteur d'adoption que nous avons recensé qui est négativement corrélé à l'adoption de l'informatique en nuage. En d'autres termes, les organisations peuvent renoncer à adopter l'informatique en nuage car les nécessités d'interagir avec le système informatique via l'Internet et de faire confiance au réseau du fournisseur de services leur semble trop contraignantes. Ainsi, il ne serait pas surprenant que des organisations conscientes de ces contraintes les mitigent en ayant des exigences pour la sélection de l'environnement infonuagique.

Ensuite, nous voyons que plusieurs facteurs d'adoption ne sont associés à aucune exigence. Nous l'expliquons par deux arguments. En premier lieu, nous constatons que certains de ces facteurs sont clairement liés aux aspirations d'un individu et non aux exigences d'une organisation (*Potentiel d'employabilité*, *Être averti des innovations technologiques*). De fait, ce n'est pas dans l'intérêt d'une organisation de sélectionner l'environnement infonuagique de manière à accroître l'employabilité des parties prenantes, il n'y a donc pas de raison que des exigences y soit liées. En outre, d'autres facteurs d'adoption font plutôt le constat d'une réalité au sein d'une organisation (*Taille et structure de l'organisation*, perception de l'*Utilité*), et non à un besoin. Finalement, il est pour nous évident que le facteur d'adoption *Compatibilité avec les exigences* ne soit pas associé à une exigence en particulier : une organisation adopte l'informatique en nuage et migre son système informatique si elle peut sélectionner un environnement compatible avec ses exigences. Pour nous, ce dernier point souligne la nécessité d'évaluer la satisfaction de ces exigences dès la conception, afin de permettre aux organisations de décider si elles adoptent ou non l'informatique en nuage.

Enfin, nous constatons que trois exigences (E_6 , E_9 et E_{11}) ne se trouvent associées à aucun

Exigence	Facteurs d'adoption de l'état de l'art
E_1	Facilité d'usage, Concentration sur le métier de l'organisation, Réduction des coûts
E_2	Réduction des coûts, Capacité de mise à l'échelle, Élasticité
E_3	Dépendance à la qualité du réseau
E_4	Utilisation efficiente de l'infrastructure, Capacité de mise à l'échelle, Élasticité, Dépendance à la qualité du réseau
E_5	Auto-efficacité
E_6	-
E_7	Sécurité
E_8	Interopérabilité, Flexibilité, Confiance accordée au fournisseur de services, Possibilité d'essai avant l'engagement
E_9	-
E_{10}	Rapidité d'accès, Pression compétitive
E_{11}	-
-	Utilité
-	Taille et structure de l'organisation
-	Potentiel d'employabilité
-	Être averti des innovations technologiques
-	Compatibilité avec les exigences

TABLE 5.3 – Correspondances entre les exigences identifiées et les facteurs d'adoption recensés dans l'état de l'art

facteur d'adoption. Si cela nous étonne de ne pas trouver de facteur d'adoption quant au coût de la migration (E_9), nous ne sommes pas surpris de ne pas en trouver vis-à-vis de la souveraineté numérique (E_6) et des impacts environnementaux (E_{11}). En effet, ce sont des thèmes apparus tardivement et qui n'intéressent pas forcément toutes les organisations. Par ailleurs, nous pensons que des facteurs d'adoption qui leur seraient associés seraient plutôt négativement corrélés avec l'adoption de l'informatique en nuage. En effet, cela semble illogique qu'une organisation adopte l'informatique en nuage pour des raisons de souveraineté numérique ; en revanche, une telle organisation devant adopter l'informatique en nuage pour d'autres raisons aura des exigences vis-à-vis de la sélection de l'environnement en lien avec la souveraineté numérique.

Méthodes de sélection de l'environnement

La diversité des méthodes de sélection de l'environnement passées en revue dans l'état de l'art abordent certaines exigences que nous avons identifiées. En particulier, nous constatons que la minimisation du coût de l'environnement (E_2) est une exigence bien connue des travaux

précédents, par exemple ceux de M. ZHANG et coll. (2012), BELLI, LOOMIS et ABDENNADHER (2016) et de LIU et coll. (2019). La minimisation de la latence de réponse du système (E_4) est une autre exigence largement abordée. Au contraire, certaines exigences sont très rarement évoquées, par exemple la minimisation de l'effort de maintenance opérationnelle (E_1) que QUINTON (2014) aborde en automatisant la sélection de *PaaS* quand la configuration du système le permet, ou la souveraineté numérique (E_6) abordée par RAMAMURTHY et coll. (2020) avec les restrictions relatives aux lois de régulation des données. Enfin, certaines exigences ne sont jamais évoquées dans ces travaux, par exemple en matière de coûts de migration (E_9) ou d'impacts environnementaux (E_{11}).

En outre, nous notons que les méthodes proposées dans ces travaux posent des contraintes et des hypothèses pour la sélection de l'environnement. Par exemple, la plupart d'entre elles restreignent les services infonuagiques candidats aux *IaaS*; d'autres sont adaptées à la sélection d'environnements multilingues.

De plus, la plupart des méthodes que nous avons étudiées abordent l'estimation des critères (p. ex. le coût de l'environnement) soit de manière qualitative, soit en la considérant comme un calcul en boîte noire, étudié par ailleurs dans d'autres travaux de recherche.

Enfin, à l'exception de FAROKHI et coll. (2014) qui ont constaté que différents niveaux d'importance sont affectés à chaque critère selon le contexte de migration, les méthodes proposées ont des critères de sélection fixes. Or, nous avons constaté dans les entretiens qu'en plus de ne pas trouver les mêmes exigences dans chaque migration et divers raffinements de ces exigences, le contexte mène à favoriser certaines exigences par rapport à d'autres. Par exemple, dans la migration effectuée par P_5 , l'exigence d'héberger le système sur le territoire français (E_6) n'était pas négociable, tandis que P_6 a pu proposer un compromis sur une exigence semblable (E_6) afin de favoriser notamment la réduction de l'effort de maintenance opérationnelle (E_1). Une méthode de sélection de l'environnement adéquate devrait permettre de se concentrer sur les critères importants dans notre contexte et de leur affecter une importance relative, permettant de dégrader certains critères au profit de l'optimisation d'autres critères plus importants. Cela soulève également le sujet des compromis, car il est parfois impossible de satisfaire un ensemble d'exigences avec le catalogue de services infonuagiques existant; or, ce sujet n'est pas abordé dans les méthodes existantes.

5.5.3 Catégorisation des exigences

Suite à l'identification de ces exigences de haut niveau, nous avons cherché à les catégoriser. En effet, catégoriser les exigences est une pratique commune de l'ingénierie des exigences afin d'aider la découverte d'exigences qui n'auraient pas encore été élicitées, et leur analyse. Notre

objectif était donc d'identifier des catégorisations permettant de discriminer les exigences entre elles de manière à assister l'élicitation et l'analyse des exigences d'un nouveau projet de migration.

En outre, nous n'avons pas mis en œuvre de méthode pour chercher les catégorisations. Comme nous le montrons dans les paragraphes suivants, nous nous sommes reposés sur des catégorisations classiques de l'ingénierie des exigences et des concepts de gestion de projet.

Catégorisations

Notre recherche a abouti à deux catégorisations qui nous ont semblé suffisamment intéressantes. Nous les détaillons ci-dessous.

Triangle de fer En matière de gestion de projet, il est commun de considérer trois dimensions des activités à mener : leur coût, leur durée et la qualité qu'elle apporte au projet ; ces trois dimensions, parfois surnommées *triangle de fer*, sont une base pour réaliser des compromis (BABU et SURESH, 1996). Par exemple, dans un projet au budget contraint et devant être achevé rapidement, il sera nécessaire d'accepter une moindre qualité du système développé.

C'est pour cette raison que nous avons cherché à catégoriser les exigences de haut niveau que nous avons identifiées d'après le triangle de fer. Nous avons identifié deux manières de catégoriser les exigences dans cette optique.

Dans un premier temps, nous pouvons les catégoriser en ne considérant que le processus de migration, tel qu'illustré dans la table 5.4. Dans ce cas, nous distinguons deux groupes d'exigences : d'une part, celles qui ont trait au système informatique migré et, d'autre part, celles qui concernent le processus de migration en soi. Ce deuxième groupe ne contient que deux exigences, E_9 et E_{10} , qui relèvent respectivement des coûts et de la durée de la migration. Toutes les autres exigences font état de la qualité du système.

Si cette première catégorisation semble évidente et peut aider l'élicitation des exigences, son intérêt pour l'analyse des exigences nous semble limité. En effet, suite au développement du système vient la maintenance opérationnelle de ce système, qui est un nouveau processus dans lequel les notions de coût, de durée et de qualité sont également à considérer. Nous proposons donc une seconde catégorisation inspirée du triangle de fer qui prend en compte à la fois la migration et la maintenance opérationnelle, dans la table 5.5. Nous y retrouvons l'unique E_{10} dans la catégorie *Durée*, puisqu'elle demeure la seule qui vise à réduire la durée des activités. Pour le reste, certaines exigences de la catégorie *Qualité* de la première catégorisation font ici partie de la catégorie *Coût* :

- E_1 est une exigence liée à la réduction des coûts car elle accompagne, dans tous les entretiens, le souhait de limiter le personnel dédié à la maintenance opérationnelle. Le

Catégorie	Exigences de haut niveau
Coût	E_9
Durée	E_{10}
Qualité	$E_1, E_2, E_3, E_4, E_5, E_6, E_7, E_8, E_{11}$

TABLE 5.4 – Catégories inspirée du triangle de fer pour le seul processus de migration

Catégorie	Exigences de haut niveau
Coût	E_1, E_2, E_5, E_9
Durée	E_{10}
Qualité	$E_3, E_4, E_6, E_7, E_8, E_{11}$

TABLE 5.5 – Catégories inspirée du triangle de fer pour le cycle de vie du système

coût à réduire dans ce cas est la masse salariale ;

- E_2 est évidemment une exigence pour diminuer les coûts du système informatique, en diminuant ceux de l'hébergement ;
- E_5 , enfin, est lié aux coûts à deux titres. Dans les entretiens, il était soit question de ne pas embaucher du personnel doté de compétences inconnues des employés présents, soit d'éviter de former des employés à de nouvelles compétences. Dans les deux cas, c'est bien le coût (d'un nouveau salaire, de la formation) qui devait être minimisé.

Activités des équipes Nous avons également pensé à catégoriser les exigences d'après les types d'activités réalisées au sein des équipes. En ce qui concerne le développement logiciel, deux grands types d'activités peuvent être identifiées : le développement du système et la maintenance opérationnelle. Cependant, dans l'informatique en nuage, une partie de la maintenance opérationnelle est assurée par le fournisseur de services, qu'il convient de prendre en compte.

Il en résulte la catégorisation présentée dans la table 5.6. Les exigences de la catégorie *Développement* sont celles qui ont, en particulier, demandé d'importantes tâches de développement pour adapter le système, dans les entretiens que nous avons mené. Celles de la catégorie *Maintenance opérationnelle* sont celles qui vont mener à un plus grand effort de la part des opérateurs. Enfin, celles de la catégorie *Caractéristiques des services infonuagiques* sont celles qui ne vont pas engendrer des activités pour les équipes de développement et de maintenance opérationnelle, mais qui dépendent d'une sélection adéquate de l'environnement infonuagique.

Deux exigences se trouvent dans deux catégories. D'une part, les exigences liées à la *minimisation de nouvelles compétences* (E_5), qui peuvent concerner les compétences liées au développement (p. ex. savoir utiliser des cadriciels, un langage de programmation) et à la maintenance opérationnelle (p. ex. surveillance d'architecture sans serveurs, *SRE* (BEYER et coll., 2016)).

Catégorie	Exigences de haut niveau
Développement	E_1, E_2, E_5, E_8
Maintenance opérationnelle	$E_3, E_5, E_8, E_9, E_{10}$
Caractéristiques des services infonuagiques	E_4, E_6, E_7, E_{11}

TABLE 5.6 – Catégories liées aux activités des équipes

D'autre part, l'*adhérence au fournisseur de services* (E_8) a été évoquée en deux opposés : soit l'organisation souhaitait s'engager avec un fournisseur de services en particulier, coïncidant avec l'adaptation du système pour bénéficier des avantages de s'engager avec ce fournisseur de services ; soit l'organisation voulait que le système soit agnostique du fournisseur de services, auquel cas les *IaaS* sont favorisés pour la sélection de l'environnement, ce qui demande plus d'effort pour la maintenance opérationnelle.

Autres catégorisations

La recherche de catégorisations nous a amené à en envisager certaines qui ne nous ont finalement pas semblé concluantes, nous les présentons dans les paragraphes suivants.

Exigences fonctionnelles et non fonctionnelles Classiquement dans l'ingénierie des exigences, nous distinguons les exigences fonctionnelles, qui décrivent les fonctionnalités désirées du système, et les exigences non fonctionnelles, qui décrivent les qualités que doit présenter le système (KOTONYA et SOMMERVILLE, 1998a).

Cependant, nous estimons que les onze exigences de haut niveau que nous avons identifiées sont toutes des exigences non fonctionnelles, puisqu'elles décrivent dans quelles conditions la migration se déroule et les qualités du système suite à sa migration, et non de nouvelles fonctionnalités que lui apporte la migration. Ainsi, cette catégorisation ne nous semble pas fructueuse.

GORE Une catégorisation possible nous a été inspirée par l'ingénierie des exigences dirigée par les buts (en anglais : *Goal Oriented Requirements Engineering*, GORE), qui distingue les buts *durs* des buts *mous* (en anglais : *hard goals* et *soft goals*). Dans le premier cas, il s'agit d'exigences qui peuvent être satisfaites sans ambiguïté ; dans le second, l'exigence décrit une direction sans définir un critère précis de satisfaction (DALPIAZ, FRANCH et HORKOFF, 2016 ; LAMSWEERDE, 2004). Par exemple, exiger de réduire les dépenses est un but mou tandis qu'un but dur analogue pourrait être d'imposer un budget à ne pas dépasser.

Dans les exigences que nous avons identifiées, certaines d'entre elles sont effectivement

toujours rencontrées en tant que but dur ou mou uniquement. Ainsi, les exigences quant à la souveraineté numérique (E_6) que nous avons recensé dans les entretiens sont toujours des buts durs, par exemple l'obligation pour les données du système d'être hébergées en France ou l'obligation de ne pas utiliser un fournisseur de services qui suit une législation d'un pays donné : l'exigence exprime clairement ce qui la satisfait ou l'insatisfait. Au contraire, certaines exigences ont été rencontrées à la fois comme des buts mous et durs. C'est le cas pour le coût de l'environnement infonuagique (E_2) comme nous l'avons utilisé en exemple plus haut, mais d'autres également comme celles sur la durée de la migration (E_{10}) : dans certains cas, il s'agissait de faire en sorte d'achever la migration le plus vite possible et, dans d'autres cas, d'achever la migration avant une date donnée.

Comme la plupart des exigences de haut niveau peuvent être à la fois dans la catégorie *buts mous* et *buts durs*, nous jugeons que cette catégorisation n'est pas concluante.

Type de services utilisé Enfin, nous avons tenté de catégoriser les exigences de haut niveau en fonction des types de services qu'ils mènent à utiliser : *IaaS*, *PaaS* ou *SaaS*. Il s'avère que, pour certaines d'entre elles, nous avons nettement constaté de telles associations : par exemple, quand le coût et la durée de la migration devaient être minimisés (E_9 et E_{10}), l'utilisation de *IaaS* ont été particulièrement utilisés, tandis que les *PaaS* ont été plébiscités pour minimiser la maintenance opérationnelle (E_2).

Cependant, ces catégories n'ont pas de sens pour d'autres exigences. Par exemple, la souveraineté numérique (E_6) et la sécurité (E_7) ne sont pas du tout liées au choix du type de services. En outre, le choix du type de service pour satisfaire les exigences quant aux coûts de l'environnement infonuagique (E_2) dépend du contexte d'utilisation : pour les composants du système seulement ponctuellement utilisés, il semble préférable d'utiliser des *PaaS* sans serveur tandis qu'il semble moins coûteux d'utiliser un *IaaS* s'il est utilisé intensivement. Pour ces raisons, nous jugeons cette catégorisation infructueuse.

5.6 Conclusion

Dans ce chapitre, nous avons présenté l'étude qualitative que nous avons mené dans le but de répondre à la question suivante : « *Quelles sont les exigences de haut niveau qui dirigent la sélection d'un environnement infonuagique lors d'une migration ?* ». Pour cela, nous avons procédé à des entretiens semi-dirigés auprès d'un panel d'industriels ayant participé à une migration infonuagique. Ils ont abouti à l'identification de onze exigences de haut niveau qui dirigent la sélection d'un environnement infonuagique lors d'une migration. Nous avons ensuite proposé une discussion sur les résultats de cette étude dans laquelle nous présentons deux catégorisa-

tions des exigences de haut niveau ainsi qu'une discussion au regard de l'état de l'art à propos des facteurs d'adoption de l'informatique en nuage et des méthodes de sélection de l'environnement infonuagique. Cette discussion a mis en lumière des sujets qui ne sont pas encore abordés par les travaux de recherche ; et en particulier l'absence de méthode de sélection pour satisfaire certaines exigences que nous avons identifiées et l'élaboration de compromis.

Afin de fonder une méthode de sélection multi-critères, il convient de pouvoir évaluer la satisfaction des exigences dès la conception de la migration. L'une des exigences les plus récurrentes que nous avons identifiées concerne le coût de l'environnement infonuagique. Or, s'il existe des approches pour évaluer le coût d'un environnement infonuagique, ces approches ne tiennent pas compte des spécificités de l'informatique en nuage. Par conséquent, le chapitre suivant est dédié à nos travaux concernant l'estimation des coûts d'un environnement infonuagique.

Chapitre 6

Définition d'un modèle conceptuel pour l'estimation des coûts opérationnels d'une conception préliminaire de système infonuagique

Comme nous l'avons vu dans le chapitre 3, les coûts de l'informatique en nuage sont une préoccupation récurrente. En effet, l'attente de coûts réduits est un important facteur d'adoption de ce paradigme, et il s'agit d'un critère fréquemment utilisé pour la sélection d'un environnement infonuagique. De plus, nous avons vu dans le chapitre 4 que plusieurs travaux aussi bien académiques qu'industriels s'attachent à évaluer les coûts d'un environnement infonuagique. Enfin, le chapitre précédent a montré que minimiser les coûts d'un environnement infonuagique est une exigence fréquente à considérer pour sélectionner un environnement lors d'une migration infonuagique. Par conséquent, nous identifions clairement l'estimation des coûts d'un environnement infonuagique comme un enjeu pour la réussite d'une migration.

Dans un contexte industriel, cette estimation se doit d'être automatisée par un outil afin d'accélérer et multiplier les expérimentations, et cet outil doit être adapté à son contexte d'utilisation. Afin de développer un tel outil, nous devons au préalable modéliser les composantes qui interviennent dans l'estimation des coûts d'un environnement infonuagique.

Dans ce chapitre, nous présentons un modèle conceptuel permettant d'évaluer les coûts

d'une conception préliminaire de système infonuagique sur un nuage public, et qui tient compte de caractéristiques organisationnelles fréquemment rencontrées dans l'industrie.

Ce chapitre est organisé comme suit. Dans la section 6.1, nous présentons les buts que nous avons identifiés pour un outil d'estimation des coûts, et nous analysons les outils présentés dans le chapitre 4 sous leur prisme. Puis, dans la section 6.2, nous présentons le modèle que nous avons défini afin qu'un outil qui l'implémente satisfasse ces buts. Dans la section 6.3, nous analysons les buts que satisfait le modèle conceptuel, et nous concluons dans la section 6.4.

6.1 Buts d'un outil d'estimation des coûts d'un environnement infonuagique

Comme nous l'avons présenté, automatiser l'estimation des coûts d'un environnement infonuagique est nécessaire pour aider les organisations à faire face aux particularités de l'informatique en nuage et aux contraintes temporelles et organisationnelles communes dans l'industrie.

Dans cette section, nous présentons les buts que nous avons identifiés pour un tel outil. Nous verrons qu'il se doit de faciliter l'estimation des coûts liés à la mise à l'échelle automatique, mécanique récurrente de l'informatique en nuage dont il est difficile de manuellement estimer les répercussions sur les coûts, ainsi que de ceux liés aux interactions au sein de l'environnement. De plus, certaines décisions architecturales sont difficiles à réviser une fois le système développé et mis en ligne, l'outil doit donc être utilisable dès les phases préliminaires de la conception. En outre, le développement de système infonuagique étant souvent incrémental, cet outil doit pouvoir être réutilisé à chaque incrément sans nécessiter de recommencer l'estimation de zéro. Enfin, l'outil doit permettre aux acteurs présents dans les organisations de coopérer, en tenant compte de l'expertise que chacun a à apporter à l'estimation. Pour finir cette section, nous passons en revue les outils de l'état de l'art sous le prisme de ces buts.

6.1.1 Liste des buts

Estimation des coûts liés à la mise à l'échelle automatique

Dans le chapitre 2, nous avons expliqué que les environnements peuvent être mis à l'échelle, c'est-à-dire qu'il est possible d'ajouter ou de retirer des ressources dans un environnement, et ce très rapidement. La vitesse de mise à l'échelle est la définition même d'élasticité. Une élasticité rapide est l'une des caractéristiques des services infonuagiques. Dans les nuages publics, les coûts dépendent pour partie du nombre de ressources et du temps pour lequel elles sont

allouées, ce qui explique pourquoi il est important de tenir compte de la mise à l'échelle dans l'estimation des coûts : la quantité de ressources varie dans le temps.

De plus, les organisations configurent leurs environnements avec des mécanismes de mise à l'échelle automatique afin de minimiser leurs dépenses. Ces derniers permettent d'adapter automatiquement l'environnement en fonction du besoin, ce dernier est corrélé à la quantité d'interactions des utilisateurs avec le système. Par exemple, le service de machines virtuelles à la demande *Compute Engine* de *Google Cloud* permet la définition de groupes d'instances qui adaptent leur nombre de machines virtuelles en fonction de l'utilisation du *CPU* des machines déjà déployées. L'objectif est d'ainsi minimiser le nombre de ressources facturées tout en garantissant un niveau de qualité de service.

Cela requiert de tenir compte du nombre d'interactions en cours à chaque instant, ce qui inclut les interactions qui débutent à cet instant mais également celles qui sont en cours de traitement. Par exemple, un serveur Web peut prendre en charge plusieurs requêtes simultanément, et prend du temps à traiter ces requêtes : si le nombre de requêtes pris en charge par le serveur Web est trop important, alors une nouvelle ressource doit être déployée pour traiter les nouvelles requêtes incidentes. En outre, les mécanismes de mise à l'échelle automatique peuvent être configurés de diverses manières selon les fournisseurs de services, et ces configurations peuvent grandement influencer sur le nombre de ressources utilisées.

Dans les faits, tenir compte de ces paramètres est complexe et chronophage dans un calcul de coûts manuel, car les données à considérer sont diverses et il est nécessaire de tenir compte de la dimension temporelle. Ainsi, nous pensons qu'un des buts pour un outil adapté aux besoins de l'industrie est le suivant :

But 1 (B_1) *Un outil d'estimation des coûts d'un environnement infonuagique doit faciliter la prise en compte de la mise à l'échelle automatique.*

Estimation des coûts liés aux interactions avec les ressources

La prise en compte des interactions avec l'environnement infonuagique et en son sein est une seconde difficulté que nous identifions dans l'industrie. Nous identifions plusieurs racines à ce problème.

D'abord, les outils existant pour l'estimation des coûts mettent l'accent sur des données qui résument l'utilisation du système infonuagique sur une période de temps donnée, généralement le mois. Si cela ne pose pas de problème pour évaluer le coût d'allocation de ressources statiques (p. ex. une machine virtuelle déployée en permanence), les interactions, elles, mobilisent chacune d'infimes quantités facturables. Par exemple, il est difficile d'évaluer le nombre de requêtes *HTTP* qui seront adressées à un serveur au cours d'un mois. Ainsi, faire le suivi

des interactions à l'échelle d'un mois requiert un cadre adapté. De plus, les interactions sont initiées parfois par les ressources, et parfois par les utilisateurs du système informatique. Or, comme nous l'avons mentionné précédemment, les acteurs qui disposent de la connaissance à propos de ces utilisateurs sont rarement sollicités dans l'estimation des coûts. Enfin, les coûts liés aux interactions sont multiples et varient selon le service. En effet, certains services facturent le fait d'interagir, et ils facturent différemment selon la nature de l'interaction (p. ex. un tarif différent pour l'écriture et la lecture sur une base de données). Ces interactions sollicitent le réseau, ce qui peut également coûter de l'argent selon la situation. Les interactions au sein d'un centre informatique sont souvent gratuites, mais pas entre centres informatiques au sein du réseau du fournisseur de services, ce qui peut rendre les coûts difficiles à évaluer pour les déploiements élastiques qui répartissent leurs ressources entre les centres informatiques.

Ainsi, les conséquences sur les coûts des interactions avec et au sein de l'environnement sont difficiles à évaluer. Certes, AOSHIMA et YOSHIDA (2022) abordent cette difficulté par une modélisation de l'environnement en un graphe acyclique dirigé, mais ils restreignent leur étude aux services de conteneurs à la demande, en faisant l'hypothèse que les ressources allouées le sont à chaque fois pour traiter une requête, et désallouées à la fin du traitement de cette requête, ce qui ne correspond pas tout à fait à la réalité de ces services. Ce constat nous amène à un deuxième but que doit satisfaire un outil d'estimation des coûts :

But 2 (B_2) *Un outil d'estimation des coûts d'un environnement infonuagique doit faciliter la prise en compte des interactions au sein de l'environnement.*

Estimation des coûts à la conception

Comme nous l'avons dans le chapitre 4, il existe des travaux de recherche visant à évaluer et optimiser des systèmes existants (CHAISIRI, LEE et NIYATO, 2012; AMIRI et KHANLI, 2017; CHARD et coll., 2017). Cependant, ces approches d'optimisation arrivent tardivement, quand le développement du système est largement entamé ou achevé. Dès lors, il est difficile de revenir sur certaines décisions. La principale explication que nous trouvons à cette difficulté est l'enfermement propriétaire : les particularités de chaque service infonuagique requièrent de développer un système spécialement pour les utiliser, et il est dès lors nécessaire de procéder à de nouveaux développements pour changer l'environnement infonuagique. Cela explique pourquoi les approches d'optimisation se concentrent sur des détails de configuration des services : par exemple, le nombre ou le gabarit des machines virtuelles de l'environnement. À notre connaissance, de telles approches ne permettent pas la remise en question d'une architecture inadaptée.

L'idée selon laquelle la difficulté de résoudre un problème croît avec le temps n'est pas

nouvelle. Si elle était discutée auparavant, elle fut démocratisée par l'édition de 1994 du rapport *Chaos* du cabinet de conseil en recherche informatique *Standish Group*¹. Ce document rapporte de très importants surcoûts et délais supplémentaires des projets de développement informatique. Il attribue ces surcoûts et ces délais à la tendance des entreprises à redémarrer les projets, qu'ils expliquent par de nombreux facteurs qui ont, pour la plupart, trait à des insuffisances dans le processus de conception. Bien que l'importance des mesures présentées par ce rapport soit très critiquées, les conclusions du *Standish Group* sont reconnues dans le milieu académique (JØRGENSEN et MOLØKKEN-ØSTVOLD, 2006 ; GLASS, 2006). En outre, STECKLEIN et coll. (2004) ont mené une étude en 2004 pour déterminer à quel point il est coûteux de résoudre un problème tardivement dans le développement logiciel. Leur conclusion est que le coût de résolution d'un problème évolue exponentiellement avec l'avancée du développement. En ce qui concerne les problèmes liés aux coûts de l'environnement dans l'infonuagique, ces derniers sont nettement identifiables au plus tard, quand le système est opérationnel. Cela rend la résolution de ces problèmes particulièrement coûteuse.

Pour cette raison, un autre but nous identifions est le suivant :

But 3 (B_3) *Un outil d'estimation des coûts d'un environnement infonuagique doit pouvoir être utilisé dans les phases préliminaires de la conception.*

Fil numérique

Les systèmes infonuagiques sont, pour la plupart, développés incrémentalement en suivant des méthodes *Agile* (YOUNAS et coll., 2018). Nous pouvons distinguer deux cas. D'un côté, un système existant est migré vers un environnement infonuagique. Si, comme nous l'avons présenté dans le chapitre 3, la recherche académique a identifié plusieurs stratégies de migration, l'une d'elle est particulièrement mise en avant dans les méthodes recommandées par les fournisseurs de services² : une migration vers des *IaaS* avec peu ou pas d'adaptation des logiciels. Cette migration initiale est suivie d'étapes de modernisation successives réalisées en parallèle du développement de nouvelles fonctionnalités du système. De l'autre côté, un système est créé dès le début sur un environnement infonuagique. Dans cette situation, il est évident que l'environnement infonuagique et l'usage de cet environnement évoluent à chaque incrément. Dans les deux cas, les coûts de l'environnement infonuagique changent d'un incrément à l'autre. Par conséquent, une organisation devrait évaluer les coûts de l'environnement à chaque incrément pour s'assurer qu'aucun écart trop important n'aie lieu et que les exigences demeurent

1. Rapport *Chaos* du *Standish Group* publié 1994 : https://www.standishgroup.com/sample_research_files/chaos_report_1994.pdf.

2. Par exemple, le processus de migration recommandé par *Amazon Web Service* : <https://aws.amazon.com/fr/cloud-migration/how-to-migrate/>.

satisfaites. Un outil d'estimation des coûts doit donc permettre la réutilisation des documents nécessaires à l'estimation des coûts. Cela s'inscrit dans l'idée de *fil numérique*, que SINGH et WILLCOX (2018) définissent comme le lien entre toutes les informations générées tout au long du cycle de vie d'un produit, utilisé pour prendre des décisions sur le long terme.

Néanmoins, nous pensons que la réutilisabilité seule n'est pas suffisante. En effet, la nature des ressources à réutiliser doit permettre aux parties prenantes de les faire évoluer sans les régénérer intégralement, afin de rendre l'utilisation de l'outil peu chronophage. Par exemple, ce n'est pas le cas des données requises par les calculatrices de coûts présentées dans le chapitre 4. En effet, elles requièrent d'estimer les quantités d'usage de chaque service infonuagique. Or, chaque modification de l'environnement et chaque ajout de fonctionnalité modifie la nature des usages en question et les quantités de ces usages. Pour illustrer ce point, nous pouvons considérer une évolution du système dans laquelle un logiciel hébergé sur une machine virtuelle est relocalisé sur un service de conteneurs à la demande ; dès lors, les quantités d'usages imputées à la machine virtuelle doivent être éliminées de l'estimation et celles du services de conteneurs à la demande calculés. Or, il n'y a pas de point commun entre ces deux quantités, car celles pour la machine virtuelle dépend uniquement du gabarit de la machine tandis que pour le conteneur, il faut également tenir compte du comportement des utilisateurs.

Finalement, ces deux caractéristiques nous mènent à un nouveau de l'outil :

But 4 (B_4) *Les paramètres d'un outil d'estimation des coûts d'un environnement infonuagique doivent être réutilisables et évolutifs pour suivre le cycle de vie de l'environnement*

Coopération des parties prenantes

Les coûts d'un environnement infonuagique sont calculés d'après les usages générés par ses ressources, ce qui dépend des services infonuagiques et de la population d'utilisateurs. Il faut aussi compter d'éventuels tarifs négociés avec le fournisseur infonuagique. Ainsi, plusieurs rôles prennent part à l'estimation des coûts d'un environnement infonuagique. Ces rôles sont ceux qui détiennent les expertises techniques, fonctionnelles et financières du projet de développement du système. Or, dans les organisations, les acteurs qui possèdent ces rôles sont souvent différents. Par exemple, l'architecte de systèmes infonuagiques est rarement aussi l'analyste fonctionnel et le responsable financier de l'organisation.

Comme les informations requises sont réparties entre plusieurs acteurs, il est nécessaire que l'outil d'estimation facilite leur coopération. Une stratégie répandue pour ce faire est la séparation des préoccupations (ici : les expertises technique, fonctionnelle, financière). Il s'agit, d'abord, d'un principe de conception en informatique qui consiste à séparer un programme en plusieurs segments isolés qui chacun traite une partie du problème à résoudre sans nécessiter

une compréhension exhaustive de ce problème (EVANS, 2004). Ce principe a été appliqué dans divers travaux, tels que dans les méthodologies de développement. Par exemple, ELSHAMY et ELSSAMADISY (2006) l'emploient dans une méthode nommée « *Conquérir puis Diviser* »³ pour les développements *Agile* de très grands systèmes. La première, *Conquérir*, dans laquelle une petite équipe multidisciplinaire débute le développement d'une première version du système qui pose son architecture et aborde toutes les grandes fonctionnalités sans chercher à détailler l'ensemble des cas à traiter. Puis, une phase *Diviser* dans laquelle l'ensemble des parties prenantes est divisé par unité fonctionnelle qui deviennent chacune autonome grâce à un transfert de connaissance depuis les membres de la petite équipe de la phase précédente, et qui chacune acquiert une meilleure connaissance de l'unité fonctionnelle à laquelle elle est affectée.

Pour conclure, l'estimation des coûts requiert la coopération de plusieurs acteurs que nous permettons en séparant leurs préoccupations dans les paramètres de l'outil que nous devons spécifier. D'où l'exigence suivante :

But 5 (B_5) *Les paramètres d'un outil d'estimation des coûts d'un environnement infonuagique doivent permettre aux parties prenantes de travailler indépendamment.*

6.1.2 Satisfaction des buts par les outils revus dans l'état de l'art

La table 6.1 récapitule les travaux en lien avec l'estimation des coûts que nous avons revu dans l'état de l'art (chapitre 4) et qui sont des outils ou pourraient être l'objet du développement d'un outil. Nous les analysons sous les prismes des buts que nous venons de présenter.

Seule la modélisation en graphe de Aoshima et Yoshida aborde, bien que partiellement, la facilitation de prise en compte de l'élasticité (B_1). En effet, leurs travaux sont résolument orientés pour les services de conteneurs à la demande, dont l'utilisation entraîne nécessairement la mise à l'échelle de l'environnement. Cependant, il ne s'agit pas du cœur de leur contribution, car ils sont plutôt concentrés sur les interactions au sein de l'environnement infonuagique (B_2), avec les manques évoqués ci-avant. Deux autres travaux abordent ce second but. Fittkau et coll., avec *CDOSim*, permettent de modéliser des machines virtuelles et simuler les interactions qu'elles ont entre elles. Ces interactions permettent d'évaluer l'intérêt de stratégies de mise à l'échelle, mais cela ne s'inscrit pas a priori dans les mécanismes de mise à l'échelle automatique proposés par les fournisseurs de services⁴. D'une certaine manière, *COCA-PT* aborde également partiellement le but B_2 car le modèle de consommation des ressources capture les conséquences des interactions sur l'infrastructure d'origine, et permet de les répercuter sur les coûts de l'environnement.

3. Dans le texte : « *Divide after you Conquer* ».

4. Cela peut s'expliquer par le petit nombre de fournisseurs de services proposant une telle fonctionnalité à l'époque de la parution de ces travaux.

Contribution de l'état de l'art	B_1	B_2	B_3	B_4	B_5
<i>CDOSim</i> (FITTKAU, FREY et HASSELBRING, 2012b; FITTKAU, FREY et HASSELBRING, 2012a)	$\emptyset$	$\sim$	✓	✓	$\emptyset$
Calcul du <i>TCO</i> de MARTENS, WALTERBUSCH et TEUTEBERG (2012)	$\emptyset$	$\emptyset$	✓	$\emptyset$	$\emptyset$
Modélisation de FERRETTI et coll. (2014)	$\emptyset$	$\emptyset$	✓	$\emptyset$	$\emptyset$
Modélisation en <i>DAG</i> (AOSHIMA et YOSHIDA, 2020; AOSHIMA et YOSHIDA, 2022)	$\sim$	$\sim$	✓	✓	$\emptyset$
<i>COCA-PT</i> de BELL, LOOMIS et ABDENNADHER (2016)	$\emptyset$	$\sim$	$\sim$	$\sim$	$\sim$
Calculatrices de coûts des fournisseurs de services	$\emptyset$	$\emptyset$	✓	$\emptyset$	$\emptyset$
Calculatrices de coûts multifournisseurs	$\emptyset$	$\emptyset$	✓	$\emptyset$	$\sim$
Calcul intégré aux outils de déploiement de l'environnement	$\emptyset$	$\emptyset$	$\sim$	$\sim$	$\sim$

TABLE 6.1 – Satisfaction des buts identifiés par les outils et approches outillables de l'état de l'art (✓ : satisfaction, $\sim$: satisfaction partielle, $\emptyset$: pas pris en compte)

L'ensemble des approches revues sont utilisables dès la conception du système (B_3). Cela est dû à un choix que nous avons présenté en début du chapitre 4. Cette affirmation peut toutefois être discuté pour *COCA-PT*, car il repose sur l'existence d'un système à observer : si cet outil convient à la migration infonuagique, il n'est pas envisageable de s'en servir pour développer un nouveau système natif à l'informatique en nuage.

Nous considérons que plusieurs travaux satisfont l'exigence B_4 , au sujet du fil numérique. En effet, les paramètres des simulations de *CDOSim* sont sérialisables et ils peuvent être modifiés au fur et à mesure, tout comme le sont les graphes proposés par Aoshima et Yoshida. Les modèles de consommation dans *COCA-PT* sont également sérialisables, cependant ils ont été générés par un outil et sont difficiles à faire évoluer tout comme le sont les données à insérer dans les calculatrices de coûts. Nous pouvons faire la même remarque pour les données complémentaires apportées aux outils de déploiement de l'environnement pour évaluer les coûts. Néanmoins, nous pouvons noter pour ces derniers que les outils actuels sont appelés *Infrastructure en tant que Code*, car le développement de l'infrastructure est effectivement ramené à du développement de code évolutif et sauvegardable.

Enfin, peu d'outils abordent la séparation des préoccupations (B_5). En reposant sur l'observation d'un système existant, *COCA-PT* contourne le besoin d'une telle pratique, mais cela ne permet pas de tirer profit des expertises de chaque rôle. Les paramètres à renseigner dans les calculatrices de coûts multifournisseurs font l'abstraction des détails techniques, ils s'adressent ainsi, et dans une moindre mesure, aux acteurs détenant l'expertise fonctionnelle. Enfin, les outils de déploiement de l'environnement sont des outils du quotidien des techniciens ; ils portent en eux une partie de la connaissance de ces acteurs, laquelle doit être enrichie d'autres informations qui mêlent différentes préoccupations.

Pour conclure, nous avons vu que les buts que nous avons identifiés sont peu couverts par les travaux existants. Or, nous pensons qu'un outil d'estimation des coûts d'un environnement infonuagique doit les satisfaire tous pour être adapté à un usage industriel. C'est pourquoi nous détaillons, dans la section suivante, un modèle conceptuel pour un outil qui satisfait ces buts.

6.2 Modèle conceptuel

Dans cette section, nous présentons notre démarche de modélisation pour un outil d'estimation des coûts d'un environnement infonuagique, et le modèle qui en résulte.

Notre démarche a débuté par l'identification des parties prenantes de cette estimation. Cela nous a amené à identifier quatre types de parties prenantes : les fournisseurs de services, le responsable des achats, l'architecte de systèmes infonuagiques et l'expert fonctionnel. Ces acteurs participent à l'estimation des coûts en générant, chacun de leur côté, des artefacts que nous détaillons dans cette section. Enfin, nous intégrons un cinquième acteur, le responsable *FinOps*, qui a pour tâche d'analyser les résultats de l'estimation ; nous revenons sur ce point dans la sous-section 6.2.6, dédiée aux résultats de l'estimation.

Pour chacune de ces parties prenantes, nous avons établi les informations qu'elle doit fournir ou utiliser, d'après les connaissances que nous pouvons attendre qu'elle possède. La figure 6.1 ordonne ces informations : nous y voyons les acteurs cités précédemment ainsi que les éléments qu'ils génèrent et la manière dont ils sont intégrés à l'estimation des coûts. Dans cette section, nous détaillons chaque artefact représenté sur cette figure.

6.2.1 Catalogue de services infonuagiques

Les *fournisseurs de services* décrivent un catalogue, qui recense l'ensemble de leurs services. Les usagers sélectionnent l'environnement à partir de ce catalogue.

Dans les paragraphes suivants, nous détaillons les éléments qui constituent ce catalogue.

Géographie du nuage informatique

Un élément récurrent dont dépendent les coûts de l'environnement est la localisation de ses ressources. Chaque ressource est déployée dans une localisation (*Location*) choisie par l'utilisateur. De cette localisation dépendent grandement les coûts. Dans de nombreux cas, le tarif d'une même ressource diffère d'une localisation à l'autre. La localisation de ressources dans des centres informatiques éloignés engendre également des frais pour l'utilisation du réseau.




FIGURE 6.1 – Acteurs et artefacts impliqués dans l'estimation des coûts d'un environnement infonuagique

Les localisations correspondent aux centres informatiques qui composent le nuage, et à des ensembles de ces centres informatiques. Il y en a donc plusieurs types.

Le centre informatique est l'unité de lieu la plus fine que peut utiliser un usager : sa ressource est située sur l'une des machines de ce centre informatique, sans autre précision. Un centre informatique est situé quelque part sur Terre, mais souvent seule une indication peu précise est fournie quant à ses coordonnées réelles. Par exemple, les localisations *europe-west9-a*, *europe-west9-b* et *europe-west9-c* correspondent à des centres informatiques de Google Cloud Platform à Paris et dans ses alentours. Ce type de localisation porte le nom de *zone* ou de zone de disponibilité.

L'hébergement de ressources dans une zone peut représenter un risque : un centre informatique peut devenir injoignable à cause d'un incident (p. ex. panne d'électricité, coupure du réseau) et mettre en péril le bon fonctionnement du système infonuagique. Pour contrecarrer ce problème, les fournisseurs de services proposent de déployer des ressources à l'échelle d'une *région*, c'est-à-dire répliquer les ressources dans plusieurs centres informatiques géographiquement proches mais dont les conditions de fonctionnement sont supposées indépendantes. Une région est donc composée de zones. Par exemple, *europe-west9* est une région de Google Cloud Platform qui correspond à la région parisienne et qui est composée des trois zones citées ci-dessus.

L'usage de régions correspond à un besoin des usagers de stabiliser leur environnement afin de maintenir un certain niveau de service. Cependant, cela ne permet pas de répondre aux besoins de basse latence du réseau pour des utilisateurs du système informatique répartis sur de grandes aires géographiques. Pour cela, des fournisseurs de services proposent des localisations nommées *multi-régions* qui agrègent plusieurs régions à l'échelle d'un continent. Pour poursuivre l'exemple de Google Cloud, ils fournissent la multi-région *europe* qui agrègent toutes les régions du continent européen.

Services de machines virtuelles à la demande

Les nuages hébergent des services infonuagiques (*CloudService*) de divers types. Dans ce paragraphe, nous nous restreignons à l'explication de la modélisation des services de machines virtuelles à la demande, mais il faut compter un travail équivalent pour les autres types de services infonuagiques.

Les services de machines virtuelles à la demande, souvent appelés en anglais des *services de calcul* (*ComputeService*), permettent à un usager de configurer une machine virtuelle. Les services Compute Engine de Google Cloud Platform, EC2 de Amazon Web Services et Virtual Instances de Scaleway sont des exemples de services de machines virtuelles à la demande.

Il s'agit de *IaaS* qui dépendent d'autres *IaaS*, pour le déploiement de disques durs virtuels, d'un réseau, d'équilibreurs de charge. Un usager souhaitant déployer une machine virtuelle avec un service de ce type a besoin de deux éléments : un gabarit de machine et un système d'exploitation à installer.

Gabarit de machine D'un côté, les fournisseurs proposent divers gabarits de machine, ou type de machine (*MachineType*). Un exemple de gabarit de machines est *PRO2-M* du service Virtual Instances de Scaleway⁵. Le processeur de ce gabarit a seize cœurs virtuels partagés : cela signifie que le matériel sous-jacent est mis en commun avec d'autres ressources infonuagiques (et avoir des conséquences sur la performance de calcul). De plus, il a 64 gigaoctets de mémoire vive. D'autres détails sont fournis, par exemple la marque du processeur matériel : de marque *AMD*, série *EPYC 7003* ou *7001*. Ainsi, un gabarit définit les ressources qui sont allouées à la machine virtuelle. Dans le cadre de l'estimation des coûts, ces informations sont importantes : si certains fournisseurs de services facturent l'utilisation d'un gabarit de machine donné, d'autres facturent distinctement les cœurs du processeur et la mémoire vive. Dans ce second cas, ce n'est pas le gabarit qui est pris en compte, mais une famille (*MachineTypeFamily*) auquel ce gabarit appartient. Un gabarit de machine peut-être présenté par le fournisseur de services comme disponible dans plusieurs zones, comme c'est le cas du gabarit *PRO2-M* : il est disponible dans toutes les zones de Scaleway. Cependant, il convient mieux de considérer qu'il existe plusieurs gabarits portant le même nom, un par zone : en effet, les différences tarifaires d'une zone à l'autre indiquent que le gabarit de chaque zone est un produit à part, avec un tarif propre.

Système d'exploitation De l'autre côté, l'utilisateur doit sélectionner un système d'exploitation pour démarrer une machine virtuelle. L'importance de choix dans le calcul du coût est souvent négligeable : certes, le système d'exploitation occupe de l'espace de disque, mais c'est un coût marginal ; en revanche, certains systèmes d'exploitation requièrent le paiement d'une licence, dont les coûts peuvent être importants. Les services de machines virtuelles à la demande mettent à disposition des archives de systèmes d'exploitation (*OperatingSystemArchive*) prêtes à l'usage. Ces archives sont stockées à plusieurs endroits par le fournisseur de services afin d'accélérer leur téléchargement lors de l'initialisation d'une machine virtuelle. Certains services ont une fonctionnalité d'archives personnalisées (*CustomArchivesFeature*), qui permettent aux usagers d'utiliser leurs propres systèmes d'exploitation au prix du stockage des archives.

5. Page Web du service Virtual Instances de Scaleway : <https://www.scaleway.com/en/virtual-instances/>.




FIGURE 6.2 – Diagramme de classes de la géographie des nuages publics

Type d'engagement

Afin de fidéliser leurs usagers, les fournisseurs de services ont introduit la notion d'engagement : un usager s'engage à utiliser un minimum un service infonuagique sur une période donnée. De son côté, l'utilisateur bénéficie d'un tarif réduit sur ce qu'il s'est engagé à utiliser. Par exemple, Amazon Web Services permet aux usagers de s'engager sur un an ou sur trois ans à l'utilisation d'une machine virtuelle tout au long du mois : pendant cette durée (un an ou trois ans), le coût mensuel d'une machine virtuelle est prélevé à l'utilisateur avec une remise, qu'il y en ait une déployée ou non.

Si l'organisation usagère d'un nuage peut négocier directement un engagement avec le fournisseur de services, cela reste l'apanage d'organisations dont les dépenses sont élevées et que le fournisseur de services a intérêt à fidéliser. Pour les autres, des types d'engagement (*CommitmentType*) prédéfinis par le fournisseur de services sont disponibles.

Synthèse

Les paragraphes précédents montrent comment nous avons étudié la réalité observable en tant qu'utilisateur de services infonuagiques afin de conserver les seules informations utiles au calcul du coût. Ce travail nous a permis d'établir les diagrammes de classes de la figure 6.2 pour la géographie des nuages publics, et de la figure 6.3 pour les services des nuages publics. Ce second diagramme ne couvre, comme nous l'avons expliqué, que les services de machines virtuelles à la demande : une étude similaire a été réalisée pour modéliser d'autres services et doit être poursuivie pour couvrir l'intégralité des catalogues de fournisseurs de services.

6.2.2 Tarifs de services infonuagiques

Toutes organisations disposent, normalement, d'un *responsable des achats*, qui négocie les tarifs des services infonuagiques. En effet, en même temps que leur catalogue, les *fournisseurs de services* établissent les tarifs de leur catalogue. Ces tarifs peuvent être consultés en ligne comme documentation des services infonuagiques ou par *API*. Chaque tarif est associé à une




FIGURE 6.3 – Diagramme de classes du catalogue de services infonuagiques restreint aux services de machines virtuelles à la demande

unité de gestion des stocks (en anglais : *Stock Keeping Unit*, *SKU*), un terme commun dans le domaine de la gestion des stocks. Ce *SKU* est une référence à des usages faits de services infonuagiques et indique le tarif en vigueur. Dans cette sous-section, nous commençons par présenter deux exemples de *SKU* ; puis, nous prenons du recul afin de modéliser les tarifs des services infonuagiques.

Exemples de tarifs

Premier exemple Le service Compute Engine de Google Cloud Platform permet aux usagers de déployer des machines virtuelles avec, en particulier, des gabarits de machines d'une famille nommée *E2*. Le *SKU* d'identifiant *0034-652F-8BC9* facture l'allocation des coeurs *CPU* de ces machines virtuelles en région parisienne : 0.025\$ par heure d'allocation d'un coeur⁶. Ainsi, une machine dont le gabarit est *e2-standard-4*, un gabarit de la famille *E2* avec un processeur à quatre coeurs, dépense chaque heure quatre heures d'allocation de coeur *CPU* : le coût lié à ce *SKU* pour cette machine est donc de 0.1\$ par heure.

Second exemple Le service *EC2* d'Amazon Web Services déploie lui aussi des machines virtuelles. Ces machines peuvent émettre et recevoir des communications à travers le réseau : l'utilisation du réseau est une source de coûts. Par exemple, considérons les coûts de transferts sortant du réseau d'Amazon Web Services depuis une machine virtuelle située en région parisienne ; la table 6.2 résume le tarif appliqué à ces transferts. Comme nous le voyons, le coût n'évolue pas linéairement avec la quantité de données sortantes ; il évolue linéairement par palier : les dix premiers téraoctets coûtent 0.09\$ par gigaoctets, puis le tarif décroît à chaque palier. La notion de palier est liée à une période de temps : un compteur est incrémenté à chaque transfert pour déterminer le palier qu'il faut utiliser, et il est réinitialisé au début du mois suivant.

Considérons une succession de transferts réseaux qui totalisent 9999 gigaoctets : l'ensemble de ces transferts coûte 0.09\$ par gigaoctet, soit 899.91\$. Le transfert de données suivant a pour taille cinq gigaoctets (par exemple, une archive de système d'exploitation). Si ce transfert a lieu dans le même mois que la série de transferts mentionnée ci-avant, alors un gigaoctet est sur le premier palier, et quatre sur le second : le transfert coûte donc 0.43\$. Sinon, le transfert a lieu un mois ultérieur, dans ce cas le calcul reprend dès le début du premier palier : le transfert coûte 0.45\$.

6. Tarif pour le *SKU* d'identifiant *0034-652F-8BC9* : <https://cloud.google.com/skus?filter=0034-652F-8BC9>.

Quantité de données transférées	Coût
10 premiers To par mois	0.09\$ par Go
40 To suivants par mois	0.085\$ par Go
100 To suivants par mois	0.07\$ par Go
Au-delà de 150 To par mois	0.05\$ par Go

TABLE 6.2 – Tarification des transferts de données sortantes depuis *EC2*, région *Paris*, vers l'Internet

Modélisation

Usage de service infonuagique Comme nous l'avons vu, le *SKU* de chaque exemple cible un usage particulier de service infonuagique (*CloudServiceUsage*) :

- Dans le premier exemple : l'allocation d'un coeur *CPU* d'une machine de la famille *E2* du service Compute Engine dans l'un des centres informatiques de la région parisienne de Google Cloud Platform ;
- Dans le second exemple : le transfert sortant du réseau d'Amazon Web Service depuis une machine virtuelle déployée en région parisienne par le service *EC2*.

Ces usages sont indépendants de toute définition d'environnement, ce qui permet au fournisseur de services de les définir de son côté. Chaque type de service modélisé doit nécessairement entraîner la modélisation de nouveaux types d'usages de services infonuagiques générés lors de son utilisation.

Quantification de l'usage d'un service infonuagique L'utilisation de services est mesurable, comme nous l'avons vu dans les exemples :

- Dans le premier exemple : la durée (d'allocation d'un coeur *CPU*), facturé à l'heure ;
- Dans le second exemple : la taille (d'un transfert sur le réseau), facturé au gigaoctet. Les paliers dépendent d'une quantité de téraoctets consommés.

La notion de quantité consommée (*ConsumptionMeasure*) apparaît donc à deux reprises. D'une part, il s'agit de l'unité facturée : Amazon Web Service, dans le second exemple, facture le réseau sortant de la région parisienne par tranches d'un gigaoctet. D'autre part, il s'agit de la mesure utilisée pour séparer les paliers de tarification. Enfin, nous devons attendre du service infonuagique en cours d'utilisation qu'il génère une quantité consommée adossé à un usage afin de déterminer quel *SKU* facturer et le montant facturé.

Nous avons identifié quatre types de quantités consommées : la consommation de durée (*DurationConsumption*), la consommation de données (*DataConsumption*), la consommation de durée pendant une durée (*DataOverDurationConsumption*) et la consommation d'unités (*UnitConsumption*).

Expression de tarif et intervalle d'agrégation Nous constatons que la manière d'affecter un prix à une unité facturée (*UnitPricing*) est différente dans les deux exemples :

- Dans le premier : le prix est une fonction linéaire du nombre d'unités facturés (*LinearUnitPricing*);
- Dans le second : le prix est une fonction linéaire par palier du nombre d'unités facturés (*TieredUnitPricing*).

Ces deux modèles sont conformes aux constats de FERRETTI et coll. (2014), et nous n'en avons pas trouvé d'autres dans les services que nous avons modélisés.

Dans le cas d'une fonction linéaire par palier, nous avons besoin d'une donnée supplémentaire : un intervalle d'agrégation (*AggregationInterval*), qui indique le terme au bout duquel le compteur de quantités consommées est réinitialisé. Nous avons constaté l'usage de deux intervalles d'agrégation : la journée (*DayMatcher*) et le mois (*MonthMatcher*).

Synthèse La figure 6.4 est un diagramme de classes qui récapitule ce que nous avons dit dans les paragraphes précédents. Un *SKU* y est appelé une règle de tarification (*PricingRule*), et la facturation d'un nuage informatique (*CloudPricing*) est composée de règles de tarification.

Négociation des tarifs

Le catalogue des services infonuagiques est le même pour tous les usagers et, à notre connaissance, aucune négociation n'est possible pour ajouter un service ou une configuration de service pour un usager en particulier. Cependant, ce n'est pas le cas des tarifs. Dans les grandes organisations, un responsable des achats est mandaté pour surveiller les dépenses et négocier des tarifs avec les fournisseurs de services. Il peut en résulter un arrangement sous forme d'engagement : l'organisation s'engage à dépenser un minimum d'unités d'un *SKU* sur une période donnée, pour un coût unitaire du *SKU* réduit. Si de tels types d'engagement font partie du catalogue de services infonuagiques, la négociation initiée par le responsable des achats a pour but d'en créer de nouveaux, spécifiques à son organisation, pour réduire le coût de l'environnement sélectionné.

6.2.3 Contrat (entre l'architecte et l'expert fonctionnel)

Les artefacts présentés dans les sections suivantes sont générés par les parties prenantes de la conception de l'environnement infonuagique. Nous avons constaté qu'actuellement, l'expert fonctionnel n'est pas vraiment sollicité dans les estimations des coûts du système infonuagique, la teneur de sa participation nécessite donc d'être expliquée. Pour parvenir à faire coopérer




FIGURE 6.4 – Diagramme de classes des tarifs des services infonuagiques

l'architecte et l'expert fonctionnel, nous avons choisi de leur permettre de rédiger leurs propres artefacts indépendamment.

En amont, ces deux acteurs doivent fixer un contrat qui explicite les opérations qu'un utilisateur du système informatique peut réaliser. Ce contrat est nécessaire pour que l'expert fonctionnel puisse décrire le comportement des utilisateurs et que l'architecte explique comment le système informatique effectue ces opérations.

Ce contrat (*CloudSystemContract*) doit préciser trois points. D'abord, les types de données (*DataKind*) manipulées avec le système, et en particulier la taille de ces données. Ensuite, les routes *HTTP* sont exposées par le système. Décrire une route *HTTP*, c'est définir les formats de la requête et de la réponse ; dans le cadre d'une estimation des coûts, seuls la taille de ces messages nous importe. Enfin, il faut prévenir de l'existence de certaines ressources de l'environnement infonuagique qui ont un lot d'opérations prédéfinis et qui sont accessibles directement par les utilisateurs. Prenons l'exemple des compartiments d'objets (*buckets*) : ces ressources sont souvent accessibles depuis l'extérieur du système pour télécharger ou téléverser des documents ; ils sont donc une partie intégrante du contrat entre l'architecte et l'expert fonctionnel. La figure 6.5 est un diagramme de classes du contrat que nous venons de décrire.




FIGURE 6.5 – Diagramme de classes des contrats entre l'architecte et l'expert fonctionnel

6.2.4 Description du système infonuagique

L'acteur chargé de concevoir le système infonuagique est l'architecte. Il doit sélectionner l'environnement infonuagique et déterminer les logiciels que son organisation doit développer pour les exécuter sur cet environnement.

Nous pouvons distinguer deux artefacts composant cette description, ce que nous détaillons dans les paragraphes suivants.

Architecture

Le premier artefact est un squelette de l'environnement, autrement appelé une architecture (*CloudSystemArchitecture*). Elle contient les éléments (*ArchitectureElement*) configurés par l'utilisateur sur les services infonuagiques. Elle explique aussi comment le système satisfait le contrat établi entre l'architecte et l'expert fonctionnel.

Éléments d'architecture Prenons le cas des éléments configurés sur les services de machines virtuelles à la demande. L'utilisateur ne déploie pas directement des machines virtuelles : en vérité, il configure des plans de déploiement de ces machines (*AMachineDeployment*). Ces plans de déploiement peuvent être de deux types. Dans le premier cas, le plan ne déploie qu'une seule machine (*ASingleMachine*) ; celle-ci peut être simple ou préemptible, c'est-à-dire que les ressources matérielles utilisées par cette machine virtuelle peuvent être à tout moment réquisitionnées par le fournisseur de services. En contrepartie, les tarifs pour ces machines sont très inférieurs : par exemple Amazon Web Services accorde une remise de 90% pour les machines virtuelles préemptible de son service *EC2*. Dans le second cas, le plan déploie et gère le cycle de vie de plusieurs machines virtuelles, il s'agit d'un groupe de machines (*AMachinesGroup*). Peu importe le type de plan, l'architecte prévoit un modèle de machine virtuelle (*AMachineTemplate*). Ce dernier indique les disques branchés à la machine ainsi que son interface au réseau (*AMachineNetworkInterface*), qui précise si la machine a seulement une adresse privée sur un réseau virtuel ou également une adresse publique, accessible partout sur l'internet. Enfin, il doit prévoir les logiciels (*ASoftware*) qui sont exécutés par la machine. Un logiciel, quand il est exécuté, réalise une séquence de tâches (*ATask*) qui peuvent mobiliser d'autres ressources de l'environnement (p. ex. écrire sur un disque, téléverser un document sur un compartiment d'objets).

Satisfaction du contrat L'architecture doit permettre à l'architecte d'expliquer comment les fonctionnalités que le système doit fournir, tel qu'annoncé dans le contrat qu'il a établi avec l'expert fonctionnel. Il s'agit simplement d'indiquer, pour chaque route *HTTP*, l'adresse (*IpAddressTarget*) que l'utilisateur du système doit contacter.

Synthèse La figure 6.6 diagramme de classe résultant de notre modélisation des architectures. Une fois de plus, nous l'avons restreint aux services de machines virtuelles à la demande, mais un travail de modélisation similaire doit être effectué pour les autres services.

Pour résumer, une architecture est composée d'éléments d'architecture (qui correspondent aux ressources déployées), ainsi que les interactions entre ces éléments, grâce à la notion de tâches. En somme, une architecture est un graphe comparable à ceux de AOSHIMA et YOSHIDA (2020),




FIGURE 6.6 – Diagramme de classes des architectures décrites par l'architecte

avec toutefois deux distinctions. D'une part, l'architecture est agnostique des fournisseurs de services. En effet, un déploiement d'un groupe de machines virtuelles peut tout aussi bien être déployé sur Amazon Web Services, Scaleway ou un autre nuage ; ses propriétés (p. ex. la topologie du réseau) demeureront peu importe le fournisseur de services choisi. D'autre part, les sommets du graphe de l'architecture ne sont pas de la même nature que ceux des graphes d'Aoshima et Yoshida : en effet, tandis qu'ils considèrent que chaque sommet est une ressource (dans leur travaux, des conteneurs (AOSHIMA et YOSHIDA, 2022)), les éléments d'architecture sont les plans de déploiement de ces ressources, ils peuvent donc potentiellement être associés à un grand nombre de ressources. Les plans de déploiement sont ce que les usagers peuvent configurer, en réalité. En effet, si l'utilisateur peut décider quand il veut allumer et éteindre une machine virtuelle (il configure le plan de déploiement de cette machine), c'est en fait le fournisseur de services qui est chargé de son cycle de vie (p. ex. il n'allume la machine qu'après avoir alloué les ressources physiques nécessaires). Cette distinction est importante pour modéliser les mécanismes de mise à l'échelle automatique, dans lesquelles il n'est pas question d'une ressource en particulier, mais d'un modèle reproductible de ressources et d'une politique de mise à l'échelle.

Exemple fil rouge

L'architecture du système pour l'agence spatiale doit préciser comment seront stockées les données satellitaires. Plusieurs décisions peuvent ici être envisagées, nous en proposons ici deux.

D'un côté, utiliser un *IaaS* pour déployer une machine virtuelle sur laquelle l'équipe exécutera un *SGBD* adapté au stockage de fichiers, tels que Minio ^a. L'architecture comprend, alors, la machine virtuelle, les disques et un descriptif de ce que permet le *SGBD* et ce qu'il se passe quand il est utilisé (p. ex., quand une requête est reçue pour enregistrer un document, le *SGBD* procède à des calculs, écrit le fichier sur un disque, se coordonne avec d'autres instances du logiciel sur d'autres machines pour la redondance, ...).

De l'autre côté, il est possible d'utiliser un *PaaS* de stockage de documents, tels que AWS S3 ou Google Cloud Storage que nous avons présentés précédemment. Les ressources déployées par ces services sont des compartiments de documents (en anglais, *bucket*) ; les opérations disponibles pour ces ressources sont conventionnelles (écriture, lecture, mise à jour), et leur fonctionnement interne n'est pas connu des usagers. Pour le stockage des données satellitaires, l'architecture mentionnerait donc le déploiement d'un tel conteneur.

Le choix en matière d'architecture relève de la satisfaction de certaines exigences. Par

exemple, ici, la première décision permet d'assurer l'agnosticisme vis-à-vis du fournisseur de services au détriment de l'effort de maintenance, que minimise la seconde décision.

a. Site Web de Minio, un SGBD pour les fichiers : <https://min.io/>.

Configuration de l'architecture

Le second artefact qui compose la description du système est la configuration de l'architecture. En effet, nous avons présenté dans la section précédente l'architecture du système, qui est indépendante d'un fournisseur de service. C'est la configuration de l'architecture qui spécifie, pour chaque élément de l'architecture, quel service le déploie et comme le service est configuré pour le déployer.

Éléments de configuration Tout comme l'architecture est composée d'éléments, la configuration de l'architecture comporte une arborescence en miroir : chaque élément de l'architecture doit être configuré. Poursuivons la modélisation pour les services de machines virtuelles à la demande. L'architecte doit préciser deux informations : le modèle de machine et les conditions du déploiement des machines.

D'une part, pour le modèle de la machine (*CMachineTemplate*), il s'agit d'explicitier les éléments de configuration pour tout ce qui doit être déployé. Cela inclut, par exemple, le service utilisé, le nom du gabarit de la machine ainsi que le type et la taille des disques (*CDiskTemplate*) qui lui sont associés. Il faut aussi configurer les tâches (*CTask*) des logiciels hébergés par la machine (*CSoftware*) : par exemple, si le logiciel téléverse des documents sur un compartiment d'objets, la configuration doit indiquer la classe de stockage de ces documents.

D'autre part, l'architecte doit configurer le plan de déploiement des machines. Pour une machine seule (*CSingleMachine*), il indique la zone (le centre informatique) dans laquelle elle est déployée. De plus, elle peut ne pas être tout le temps allumée. En effet, une organisation peut utiliser une machine dédiée au développement que pendant la journée, quand les développeurs l'utilisent ; elle est éteinte le reste du temps. Par conséquent, l'architecte peut associer à un déploiement de machine seule un agenda (*MachineSchedule*), qui indique quand allumer et éteindre la machine. Quant aux groupes de machines (*CMachineGroup*), ils sont configurés dans une région : chaque machine du groupe est déployée dans une zone de la région, en suivant une répartition choisie par le fournisseur de services. Les groupes de machines ont une taille initiale, c'est le nombre d'instances qu'ils comptent au déploiement du système. Leur taille peuvent varier si l'utilisateur configure une politique de mise à l'échelle automatique (*Autos-*

calingPolicy). La mise à l'échelle automatique procède comme suit : périodiquement, le groupe s'adapte en suivant une stratégie (*AutoscalingStrategy*). Une stratégie peut être d'adapter le groupe pour garder l'utilisation moyenne des processeurs en dessous d'un seuil. L'adaptation consiste en le déploiement ou la suppression d'un nombre de machines virtuelles. Ce nombre peut être borné par l'utilisateur, afin d'éviter leur multiplication à outrance (qui serait coûteuse). De plus, un pas de mise à l'échelle peut être spécifié pour limiter l'adaptation à chaque période (p. ex. ajouter au plus trois machines virtuelles par période).

Enfin, notons que l'architecte peut déclarer l'utilisation d'archives personnalisées de systèmes d'exploitation (*CCustomArchive*).

Souscription à un engagement Comme nous l'avons expliqué précédemment, un usager peut souscrire à un engagement pour limiter les coûts de l'environnement. Cela concerne un usage, associé à un *SKU*, et pour une certaine durée précisée par le type d'engagement pris par l'utilisateur, comme nous l'avons décrit précédemment.

Synthèse La figure 6.7 est le diagramme de classes des configurations de l'environnement décrites par l'architecte, restreint aux services de machines virtuelles à la demande.

Lors de la conception, il est pertinent d'expérimenter diverses configurations pour une même architecture : selon les décisions prises, les coûts varient. Il est souhaitable, par exemple, de connaître le surcoût lié à une légère augmentation des performances de calcul, afin d'aboutir aux meilleurs compromis. En séparant ce qui demeure stable (l'architecture) et ce qui varie dans les itérations de conception (la configuration de l'architecture), les documents peuvent simplement évoluer, ce qui simplifie la multiplication des estimations. Par conséquent, nous affirmons qu'il s'agit d'une modélisation pertinente de l'expertise des architectes dans un tel outil.

Exemple fil rouge

Selon l'architecture choisie, diverses décisions devront être prises dans la configuration de l'architecture. Pour l'exemple, considérons la seconde décision d'architecture que nous avons illustré ci-avant, à savoir le stockage des données satellitaires dans un compartiment de documents (*bucket*) déployé par un *PaaS*.

Il est souhaitable d'envisager diverses expérimentations.

Dans un premier temps, ces expérimentations peuvent porter sur la configuration d'un service. Considérons, par exemple, de déployer ce compartiment avec Google Cloud Storage. Il faut décider, en tout premier lieu, dans quels centres informatiques localiser le




FIGURE 6.7 – Diagramme de classes des configurations d'architecture décrites par l'architecte

compartiment. Cette décision affecte notamment la latence du réseau (dûe à la proximité avec les autres ressources de l'environnement, avec les utilisateurs du système informatique) et la politique de redondance des données. Ainsi, un compartiment peut être localisé dans une région, c'est-à-dire que ses données sont répliquées parmi trois centres informatiques géographiquement proches, soit dans une multirégion : elles sont répliquées dans un ensemble de régions qui couvre un continent. Ensuite, il faut décider de la classe de stockage par défaut utilisée pour les données, c'est-à-dire la qualité choisie pour la vitesse de lecture et d'écriture et, incidemment, le tarif pour les opérations et le stockage. Google Cloud Storage propose quatre classes de stockage dans toutes les localisations disponibles : *standard* (lecture et écriture très rapides et peu coûteuses, coût de stockage élevé), *nearline*, *coldline* et *archive* (lecture et écriture lentes et coûteuses, coût de stockage bas). Cette classe de stockage n'est pas assignée pour toujours, elle peut être changée, et cela peut-être fait automatiquement : la configuration peut également spécifier une politique de migration automatique de la classe de stockage d'un document, parmi les possibilités du service.

En tenant compte de ces considérations, nous pouvons envisager plusieurs configurations de l'architecture à expérimenter. Une première pourrait être de déployer le compartiment avec Google Cloud Storage dans la région *europa-west9* (correspondant à la région parisienne), d'utiliser *standard* comme classe de stockage par défaut, et de configurer le compartiment pour que toutes les données dont la classe de stockage est *standard* et qui n'ont pas été lues depuis deux mois soient migrées en *coldline*. Une deuxième configuration pourrait être identique, sauf pour la politique de migration qui devient : toutes les données dont la classe de stockage est *standard* et qui n'ont pas été lues depuis trois mois sont migrées en *archive*. Diverses variantes peuvent être envisagées afin de constater les effets de ces réglages sur les coûts engendrés et ainsi affiner la configuration.

Dans un second temps, nous pouvons envisager des expérimentations pour le choix du service. Par exemple, sur AWS S3 et Object Storage (Scaleway). Ces services ont différentes fonctionnalités. Ainsi, les centres informatiques ne sont, évidemment, pas les mêmes, tout comme les classes de stockage.

Pour l'exemple, nous pouvons donc considérer une troisième configuration, sur le service Object Storage de Scaleway, avec un compartiment localisé dans la région *PARIS* et avec comme classe de stockage par défaut *standard*. Comme ce service ne permet pas d'automatiquement mettre à jour la classe de stockage des documents, cela n'est pas

inclus dans cette troisième configuration.

6.2.5 Scénario

Comme nous l'avons précédemment argumenté, l'estimation des coûts d'un environnement infonuagique requiert, certes, une modélisation de l'environnement, mais il faut également compter le comportement des utilisateurs. Les coûts d'un environnement sur une période donnée varient en fonction de la nature des interactions, de leur nombre au cours de cette période ainsi que de la répartition des interactions au cours de la période. Par exemple, si les utilisateurs du système interagissent avec une machine virtuelle, cette machine virtuelle peut être suffisante si les interactions sont réparties également dans le temps tandis que d'autres machines virtuelles peuvent être nécessaires pour équilibrer la charge si les interactions se répartissent en pics. Par conséquent, la modélisation du comportement des utilisateurs doit englober la diversité et la distribution des interactions dans le temps, ce qui sous-tend une connaissance des utilisateurs eux-mêmes.

Dans les organisations, les acteurs possédant cette connaissance sont les analystes fonctionnels et les responsables de produit (en anglais : *Product Owners*). À notre connaissance, leur expertise est très peu sollicitée pour l'estimation des environnements infonuagiques. Certes, nous avons vu dans le chapitre 4 que certains simulateurs emploient le concept de scénario pour simuler une charge de travail pour un système infonuagique, p. ex. *CloudAnalyst* (WICKREMASINGHE, CALHEIROS et BUYYA, 2010) ou *GDCSim* (GUPTA, R. R. GILBERT et coll., 2011 ; GUPTA, BANERJEE et coll., 2014), mais cela est toujours envisagé comme le déclenchement d'exécutions de logiciels directement sur une instance, par des utilisateurs qui ont un accès total aux ressources de l'environnement infonuagique. Cela diffère absolument des utilisateurs plus fréquemment rencontrés dans l'industrie, qui n'ont pas de connaissance de l'infrastructure existante. Dans l'industrie, les outils disponibles compliquent la prise en compte de la contribution des experts fonctionnels. Nous notons également qu'anticiper le comportement des utilisateurs n'est pas aisé car il y a de nombreuses incertitudes, par exemple quant au succès commercial du système développé. Ainsi, nous proposons de reprendre le concept de scénarios afin que ces acteurs puissent effectivement modéliser plusieurs scénarios d'utilisation du système infonuagique, indépendamment des autres acteurs utilisateurs de l'outil d'estimation des coûts.

Le diagramme de classe de la figure 6.8 présente la modélisation des scénarios que nous proposons. Celle-ci se concentre sur l'identification de profils-types d'utilisateurs, fréquemment nommés des *persona* dans le domaine de l'expérience utilisateur. Un *persona* est une catégorie d'utilisateurs qui partagent des habitudes d'utilisation du système informatique. Un




FIGURE 6.8 – Diagramme de classes des scénarios décrits par l'expert fonctionnel

utilisateur effectue des parcours utilisateurs (en anglais : *user journey*). Ces parcours sont une succession d'action de la part de l'utilisateur (*UserOperation*), par exemple exécute une requête HTTP sur une *URL* du système infonuagique. De plus, ces parcours utilisateur ne se succèdent pas immédiatement : par exemple, un employé de bureau utilise le système à plus ou moins grande intensité au cours de sa journée de travail, et ne l'utilise pas en dehors de ses horaires de présence au bureau. Par conséquent, un fournisseur d'agendas pour les parcours utilisateurs (*JourneyScheduleSupplier*) permet de générer l'agenda de chaque utilisateur appartenant à un persona. En outre, un persona peut désigner un groupe de personnes très précisément localisées (p. ex. une agence dans une ville donnée) ou très largement réparties à travers un pays, un continent, la planète ; d'où la nécessité d'un générateur de localisation des utilisateurs (*UserLocationSupplier*) qui tient compte de la répartition géographique des utilisateurs pour générer l'endroit (*Place*) où chacun se situe. Enfin, le nombre d'utilisateurs d'un système informatique évolue dans le temps. Par exemple, un système informatique utilisé par les employés d'une entreprise gagne un utilisateur lors d'une embauche. La *population* associée à un persona débute avec un nombre initial d'utilisateur et croît en suivant un agenda (*UserSpawnSchedule*) qui peut suivre divers événements (p. ex. il est possible et utile de modéliser la croissance de la population d'un persona à la suite d'une campagne publicitaire, afin de constater les effets attendus d'une telle campagne sur les coûts du système).

Dans chaque scénario, l'expert fonctionnel doit identifier des groupes d'utilisateurs en établissant des stéréotypes.

Chaque stéréotype d'utilisateurs modélise une manière d'utiliser le système infonuagique, ce qui englobe trois notions. En premier lieu, le stéréotype contient des parcours d'utilisation type que les utilisateurs réalisent quand ils utilisent le système (p. ex. d'abord, l'utilisateur s'authentifie, puis il consulte les dernières publications, puis il se déconnecte). Ensuite, chaque utilisateur correspondant au stéréotype a un agenda d'utilisation du système qui lui est propre. Cela inclut les périodes d'activités (p. ex. des horaires de travail) et l'intensité de cette activité dans le temps (p. ex. l'utilisateur sollicite moins le système au début de sa journée de travail qu'au milieu de l'après-midi). Enfin, un stéréotype contient la localisation des utilisateurs. Ils peuvent être situés dans une région bien délimitée ou répartis dans le monde entier. La localisation de chaque utilisateur est importante dans le calcul des coûts d'utilisation du réseau : dans plusieurs cas, le tarif dépend du continent d'origine de la requête.

Pour chaque stéréotype, l'expert fonctionnel doit également en modéliser la population, c'est-à-dire le nombre fluctuant d'utilisateurs correspondant à ce stéréotype. Cela ne doit pas être confondu avec le nombre d'utilisateurs en train d'utiliser le système. Pour illustrer ce dernier point, nous pouvons considérer l'exemple de l'entreprise Netflix qui offre un service de vidéo à la demande et qui comptait 238 millions d'abonnés à la fin du deuxième trimestre de 2023, nombre qui a crû d'environ six millions d'abonnés lors de ce dernier trimestre⁷. Ces nombres sont la population d'utilisateurs du système de Netflix et sa fluctuation ; en outre, il ne fait aucun doute que les 238 millions d'abonnés n'utilisent pas le système simultanément et en permanence. Cette modélisation mobilise des concepts communs aux experts fonctionnels et, adossée à un stéréotype, permet d'estimer une utilisation vraisemblable du système infonuagique.

Exemple fil rouge

Différents profils d'utilisateurs peuvent être client d'un service d'imagerie satellitaire.

- Des utilisateurs ponctuels qui recherchent des images récentes de certaines parties du monde par curiosité ;
- Des utilisateurs professionnels réguliers qui se concentrent sur les images récemment capturées pour une même zone géographique. Par exemple, un agriculteur qui veut observer l'évolution de ses cultures ;
- Des chercheurs qui étudient l'historique d'une zone géographique sur plusieurs mois ;
- ...

7. Croissance de Netflix en 2023 : <https://www.lesechos.fr/tech-medias/medias/netflix-a-engrange-6-millions-dabonnes-supplementaires-au-deuxieme-trimestre-1963567>.

Selon la stratégie mercatique de l'agence spatiale, nous pouvons estimer l'évolution de la population de chaque profil d'utilisateurs, ce qui mène à la définition d'autant de scénarios.

6.2.6 Méthode de calcul des coûts

Les paragraphes précédents détaillent le modèle conceptuel de l'outil, en particulier les entrées de ce dernier. Cette section aborde la nature des résultats qu'il génère. Il n'est en effet pas évident de déterminer quelle information les organisations désirent obtenir lors d'une estimation des coûts. Les calculatrices de coûts, par exemple, aboutissent à un coût global de l'environnement et une répartition par service infonuagique. Si ces résultats permettent de comparer plusieurs concepts d'environnements entre eux, nous pensons qu'elle n'apporte pas suffisamment d'information pour identifier les défauts d'un environnement et permettre une correction.

Dans l'industrie, le rôle de *responsable FinOps* est apparu comme solution aux surcoûts expérimentés dans l'industrie. Un responsable *FinOps* analyse un système en cours d'exploitation pour suggérer des optimisations financières⁸. Pour ce faire, divers outils ont été développés. Ces derniers reposent notamment sur les traces de facturation générées par les fournisseurs de services : nous pouvons les assimiler à des lignes dans un tableau qui facturent un nombre d'unités facturées par le fournisseur de services. Une telle ligne contient diverses information dont : un identifiant de *SKU*, le nombre de *SKU* consommé, le coût de la consommation de ces *SKU*, une date d'émission de ce coût et une indication de la ressource qui a généré cette consommation de *SKU*. Toute la consommation du mois n'est pas rassemblé en une ligne, ce sont plutôt des agrégations sur de petits intervalles, par exemple une ligne par heure d'utilisation d'une machine virtuelle.

Actuellement, le rôle de responsable *FinOps* est limité à la phase d'exploitation du système, il n'intervient pas auparavant. Or, ils possèdent une expertise pour l'optimisation des coûts, ce qui motive l'intérêt de les intégrer au processus de conception. Ainsi, nous jugeons pertinent que le résultat d'une exécution de l'outil d'estimation des coûts prenne la forme de traces de facturation analysable par le responsable *FinOps* avec ses outils et pratiques usuelles. Cette intégration permet de mettre en place une boucle de rétroaction dans la conception, avec l'interaction du responsable *FinOps* et de l'architecte afin de converger vers une solution finan-

8. Présentation du *FinOps*, par la Fondation *FinOps* : <https://www.finops.org/introduction/what-is-finops/>.

cièrement plus efficiente.

6.3 Satisfaction des buts

6.3.1 Buts satisfaits

Estimation des coûts à la conception (B_3)

Comme nous l'avons expliqué, ce modèle conceptuel ne requiert pas le déploiement d'un environnement infonuagique. La contribution du fournisseur de services se limite ici à la modélisation de son catalogue et des tarifs de ses services. Par conséquent, nous considérons qu'un outil implémentant ce modèle conceptuel satisfait le but B_3 .

Fil numérique (B_4)

Nous avons introduit le concept de fil numérique en soulignant qu'il était important pour l'industrie de pouvoir réutiliser les artefacts générés lors d'une itération de développement, à l'itération suivante. En effet, régénérer l'ensemble des artefacts à chaque itération est chronophage et peut introduire des erreurs liées aux saisies ou à la perte progressive de connaissances pour certains aspects du projet.

Les artefacts générés par les architectes et les experts fonctionnels sont sauvegardables et réutilisables. En outre, ils sont exprimés dans le vocabulaire des acteurs qui doivent les rédiger. Ce dernier point est important pour l'évolutivité des artefacts, car l'évolution d'un système infonuagique est considérée, par les architectes, comme une modification d'un existant (p. ex. remplacer un groupe de machines virtuelles par un déploiement de conteneurs, ajouter un serveur de cache en amont d'une base de données). Ainsi, les artefacts produits lors d'une itération peuvent être réutilisés à l'itération suivante en répercutant uniquement les modifications désirées, ce qui satisfait le but B_4 .

Coopération des parties prenantes (B_5)

Comme nous l'avons argumenté, séparer les préoccupations est une stratégie commune pour aider la coopération entre les parties prenantes d'un processus. Dans le modèle conceptuel que nous proposons, l'architecte et l'expert fonctionnel sont des acteurs qui interviennent sur des documents quasiment indépendants. Cela est possible en demandant à ces acteurs de rédiger ensemble un contrat, qui est la base sur laquelle repose chacune de leurs contributions à

l'estimation des coûts. Nous considérons donc qu'un outil implémentant ce modèle conceptuel satisfait le but B_5 .

6.3.2 Autres buts

Deux buts restent à satisfaire : faciliter la prise en compte de la mise à l'échelle automatique de l'environnement (B_1) et celle des interactions au sein de l'environnement (B_2). Les artefacts générés par l'architecte et l'expert fonctionnel contiennent les informations en rapport avec ces deux buts : l'architecte décrit les mécaniques de mise à l'échelle automatique de l'environnement dans la configuration de l'architecture, et le scénario généré par l'expert fonctionnel permet de savoir quelles interactions avec l'environnement ont lieu. La satisfaction de ces deux buts est donc possible et dépend de la *méthode de calcul des coûts*.

6.4 Conclusion

Dans ce chapitre, nous avons présenté le besoin de l'industrie pour un outil d'estimation des coûts d'un environnement infonuagique, ce qui nous a amené à développer un modèle conceptuel permettant ce type d'estimation.

Néanmoins, le modèle seul ne suffit pas à satisfaire à tous les besoins de l'industrie. En outre, il comporte un dernier élément, une méthode de calcul, qui reste à déterminer. Une implémentation de ce modèle est nécessaire pour lever ces difficultés.

Dans le chapitre suivant, nous présentons l'outil que nous avons développé à cet effet.

Chapitre 7

Développement d'un outil d'estimation des coûts opérationnels d'une conception préliminaire de système infonuagique

Suite à la définition du modèle conceptuel présenté dans le chapitre précédent, nous avons procédé au développement d'un outil qui l'implémente.

Cet outil se nomme Ymir. Il s'agit d'un logiciel libre, sous licence *LGPL* et dont le code source est accessible à l'adresse suivante : <https://gitlab.com/stack-labs/oss/ymir>. C'est un logiciel modulaire écrit en Java, composé d'une interface en ligne de commande permettant de procéder à des estimations mais également de bibliothèques qui peuvent être utilisées pour l'étendre; nous l'avons, en effet, conçu pour être évolutif. L'une de ces extensions a vu le jour dans un projet auquel Stack Labs a participé, et pour lequel nous avons développé des services Web qui exposent les fonctionnalités d'Ymir et que nous exécutons sur un nuage public.

Dans ce chapitre, nous détaillons les modèles de Ymir permettant l'estimation des coûts d'un environnement infonuagique. En particulier, le modèle conceptuel présenté dans le chapitre précédent comporte un élément, une méthode de calcul, qui restait à déterminer. Dans Ymir, nous avons choisi de procéder par simulation à événements discrets. En effet, la simulation à événements discrets est communément utilisée dans l'industrie pour la conception, l'estimation et l'amélioration de processus de manufacture, ainsi que pour déterminer des politiques opérationnelles optimales (BABULAK et M. WANG, 2008). Cette technique permet no-

tamment d'accélérer les analyses, d'améliorer notre compréhension du système simulé et d'en expérimenter des variantes, sans être limité par la difficulté de manipulation et le coût de ce système (FISHMAN, 2001). En outre, c'est une modélisation qui permet de tenir compte de la temporalité des traitements (p. ex. transferts sur le réseau, écriture et lectures sur un disque) ainsi que des interactions dans le système et son adaptation en continu.

Ce chapitre est organisé de la manière suivante. Dans la section 7.1, nous détaillons les modèles d'Ymir et expliquons comment ils permettent d'évaluer le coût d'un environnement infonuagique avec les données générées par les parties prenantes d'une organisation. Puis, dans la section 7.2, nous illustrons l'utilisation d'Ymir avec l'exemple fil rouge. Ensuite, nous expliquons l'état actuel de l'utilisation d'Ymir dans l'industrie dans la section 7.3 avant, enfin, de conclure en section 7.4.

7.1 Détail de l'implémentation d'Ymir

Comme nous l'avons expliqué dans l'introduction, Ymir est un simulateur à événements discrets permettant d'évaluer les coûts d'un environnement infonuagique.

Dans cette section, nous présentons les éléments permettant à Ymir d'effectuer ses estimations. D'une part, nous expliquons les modèles utilisés pour la simulation dans la sous-section 7.1.1. D'autre part, nous présentons le modèle simulé et ses relations avec les artefacts générés par les parties prenantes de l'estimation dans la sous-section 7.1.2.

7.1.1 Modèles de simulation

Dans cette sous-section, nous présentons les éléments à la base du simulateur à événements discrets que nous avons développé. Ce modèle, présenté dans la figure 7.1, s'inspire largement des concepts proposés dans le deuxième chapitre du livre *Discrete Event Simulation : Modeling, Programming and Analysis* de FISHMAN (2001).

Moteur de simulation

Lors d'une simulation à événements discrets, un modèle simulé (dans notre cas, le système infonuagique, que nous présentons dans la sous-section suivante) évolue au fur et à mesure par l'exécution d'événements (*Event*). Ces événements peuvent être créés et associés à une date dans un agenda (*EventScheduler*) par le modèle simulé lui-même ou par une source extérieure (dans notre cas, les scénarios définis par l'expert fonctionnel).




FIGURE 7.1 – Diagramme de classes de la base du simulateur

Pour parvenir à fixer une date, une horloge de la simulation (*SimulationClock*) permet de consulter la date simulée.

Le moteur de la simulation à événement discrets (*SimulationEngine*) est responsable de l'avancée de la simulation dans le temps. Il n'a pas connaissance directement du modèle simulé : ce sont les événements qui font le lien avec le modèle simulé. Le moteur est un agenda : il enregistre les événements à exécuter à une date donnée (*EventNotice*). Il peut aussi exécuter le prochain événement dans l'ordre chronologique (méthode *triggerNextEvent*) : dans la simulation à événements discrets, le temps avance par bonds, d'événement en événement, et non par pas de temps.

Processus

La notion de processus apparaît naturellement dans la modélisation de systèmes infonuagiques. En effet, de nombreux traitements prennent du temps à aboutir et une suite logique de traitements, aux durées qu'il n'est pas toujours possible de prédire en amont, doivent être modélisés. Nous avons donc introduit la notion de processus (*Process*) qui conceptualise ces traitements qui prennent du temps.

Dans Ymir, les processus sont des objets exécutés sur le fil d'exécution (en anglais : *Thread*) du programme. Cela diffère d'implémentations répandues pour la simulation à événements discrets. Nous pouvons par exemple citer la bibliothèque SimPy¹ dans laquelle chaque processus simulé est exécuté sur son propre fil d'exécution, ou la bibliothèque SimJava² dans laquelle chaque composant du modèle simulé a son propre fil d'exécution. Ymir s'exécute sur un unique fil d'exécution, ce qui permet la reproductibilité des simulations (dans les outils utilisant plusieurs fils d'exécution, cela exigerait des mécanismes supplémentaires qui nuisent aux performances qu'ils tirent de la distribution des traitements sur plusieurs fils).

Caractéristiques des processus Nous notons trois caractéristiques des processus.

D'abord, les processus ont un terme, qu'ils approchent au fur et à mesure de la simulation en avançant (méthode *forward*). Au terme d'un processus (méthodes *terminate*), un comportement propre au type de processus peut survenir (méthode *executeWhenTerminated*). Par exemple, un processus correspond à l'allumage d'une machine virtuelle qui arrive à son terme mute l'état de la machine virtuelle pour qu'elle soit, effectivement, allumée. Ce comportement n'est cependant pas le seul, ce qui amène à une autre caractéristique des processus.

En effet, la deuxième caractéristique des processus est qu'ils peuvent être hiérarchisés. Cela est nécessaire car un système infonuagique est composé de plusieurs éléments qui peuvent être

1. Documentation de SimPy : <https://simpy.readthedocs.io>.

2. Documentation de SimJava : <https://www.icsa.inf.ed.ac.uk/research/groups/hase/papers/simjava/>.

mobilisés et qui ont leurs propres tâches à réaliser. Par exemple, si un utilisateur du système infonuagique envoie une requête *HTTP* (synchrone), il s'agit d'un premier processus que nous pouvons modéliser en trois étapes : (1) un transfert depuis le terminal de l'utilisateur vers l'environnement infonuagique, (2) le traitement de la requête par l'environnement infonuagique, (3) un transfert depuis l'environnement infonuagique vers le terminal de l'utilisateur. Cependant, le traitement de la requête n'est pas immédiat : il peut nécessiter un temps de calcul, des interactions au sein de l'environnement (p. ex. lecture sur le disque ou sur un *SGBD*) ; cela constitue un second processus (2.1), sous-processus de l'étape (2), qui peut lui-même avoir des sous-processus. Afin de modéliser cette hiérarchie, les processus peuvent avoir un processus parent (affecté par la méthode *setParent*) et, s'ils ont un parent, alors ils lui permettent d'avancer à nouveau.

Enfin, un processus peut être interrompu pour une autre raison que l'existence d'un sous-processus. En effet, dans certains cas, le déroulé d'un processus peut nécessiter une attente qui ne peut se mesurer par le temps mais par la satisfaction de conditions. Par exemple, une requête envoyée à l'adresse *IP* d'un déploiement de conteneurs qui n'a pas de conteneur disponible devra être mise en attente le temps qu'un conteneur devienne disponible (car nouvellement allumé par le déploiement ou ayant terminé de traiter une autre requête).

Types de processus De la définition des processus et des caractéristiques que nous avons identifiées utiles, nous avons modélisé trois types de processus.

D'un côté, nous avons modélisé des activités (*Activity*). Une activité a une durée au bout de laquelle elle s'achève : elle ordonne dans l'agenda un événement correspondant à sa terminaison (*ActivityFinishedEvent*) à la date courante plus cette durée. Un exemple d'activité est un transfert d'un paquet sur le réseau. Un paquet est une petite quantité de données qui transite en une fois sur le réseau. La durée du transfert dépend des localisations de l'émetteur du paquet et de son destinataire, de la qualité du réseau ainsi que de sa topologie (deux points géographiquement proches ne sont pas forcément directement reliés).

De l'autre côté, nous avons modélisé des charges de travail (*Workflow*). Il s'agit d'une succession d'étapes (*WorkflowStep*). Quand une charge de travail est démarrée (premier appel à la méthode *forward* de *Process*), il poursuit l'avancement, c'est-à-dire l'exécution des étapes, tant que possible. Cet avancement s'interrompt à deux occasions. Soit toutes les étapes ont été exécutées, auquel cas l'exécution de la charge de travail est terminée. Soit l'une des étapes génère un nouveau processus. Dans ce second cas, la charge de travail devient le parent de ce processus et s'interrompt jusqu'à ce que ce processus l'avertisse de reprendre son cours. Un exemple de charge de travail est un transfert de données d'une requête *HTTP*. Dans un tel processus, les données à transférer sont divisées en petits paquets envoyés individuellement. Il s'agit donc

d'une charge de travail qui compte autant d'étapes qu'il y a de paquets à transférer.

Enfin, nous avons modélisé des processus reportés (*PostponedProcess*). Un processus de ce type est créé quand un processus ne peut pas poursuivre dans l'immédiat. Par exemple, un calcul a été demandé à un processeur surchargé, qui remet ce calcul pour quand il sera en mesure de le traiter. Dans ce cas, le processus reporté est l'enfant du processus principal, et il ne peut pas avancer tant qu'il n'a pas été relancé (méthode *resume*). Un reporteur de processus (*ProcessPostponer*) est utilisé par les structures qui nécessitent ce mécanisme : il s'agit d'une file d'attente de processus reportés, qui vérifient que le processus suivant puisse effectivement être relancé.

7.1.2 Simulation pour la génération des coûts

Après avoir présenté les fondements du simulateur à événements discrets que nous avons implémenté, nous présentons dans cette section comment ce simulateur permet de générer les coûts d'un système infonuagique. Le modèle simulé est décomposable en modules correspondant à chaque type de services infonuagiques, auxquels s'ajoute une base commune.

Dans un premier temps, nous présentons le socle commun aux services infonuagiques simulés, puis nous développons un exemple : la simulation des services de conteneurs à la demande.

Composants matériels

Comme nous l'avons précédemment expliqué, l'usager d'un nuage public n'a pas de connaissance quant à la constitution du centre informatique et des couches logicielles qui mettent à disposition les services infonuagiques qu'il utilise. Cependant, modéliser certains aspects d'une infrastructure est utile afin de simuler la durée de certains traitements, tels que l'écriture et la lecture sur un disque dur, ainsi que les interactions entre ressources. Ainsi, nous présentons dans la figure 7.2 le diagramme de classes des éléments d'infrastructure que nous avons implémenté.

La notion de système d'exploitation apparaît dans la modélisation de plusieurs ressources, telles que pour les conteneurs déployés par les services de conteneurs à la demande ou pour les machines virtuelles. Le système d'exploitation est le logiciel qui tire parti des dispositifs branchés à son hôte (*OperatingSystemHost*). Notre modélisation retient trois de ces dispositifs : ses ressources de calcul, ses interfaces avec le réseau et ses dispositifs de stockage.




FIGURE 7.2 – Diagramme de classes des composants matériels

Interfaces avec le réseau Les ressources infonuagiques sont accessibles depuis le réseau : elles possèdent une adresse *IP* (*IpAddress*) qu'un utilisateur du système infonuagique ou qu'une autre ressource peut utiliser pour effectuer des transferts de données. De même, les initiateurs de transferts de données possèdent une adresse *IP*.

Un protocole très répandu pour la communication sur le réseau est *HTTP*. Il s'agit d'un protocole synchrone, c'est-à-dire que l'initiateur de la communication ouvre une connexion en envoyant une requête, et cette connexion s'achève quand le destinataire a répondu. Nous avons modélisé ces communications en une charge de travail d'interaction synchrone (*SynchronousInteractionWorklow*) qui est composé de trois étapes : d'abord l'émission de la requête, puis le traitement de la requête, et enfin l'émission de la réponse. L'émission de la requête et de la réponse sont des activités de transfert sur le réseau (*NetworkTransferActivity*) : sa durée dépend de la taille du message transféré et des positions de l'initiateur de la communication et de son destinataire³.

Stockage Un hôte de système d'exploitation peut être connecté à des dispositifs de stockage (*StorageDevice*), tels que des disques durs. Ces composants découpent l'information en secteurs de même taille. La taille de ces secteurs dépend du matériel, même s'il existe des standards ; certains fournisseurs de services communiquent sur cette information, ou permettent de la configurer afin de satisfaire certains cas d'usage. En effet, la taille de secteur influe sur la vitesse de lecture et d'écriture (plus la taille de secteur est grande, plus le dispositif doit lire ou écrire de bits lors d'une opération) ainsi que pour le nombre de fichiers réellement stockables. Les systèmes de fichiers récents (p. ex. *ext4*) ne fragmentent pas les secteurs, ce qui signifie qu'avec un tel système de fichiers, le nombre maximum de fichiers que peut stocker un dispositif de stockage est au plus son nombre de secteurs : cela peut accélérer le besoin de mise à l'échelle des ressources de stockage dans l'environnement infonuagique.

Ressources de calcul L'hôte d'un système d'exploitation dispose de ressources pour effectuer des calculs : des processeurs (*ProcessingUnit*) et de la mémoire vive (*RandomAccessMemory*). Ces ressources sont surveillées et attribuées par le système d'exploitation pour effectuer ses tâches.

Cette modélisation est simpliste. Par exemple, nous aurions pu modéliser une mémoire vive composée de barrettes hétérogènes, avec différentes performances de lecture et écriture. Cependant, et à nouveau, ce genre d'informations ne sont pas suffisamment communiquées

3. Pour se conformer à la réalité, cette activité devrait être une charge de travail : le message est divisé en paquets transmis séparément et le message est reconstitué par le destinataire. Divers aspects tels que la topologie du réseau et la bande passante sont également à prendre en compte. Nous avons simplifié la modélisation à ce niveau car nous n'avons pas étudié de cas où la bande passante pourrait être un facteur limitant dont il faut tenir compte.




FIGURE 7.3 – Diagramme de classes des systèmes de fichiers

et la mise en commun des machines physiques pour plusieurs ressources infonuagiques ne nous permet pas d'avoir des assurances quant aux performances dont bénéficie réellement l'environnement infonuagique. Les portions de processeurs et de mémoire vive utilisables sont, quant à elles, bien identifiées.

Système d'exploitation

Plusieurs ressources infonuagiques sont dotées d'un système d'exploitation (*OperatingSystem*) capable d'exécuter les logiciels de l'utilisateur (*SoftwareFeatureExecutor*). Ce système d'exploitation est déployé sur un hôte, et peut interagir avec les dispositifs de stockage de cet hôte en installant un système de fichiers. Dans les paragraphes suivants, nous détaillons ces aspects et nous appuyons sur deux diagrammes de classes : la figure 7.3 pour les systèmes de fichiers et la figure 7.4 pour les systèmes d'exploitation.




FIGURE 7.4 – Diagramme de classes des systèmes d'exploitation

Systèmes de fichiers Nous avons vu que les dispositifs de stockage ont une taille de secteurs, qui dépend de la configuration de l'environnement. Cependant, la taille d'un fichier n'est pas forcément un multiple de cette taille de secteurs, la taille d'un fichier relève de la connaissance du métier et dépend du contrat passé entre l'architecte et l'expert fonctionnel. Par ailleurs, un système d'exploitation ne lit pas directement les secteurs d'un dispositif de stockage, c'est la tâche d'un système de fichiers (*FileSystem*). Un système de fichiers tient note des secteurs où retrouver les données associées à un fichier, ou *inode*.

Le système de fichiers peut initier deux types de charges de travail : un pour créer un fichier (*CreateInodeWorkflow*) et un autre pour le lire (*ReadInodeWorkflow*). Chacune de ces charges de travail répètent autant de fois que le nombre de secteurs à lire ou à écrire leur opération de lecture ou d'écriture sur le dispositif de stockage.

Fonctionnalités logicielles Comme nous l'avons montré dans les modèles pour les entrées générées par l'architecte, nous avons choisi de ne pas modéliser les logiciels unitairement, par exemple un serveur *Web*, mais des fonctionnalités logicielles (*SoftwareFeature*), correspondant par exemple à chaque route *HTTP* d'un serveur *Web*.

Une fonctionnalité logicielle repose sur un contrat (*SoftwareFeatureContract*) qui fait partie du contrat passé entre l'architecte et l'expert fonctionnel. Ce contrat précise le format de la requête et de la réponse. En outre, une fonctionnalité logicielle est définie par une séquence d'exécution qui sont utilisées dans une charge de travail lorsque la fonctionnalité est exécutée (*SoftwareFeatureExecutionWorkflow*). Cette séquence d'exécution est constituée d'étapes (*WorkflowStep*, présentée précédemment) diverses, correspondant par exemple à la création d'un fichier ou à l'exécution d'une fonctionnalité logicielle sur une autre ressource.

Composant de mise à l'échelle automatique de groupes d'instances

De nombreux services infonuagiques disposent de mécanismes de mise à l'échelle automatique. Cette appellation désigne communément la mise à l'échelle automatique des groupes de machines virtuelles : de nouvelles machines virtuelles sont déployées quand le trafic est important. Cependant, nous devons considérer que d'autres mécanismes, complètement intégrés au fonctionnement de certains services infonuagiques, sont également des mécanismes de mise à l'échelle automatique. Par exemple, les compartiments de documents (en anglais : *Bucket*) adaptent l'espace disque alloué à l'environnement en fonction des documents stockés : un tel compartiment est mis à l'échelle à chaque opération d'écriture. Ces mécanismes sont néanmoins propres à chaque service, tandis que nous pouvons modéliser un composant commun de mise à l'échelle de groupes d'instances, qu'il s'agissent par exemple de machines virtuelles ou de conteneurs, que nous présentons dans la figure 7.5.

Un groupe d'instances est un déploiement redimensionnable de ressources (*ResizableDeployment*), c'est-à-dire qu'il est possible d'ordonner l'ajout (méthode *scaleOut*) et la suppression (méthode *scaleIn*) d'une ressource. Un composant de mise à l'échelle automatique (*Autoscaler*) a pour tâche de redimensionner (méthode *resize*) périodiquement ce déploiement. Cette période se nomme *période de stabilisation*, qui correspond à un temps durant lequel le déploiement est surveillé pour déterminer le nombre de ressources nécessaires devraient être utiles. Le redimensionnement périodique est assuré par un événement de mise à l'échelle automatique (*AutoscalingEvent*) qui est ordonné une fois par période de stabilisation. De plus, le composant de mise à l'échelle automatique dispose d'une politique (*AutoscalingPolicy*) qui détermine ce qu'il est possible de faire et comment. Cette politique renseigne le minimum et le maximum d'instances du déploiement, ainsi qu'un pas, c'est-à-dire le nombre maximum d'instance ajoutable ou supprimable à l'issue d'une période de stabilisation. Enfin, la politique porte un créateur de stratégies de mise à l'échelle automatique (*AutoscalingStrategyFactory*). Ce dernier crée des stratégies (*AutoscalingStrategy*) adaptées au déploiement. Une telle stratégie détermine à chaque instant le nombre d'instances qu'il conviendrait de disposer au sein du déploiement (méthode *computeRecommendedNumberOfInstances*).

Le diagramme comporte un exemple de stratégie de mise à l'échelle automatique, basée sur l'utilisation des processeurs des instances du déploiement (*ProcessorBasedAutoscalingStrategy*). Cette stratégie a deux paramètres principaux. D'une part, une valeur décimale mutable (*DoubleHolder*) pour l'utilisation mesurée des processeurs. Cette valeur est une interface à dessein. En effet, selon le fournisseur de services ou la politique désirée, la valeur à retenir à chaque période diffère : par exemple, il peut s'agir de la valeur moyenne ou du maximum. Elle est mise à jour à grande fréquence par un événement de surveillance des processeurs (*MultipleProcessorMonitoringEvent*). D'autre part, cette stratégie a une cible pour l'utilisation des processeurs, qui est un pourcentage configurable par l'utilisateur ou imposé par le service infonuagique. Par exemple, le service de conteneurs à la demande Cloud Run de Google Cloud Platform a une stratégie de mise à l'échelle automatique qui surveille l'utilisation moyenne des processeurs et fixe une cible de 60% d'utilisation : si la valeur mesurée dépasse ce pourcentage, alors Cloud Run ajoute une ou plusieurs instances.

Système infonuagique

Pour finir avec les modules communs aux divers services infonuagiques simulés, la figure 7.6 est le diagramme de classes du système infonuagique, qui inclut la base pour l'activation de services infonuagique ainsi que le générateur de traces de facturation.

Le système infonuagique (*CloudSystem*) peut activer des services infonuagiques (*Enabled-*




FIGURE 7.5 – Diagramme de classes du composant de mise à l'échelle automatique de groupes d'instances

CloudSystem) afin que ces derniers alimentent l'environnement en ressources. Son association à l'agenda d'événements n'a pour but que de pouvoir le transmettre aux services activés, tout comme il leur transmet un observateur des consommations de services infonuagiques (*CloudConsumptionObserver*), utilisé par les services infonuagiques et leurs ressources pour signaler qu'une quantité de *SKU* a été consommée par l'utilisateur.

Génération des traces de facturation Une implémentation évidente de cet observateur est le générateur de factures (*BillingGenerator*). Quand une consommation est signalée, le générateur de factures consulte les tarifs pour déterminer si une règle de facturation est concernée par l'usage consommé. Si aucune règle n'y est associée, rien ne se passe. Autrement, il y a deux cas. Si la règle de facturation n'a pas d'intervalle d'agrégation, alors une trace de facturation est générée immédiatement et transmise à un imprimeur de traces de facturation (*BillingLogWriter*), qui la prend en charge de manière à ce que le responsable *FinOps* puisse l'exploiter (p. ex. écriture sur une base de données ou dans un fichier) Si la règle a un intervalle d'agrégation, alors il crée ou met à jour un accumulateur de dépenses dédié à cette règle de facturation (*BillingAggregationAccumulator*). Puis, si aucune autre règle dans la période courante ne partage le même intervalle d'agrégation, un événement d'agrégation (*AggregateCostEvent*) est ordonné pour la fin de l'intervalle : à cette date, il ordonnera au générateur de factures de générer les traces de facturation pour tous les accumulateurs associés à cet intervalle.

Suivi des engagements de l'utilisateur Enfin, nous avons évoqué précédemment les engagements (*Commitment*) que peuvent prendre les utilisateurs. Nous les modélisons comme une quantité d'unités d'un ensemble d'usages que l'utilisateur doit dépenser au cours d'une période, classiquement un mois. Un exemple d'engagement que nous pouvons modéliser avec le fournisseur de services Google Cloud Platform : un engagement sur trois ans d'utiliser, chaque mois, seize coeurs *CPU* de la famille *E2* dans la région *europa-west9*. Il en résulte un engagement d'utiliser 11520 heures⁴ (association avec *ConsumptionMeasure*), pour trois usages du type *MachineCoreType* (un par zone qui constitue *europa-west9*) et le type d'engagement correspondant à un engagement sur trois ans.

Cet engagement doit être enregistré dans un traqueur d'engagement (*CommitmentTracker*). Ce dernier est consulté par le générateur de factures lors d'une consommation, afin de déterminer si l'usage associé à la consommation fait l'objet d'un engagement (méthode *interceptConsumption*). Si c'est le cas, alors le traqueur vérifie s'il reste des unités à consommer dans cet engagement pour la période courante, en déduit le nécessaire, et transmet l'éventuel reste à payer au générateur de factures.

4. Un mois dure approximativement 720 heures, multiplié par 16 coeurs *CPU*.

Au début de chaque mois, les engagements génèrent une trace de facturation qui leur est associée. Avec notre exemple, les 11520 heures de l'engagement sont facturées d'un coup en utilisant la règle de tarification associée au type d'engagement. Cela est assuré par un événement de génération de la facture pour les engagements (*CommitmentBillGenerationEvent*), qui demande cette génération au traqueur ainsi que la remise à zéro des engagements pour la nouvelle période.

Simulation des coûts de services de conteneurs à la demande

L'ensemble des éléments présentés ci-avant sont les bases sur lesquelles le simulateur est fondé. Le reste est décomposé en services infonuagiques activés par l'utilisateur. Dans cette partie, nous prenons l'exemple des services de conteneurs à la demande pour expliquer comment la simulation peut générer les coûts d'un système en cours d'utilisation. La modélisation que nous en avons est séparée en deux figures par soucis de lisibilité : la figure 7.7 présente la base des services de conteneurs à la demande, et la figure 7.8, les éléments spécifiques à leur utilisation en tant que serveurs.

Déploiements de conteneurs Un service de conteneurs à la demande activé (*EnabledContainerService*) gère des déploiements de conteneurs (*ContainerDeployment*), c'est-à-dire qu'il les crée, les répertorie et les supprime à la demande de l'utilisateur. Classiquement, nous trouvons deux types de déploiements de conteneurs : les déploiements pour une tâche, qui activent périodiquement un conteneur pour effectuer une tâche en particulier, et les déploiement de serveurs. Étant donné la prééminence que nous avons constatée pour l'usage du second type de déploiement, c'est sur celui-ci que nous nous concentrons.

Un déploiement de conteneurs-serveurs (*ServerContainerDeployment*) est un déploiement redimensionnable d'instances, ainsi que nous l'avons présenté ci-avant : à tout instant, il peut ajouter ou supprimer un conteneur. Il peut donc être associé à un composant de mise à l'échelle automatique, qui est configuré par le service de conteneurs à la demande activé.

Instances de conteneur Un déploiement de conteneur crée des conteneurs à partir d'un modèle (*ContainerInstanceTemplate*). Ce modèle précise les ressources allouées à un conteneur, à savoir le nombre de coeurs *CPU* et la taille de sa mémoire vive, et la région dans laquelle ces ressources sont déployées. De plus, il énumère les fonctionnalités logicielles disponibles sur ces conteneurs. Enfin, il fixe le nombre maximum de requêtes qu'un conteneur peut traiter en parallèle, et la durée d'allumage d'un conteneur. Ces informations sont utilisées à plusieurs fins.




FIGURE 7.6 – Diagramme de classes du système infonuagique

D'abord, pour gérer son cycle de vie (*ContainerLifecycleMonitor*). Ce dernier consiste en un statut (*ContainerStatus*) qui change au fur et à mesure des ordres donnés par le déploiement. Un conteneur démarre son existence « *non-alloué* », c'est-à-dire que le fournisseur de services ne lui a pas attribué de ressources : à cet instant, il ne coûte rien. Quand le déploiement ordonne l'allumage d'un conteneur, le statut du conteneur choisi devient « *en cours d'allumage* » et une activité d'allumage de conteneur (*StartContainerActivity*) est initiée. Cette activité a pour durée celle précisée dans le modèle de conteneurs. Au terme de l'activité, le statut du conteneur devient « *allumé* ». Quand le déploiement requiert l'extinction du conteneur, le statut est immédiatement changé en « *non-alloué* ». Il existe cependant des subtilités au cycle de vie d'un conteneur. D'une part, la configuration de la mise à l'échelle automatique peut exiger l'existence d'un nombre minimum d'instances, qui doivent avoir connaissance de leur particularité (grâce à l'attribut *mustRemainAllocated*) : ces conteneurs ne seront jamais désalloués. D'autre part, le service de conteneurs impose une durée minimum d'inactivité avant la désallocation d'un conteneur, ce qui doit être pris en compte par le déploiement pour sélectionner un conteneur désallouable.

Ensuite, le déploiement de conteneur utilise les informations du modèle pour configurer le système d'exploitation hébergé par le conteneur. En effet, un conteneur est un hôte de système d'exploitation, ainsi que nous l'avons présenté dans la section 7.1.2. Les logiciels hébergés par ce logiciel sont ceux définis dans le modèle de conteneurs.

Enfin, ces informations sont utilisées par le conteneur pour générer les dépenses associées à l'allocation de ses ressources (coeurs *CPU* et mémoire vive). Les usages générés dépendent de s'il est actuellement en train d'exécuter un logiciel (*ContainerResourceUsage*) ou non (*ContainerIdleResourceUsage*). Dans le second cas, il est important de savoir si le conteneur est là pour satisfaire le nombre minimum d'instances de conteneurs (attribut *mustRemainAllocated*), car les tarifs dans ce cas ne sont pas les mêmes que pour les autres conteneurs. Les informations du modèle de conteneurs permettent de déterminer la quantité consommée de ces usages. Ces usages sont générés périodiquement grâce à un événement récurrent de surveillance de l'allocation du conteneur (*ContainerAllocationMonitoringEvent*), qui démarre dès le passage du conteneur au start « *en cours d'allumage* » et cesse dès qu'il devient « *non-alloué* ».

Interaction avec l'environnement et les utilisateurs Les utilisateurs du systèmes et ressources désireuses d'exécuter un logiciel hébergé sur les conteneurs d'un déploiement de serveurs-conteneurs ne peuvent y accéder directement : ils passent par une adresse *IP* (*CloudDeploymentIpAddress*) appartenant au déploiement, et celui-ci redirige la requête vers un conteneur grâce à un équilibreur de charges. Cette adresse *IP* est responsable de la génération des usages en lien avec les interactions sur le réseau : les entrées (*IngressUsage*) et les sorties (*EgressUsage*);

le type réel de ces usages dépend d'où provient ou vers où est dirigée l'interaction (au sein de la région du conteneur, dans une zone ou une multi-région, hors du fournisseur de services).

De son côté, l'équilibreur de charges (*ServerContainerLoadBalancer*) sélectionne un conteneur pour traiter une requête, grâce à une stratégie d'équilibrage (*BalancingStrategy*). Une telle stratégie très connue est *round-robin* : les instances disponibles sont interrogées chacune à leur tour, puis de nouveau une fois que toutes les instances ont été interrogées. Il se peut qu'aucun conteneur ne soit disponible à l'arrivée d'une requête, dans deux cas de figure : soit tous les conteneurs sont suffisamment occupés (ils ont autant de requêtes à traiter que le maximum fixé par leur modèle), soit il n'y a pas du tout de conteneur, ce qui est possible si le composant de mise à l'échelle a un minimum d'instances à zéro. Dans ce cas, la requête est mise en attente le temps qu'un conteneur se libère ou qu'un nouveau conteneur soit créé. Pour modéliser cette mise en attente, nous avons défini un processus reporté d'exécution d'une fonctionnalité logicielle (*PostponedContainerSoftwareFeatureExecutionProcess*), qui est relancé quand l'équilibreur de charge est averti qu'un conteneur s'est libéré (méthode *acknowledgeContainerFinishedProcessing*) ou qu'un nouveau conteneur aie été créé (méthode *acknowledgeContainerStarted*).

Enfin, quand l'équilibreur de charges reçoit une requête à traiter, il génère une consommation associée à la réception de cette requête (*ContainerRequestUsage*).

7.2 Application à l'exemple fil rouge

Cette section est dédiée à l'illustration de l'usage de l'outil d'estimation des coûts dans le cadre de la conception du système de l'exemple fil rouge. De cette manière, nous pourrons constater si, dans cette situation, il satisfait les buts que nous lui avons fixés.

Bien qu'il s'agisse d'un exemple fictif, le cadre que nous avons fixé dans la section 1.4 nous permet de démarrer un processus de conception aboutissant à la sélection d'un environnement infonuagique. Il ne s'agit pas ici de réaliser ce processus de conception, seulement de montrer comment intégrer l'outil à ce dernier.

Cette section est découpée en quatre parties. Dans une première partie, nous détaillons l'exemple fil rouge en distinguant les composants du système et les opérations qu'ils exposent, ainsi que les formats de données qui transitent. Ces informations constituent le contrat entre les parties prenantes de l'estimation des coûts, permettant leur coopération sans friction (but B_5). Puis, dans la deuxième partie, nous nous intégrons à un premier cycle de conception en prenant la perspective des parties prenantes de l'estimation des coûts, et en analysant les coûts évalués par le logiciel pour aider la prise de décision (but B_3). Ensuite, dans la troisième partie, nous nous intégrons à un cycle ultérieur de conception dans lequel le système retenu dans la




FIGURE 7.7 – Diagramme de classes de la base des services de conteneurs à la demande activés




FIGURE 7.8 – Diagramme de classes des déploiements de conteneurs en tant que serveurs

partie précédente doit évoluer, et dont l'agence spatiale doit évaluer le coût (but B_4). Enfin, nous concluons sur la satisfaction des buts par l'outil.

Notons que nous ne détaillons pas le système comme le ferait l'agence spatiale. En effet, une telle précision de la connaissance du métier n'est pas nécessaire pour faire apparaître les difficultés d'estimation des coûts du système infonuagique que l'outil résout (buts B_1 et B_2), et nuirait à la compréhension de cette section.

Afin de ne pas surcharger ce document, les fichiers *JSON* de configuration de l'outil, qui correspondent aux instances des modèles présentés dans la section 6.2 (c.-à-d. contrat, architecture, configuration de l'architecture, scénario) pour l'exemple fil rouge que nous développons, sont consultables sur le dépôt du code source de l'outil, à l'adresse suivante : <https://gitlab.com/stack-labs/oss/ymir/tree/1.4/examples/catalog>.

7.2.1 Contrat entre les parties prenantes de l'estimation des coûts

En amont de l'utilisation de l'outil d'estimation des coûts, il est nécessaire d'élaborer d'avantage l'exemple fil rouge. En effet, il est nécessaire d'identifier les opérations que le système expose pour que l'expert fonctionnel puisse établir des scénarios, et les formats de données utilisés pour que l'architecte puisse décrire un système qui prend en charge et produit les données telles qu'elles sont attendues.

Rappels sur l'exemple fil rouge Ce paragraphe récapitule les informations données dans la section 1.4. Le système informatique que nous modélisons est développé par une agence spatiale française. Il a pour but de réceptionner, traiter et cataloguer des données transmises par des satellites d'observation de la planète à une antenne, qui communique avec le système informatique. Ces données sont des images satellitaires brutes. Le système informatique doit les formater, extraire des métadonnées, et les rendre accessibles aux clients de l'agence spatiale.

Il y a donc deux types d'utilisateurs de ce système informatique. D'un côté, l'antenne de la station terrienne transmet les données dès qu'elle les reçoit des satellites. De l'autre côté, les clients de l'agence spatiale qui parcourent le catalogue et téléchargent des images formatées.

Composants du système En partant de cette description des cas d'utilisation du système informatique, nous pouvons dresser le diagramme de composants de la figure 7.9.

D'abord, le système contient deux dépôts de fichiers, correspondant respectivement aux images satellitaires brutes et aux images formatées. Nous les identifions à part, conformément à notre modélisation présentée dans la section 7.1.2, car ils sont des composants réutilisables et disposant des mêmes fonctionnalités dans chacune de leurs implémentations. Notons que le




FIGURE 7.9 – Diagramme de composants (simplifié) pour l'exemple fil rouge

fait qu'ils soient identifiés dès l'élaboration du contrat est une prise de décision : une alternative serait, par exemple, de placer un intermédiaire développé par l'agence spatiale. Cependant, cette alternative engendrerait des transferts supplémentaires sur le réseau (transfert de l'utilisateur jusqu'au service, puis du service jusqu'au dépôt), ce qui résulterait en une facture plus élevée ; d'où la décision d'exposer directement les dépôts. De la perspective des utilisateurs du système informatique, ces dépôts sont utilisés à deux fins. D'un côté, l'*antenne de la station terrienne* téléverse les images brutes sur le *dépôt de données satellitaires brutes*. De l'autre côté, les *clients du catalogue* téléchargent les images formatées depuis le *dépôt de données satellitaires formatées*.

Ensuite, le système expose deux opérations. La première, à l'usage de l'*antenne de la station terrienne* a pour but de *notifier le système informatique qu'une image brute doit être formatée*. La seconde, à l'usage des *clients du catalogue*, permet à ce dernier de trouver l'identifiant d'une image formatée correspondant à un ensemble de critères de recherche. Les tailles des requêtes et des réponses de ces opérations sont de l'ordre de la centaine d'octets, puisqu'il s'agit de transits de messages comportant seulement un identifiant ou une confirmation que les traitements sont effectués.

Format des données Les utilisateurs du système manipulent deux types de données : les images brutes et les images formatées. Pour l'estimation des coûts, seule la taille de ces données importe. Dans l'optique de ne pas complexifier l'exemple outre mesure, et bien qu'il existe en réalité une variabilité de la taille d'une image à l'autre, nous considérons ici que toutes les images du même type ont la même taille. Les images brutes ont une taille de quarante gigaoctets et les images formatées, de quinze gigaoctets.

7.2.2 Estimation des coûts lors d'un premier cycle de conception

À présent qu'un contrat a été défini, les parties prenantes de l'estimation des coûts peuvent élaborer leurs artefacts indépendamment.

Définition des scénarios

Comme expliqué précédemment, l'expert fonctionnel a pour objectif de modéliser dans un scénario le comportement des utilisateurs vis-à-vis du système. Afin d'explorer différentes hypothèses (p. ex. succès commercial, répartition des utilisateurs sur la planète), il modélise plusieurs scénarios.

Ici, nous nous restreignons à un seul scénario simple, qui ne fait intervenir que l'*antenne de la station terrienne*. Celle-ci réceptionne des transmissions des satellites environ toutes les quinze minutes. Quand c'est le cas, l'antenne *téléverse* l'image brute sur le *dépôt d'images satellitaires brutes* et *notifie* le système qu'une image attend d'être formatée.

Définition de l'environnement sélectionné

Afin de sélectionner un environnement, l'architecte de systèmes infonuagiques doit définir une architecture et une configuration de l'architecture. Nous considérons ici une architecture et deux configurations de celle-ci, que nous comparerons ensuite.

Architecture L'architecture expérimentée est basée sur des *IaaS*.

D'abord, elle contient deux compartiments d'objets correspondant aux dépôts d'images brutes et formatées.

Ensuite, nous y trouvons deux machines virtuelles permettant le catalogage des images formatées. La première est l'hôte d'un *SGBD*, elle requiert donc un disque dédié au stockage de données et présente des opérations d'écriture et de lecture de lignes de base de données. La seconde machine héberge un service de catalogue, qui sert d'interface pour écrire et lire des métadonnées d'images formatées.

Puis, l'architecture contient les ressources nécessaires au formatage des images brutes. Le formatage est décomposé en une séquence de deux étapes réalisées par des services Web hébergés sur des groupes de machines virtuelles distincts : *Processeur de l'étape n°1* et *Processeur de l'étape n°2*. Le choix de groupes de machines virtuelles permet d'adapter le nombre de ressources déployées au nombre d'images à traiter simultanément. Lors de l'étape n°1, la machine qui traite la requête télécharge l'image depuis le *dépôt de données satellitaires brutes*, puis effectue en ensemble de calculs, puis supprime cette image sur le dépôt avant de demander au second groupe de machines virtuelles d'effectuer la seconde étape. Cette étape n°2 consiste à effectuer

une série de calculs, puis à téléverser l'image formatée sur le *dépôt de données satellitaires formatées*, puis à demander au catalogue d'enregistrer les métadonnées de l'image formatée. Les requêtes de traitement sont adressées à un équilibreur de charge (respectivement *ÉdC de l'étape n°1* et *ÉdC de l'étape n°2*) plutôt que directement aux machines virtuelles.

Enfin, l'opération pour notifier le système qu'une image brute attend un formatage est reçue par un service Web déployé sur sa propre machine virtuelle, *Acquisition*.

Configurations de l'architecture Nous comparons deux configurations de cette architecture. Les deux emploient les services de Google Cloud Platform : Cloud Storage pour les compartiments d'objets, Compute Engine pour les machines virtuelles, les disques et les équilibreurs de charge. Parmi les détails notables que les configurations ont en commun, nous soulignons que les données sont stockées dans la classe *standard* de Cloud Storage, dont le stockage est coûteux mais depuis laquelle il est peu coûteux de télécharger des données, et les machines qui effectuent le formatage sont d'un type de machines virtuelles dédié au calcul intensif, *c2-standard-30*⁵.

L'axe sur lequel nous différencions les deux configurations est la localisation des ressources. Étant donné les préoccupations de souveraineté numérique liées au domaine spatial, l'agence spatiale privilégie un hébergement en Union Européenne, sinon en France. Pour cette raison, la **configuration n°1** localise toutes les ressources dans la région *europa-west1*, qui correspond aux alentours de Bruxelles. Cette région est disponible dans Google Cloud Platform depuis longtemps et dispose du type de machines dédié au calcul intensif que l'agence spatiale souhaite utiliser. D'un autre côté, la **configuration n°2** localise le plus de ressources possible dans la région *europa-west9*, dans les alentours de Paris. Les centres informatiques dans cette région sont soumis à la législation française, ce qui peut être perçu comme un gain sur le plan de la souveraineté numérique. Néanmoins, ils ne sont pas pourvus du matériel permettant de déployer des machines virtuelles de type *c2-standard-30*. Un compromis possible est d'héberger le stockage des ressources en France et de conserver les ressources dédiées au formatage en Belgique. Évaluer le coût du système avec la configuration n°2 et le comparer à celui de la configuration n°1 nous permet donc d'estimer le coût financier d'une souveraineté numérique accrue.

5. *c2-standard-30* est un type de machines virtuelles fourni par Compute Engine et qui dispose d'un processeur à 30 coeurs et de 120 gigaoctets de mémoire vive. Il repose sur une infrastructure physique particulière qui n'est pas disponible dans toutes les régions de Google Cloud Platform.

Analyse des coûts évalués

La table 7.1 résume les traces de facturation produites lors des deux estimations. Ces simulations ont en commun le contrat, l'architecture, le scénario, et la période d'estimation d'une durée d'un mois. Seule la configuration de l'architecture diffère.

Dans les deux simulations, les groupes de machines ont traité la même charge de calcul et au même moment, il n'y a donc pas de différence de nombres d'instances déployées pour mettre les groupes à l'échelle entre les simulations. Nous remarquons que les coûts liés à l'allocation de ressources et au stockage dans des compartiments d'objets sont systématiquement un peu plus élevés pour la configuration qui a ses ressources en France. Cela est dû à des tarifs globalement plus élevés pour la région *europa-west9* par rapport à *europa-west1*.

La différence notable est au niveau des dépenses pour les transferts de données. Dans la configuration n°1, toutes les ressources sont dans la même région, il n'y a donc que des transferts entre zones de la même région, tandis qu'il y a des transferts entre *europa-west1* et *europa-west9* avec la configuration n°2. Les montants pour ces catégories de coût sont bien plus élevés pour la configuration n°2 pour deux raisons. D'un côté, le tarif d'un transfert entre régions est plus élevé que celui d'un transfert entre zones. De l'autre, Cloud Storage ne facture pas les transferts qui ne sortent pas de la région du compartiment d'objets. Pris dans l'ensemble, le seul fait d'avoir déplacé des ressources sur une autre région a plus que doublé le coût attribuable au réseau.

Finalement, l'estimation avec la configuration n°2 a abouti à un coût environ 20% supérieur à celui de la configuration n°1.

D'autres expérimentations pourraient être menées. Par exemple, avec une configuration dans laquelle les groupes de machines pour le formatage utilisent un type de machines moins onéreux, mais également moins efficace. Pour la suite de cet exemple, nous retiendrons la configuration n°1 : aux yeux de l'agence spatiale, le gain de souveraineté numérique ne justifie pas un si grand surcoût.

7.2.3 Estimation des coûts d'une évolution du système

Suite à un premier développement, l'agence spatiale souhaite faire évoluer son système de catalogue. En effet, l'architecture proposée précédemment n'est pas robuste à une erreur lors du formatage d'une image : en cas d'un incident indépendant de la volonté de l'agence spatiale, les calculs déjà réalisés pour le formatage sont perdus. Par conséquent, une réarchitecture est nécessaire.

Catégorie de coût	Conf. n°1	Conf. n°2
Allocation des machines virtuelles	8750.34	8923.63
Allocation des disques virtuels	6877.48	7403.35
Transferts vers l'extérieur de l'environnement	$3.32 * 10^{-5}$	$3.32 * 10^{-5}$
Transferts entre zones d'une région	1800.80	1385.34
Tranferts entre régions	0.0	3048.22
Stockage dans les compartiments d'objets	429.68	494.13
Total	17858.3	21254.68

TABLE 7.1 – Coûts évalués pour les deux configurations de la première version de l'architecture, avec le même scénario (coûts en USD)

Évolutions de l'environnement Évaluons deux modifications. D'une part, la nouvelle architecture contient un nouveau compartiment d'objets *Dépôt d'images partiellement formatées*. Les machines de l'étape n°1 écrivent dans ce compartiment avant de transmettre l'ordre de poursuivre le calcul aux machines de l'étape n°2, et donc ne transmettent pas l'image partiellement formatée dans la requête. D'autre part, deux bus de messages sont déployés. Ces bus de messages permettent de rendre le traitement des images asynchrones : plutôt que d'attendre la réponse à une requête *HTTP*, les ressources envoient un message et peuvent arrêter leurs opérations.

Pour l'architecte, les modifications ont été réalisées depuis le fichier d'architecture de l'étape précédente. Elles ont consisté en l'ajout de nouvelles ressources (le dépôt d'images partiellement formatées déployé par Cloud Storage et les bus de messages déployés par Pub/Sub) et l'édition des séquences d'exécution des logiciels existant pour qu'ils utilisent ces ressources. L'expert fonctionnel n'a eu aucun travail supplémentaire à fournir, puisque nous avons conservé le même scénario. La configuration n°1 de l'architecture a reçu des modifications similaires pour évoluer en même temps que l'architecture.

Analyse des coûts évalués La table 7.2 récapitule les coûts évalués pour le système de l'agence spatiale avant (*Architecture n°1*) et après l'évolution de l'architecture (*Architecture n°2*), sur la même période de temps et avec le même scénario. Les ressources sont localisées en Belgique.

Nous avons trois remarques à formuler. La première concerne le coût du stockage dans les compartiments d'objets, qui est légèrement plus élevé. C'est normal : cela correspond au stockage des images partiellement formatées, qui n'existent pas avec l'architecture n°1. La deuxième remarque concerne les coûts liés aux agents de messagerie, car nous pourrions nous attendre à en voir apparaître pour l'architecture n°2 ; cependant, Pub/Sub a un tier gratuit qui

Catégorie de coût	Architecture n°1	Architecture n°2
Allocation des machines virtuelles	8750.34	7921.63
Allocation des disques virtuels	6877.48	6359.06
Transferts vers l'extérieur de l'environnement	$3.32 * 10^{-5}$	$3.32 * 10^{-5}$
Transferts entre zones d'une région	1800.80	1800.80
Stockage dans les compartiments d'objets	429.68	430.64
Total	17858.3	16512.14

TABLE 7.2 – Coûts évalués pour des deux configurations de la première version de l'architecture, avec le même scénario (coûts en USD)

couvre l'utilisation faite lors de la simulation. Il n'y a donc pas de coût associé aux agents de messagerie. Enfin, nous constatons que les coûts liés à l'allocation des machines virtuelles et des disques sont légèrement inférieurs. Il s'agit des coûts liés aux groupes de machines dédiés au formatage. Dans l'architecture n°1, les machines du groupe qui effectue la première étape du formatage effectuent des requêtes *HTTP* vers les machines qui finalisent le formatage : elles doivent rester allouées en attendant la complétion du formatage. Dans l'architecture n°2, le processus de formatage est découpé : une fois la première étape terminée, la seconde peut débiter à l'initiative de l'agent de messagerie. Ainsi, les instances du premier groupe de machines virtuelles peuvent être supprimées une fois leur tâche achevée et cesser d'être facturées.

Finalement, les évolutions envisagées devraient aboutir à des coûts sensiblement inférieurs (environ 8%).

7.2.4 Conclusion de l'application à l'exemple fil rouge

Avec cet exemple d'application de l'outil, nous avons effectué trois estimations des coûts d'un système infonuagique contenant des ressources élastiques. Les deux premières ont permis d'aider la prise de décision pour un compromis entre coût de l'environnement et souveraineté numérique. La troisième a permis de mesurer la différence de coût de l'environnement pour une évolution souhaitée du système.

Les environnements dont nous avons évalué les coûts contenaient des ressources élastiques. Nous avons pour cela seulement décrit la configuration de mise à l'échelle automatique, comme un usager de service infonuagique le ferait. C'est par l'interaction de ces ressources entre elles que se déclenchent les mécaniques de mise à l'échelle. Grâce à la simulation, l'estimation des coûts a tenu compte de la mise à l'échelle automatique de l'environnement sans effort supplémentaire de la part des parties prenantes de l'évaluation. Par conséquent, nous estimons que les buts B_1 et B_2 ont été satisfaits. De plus, ces estimations n'ont pas nécessité le déploiement d'un

environnement infonuagique ; l'outil satisfait donc le but B_3 . Ensuite, nous avons montré que les artefacts générés par les parties prenantes évoluent d'étape en étape de conception. Cela ne requiert pas d'effort particulier puisque les informations contenues dans ces artefacts sont celles que les parties prenantes emploient au quotidien. Nous avons donc montré que, dans cette situation, l'outil satisfait le but B_4 . Enfin, chaque acteur a pu créer ses propres artefacts indépendants dès lors que le contrat a été établi, conformément au but B_5 .

7.3 Application industrielle

Cette thèse se déroulant dans un contexte industriel, nous avons pu confronter l'outil d'estimation des coûts que nous avons développé, Ymir, à un cas concret d'utilisation. En effet, il fut utilisé dans le cadre de la participation de Stack Labs au projet DOMINO-X. En outre, Stack Labs étant une entreprise de conseil spécialisée dans l'informatique en nuage, des usages lui sont prévus quand l'outil aura été étendu.

7.3.1 Application au sein de DOMINO-X

DOMINO-X est un projet initié par le Centre National d'Études Spatiales, dans le cadre du volet spatial du plan France Relance financé par l'État Français. Ce projet a pour but le développement de composants réutilisables, nommés *dominos*, pour la création de segments sol pour l'imagerie satellitaire.

Stack Labs a intégré l'une des équipes de DOMINO-X dont l'objectif est d'évaluer la pertinence d'un hébergement des *dominos* sur nuage public au regard des coûts. Si Ymir préexistait à cette collaboration, les échanges que nous avons au cours de celle-ci nous ont permis de diriger les développements de façon à pouvoir servir à l'industrie de l'aérospatial. Par exemple, cela nous a incité à nous focaliser sur les services d'infrastructure à la demande, car ce sont les services infonuagiques les plus utilisés dans ce domaine, et à diversifier les catalogues de fournisseur de services que nous avons modélisé. En effet, alors que nous nous étions focalisé sur Google Cloud Platform, entreprise partenaire de Stack Labs, nos partenaires de DOMINO-X nous ont suggéré d'également modéliser les services de fournisseurs de services européens, qui satisfont leurs exigences de souveraineté numérique. Cela a amené des collaborateurs de Stack Labs à modéliser les services de Scaleway et Orange Business Services. En outre, cette collaboration nous a permis de mettre le doigt sur les difficultés d'accès à ce genre d'outils dans les organisations. Cela peut être dû, par exemple, aux opérations de mise en place (p. ex. téléchargements des catalogues et tarifs), à la collaboration entre concepteurs (p. ex. partage et

versionnement des artefacts), à la multiplication des expérimentations et à l'analyse de leurs résultats. Par conséquent, et pour résoudre ces difficultés, des employés de Stack Labs ont proposé et développé un *SaaS* propriétaire qui permet d'exécuter des estimations grâce à Ymir sans installation locale.

Enfin, Ymir fut utilisé dans le cadre de cette collaboration afin de valider ses résultats. L'une des entreprises-partenaires a, en effet, un système de traitement d'images satellitaires hébergé sur Google Cloud Platform ; par conséquent, ils disposaient de factures auxquelles nous pouvons comparer les coûts évalués par Ymir. Après avoir modélisé leur système avec eux, nous avons exécuté une simulation qui a abouti à des résultats très proches de leurs facture, avec une erreur inférieure à 5%. Nous expliquons cette erreur par des approximations que nous avons réalisées dans la modélisation des scénarios.

7.3.2 Utilisation par Stack Labs

Dans le futur, Stack Labs souhaite utiliser Ymir afin d'accélérer l'élaboration de propositions commerciales en réponse à des appels d'offres. L'apport d'un tel outil permet effectivement de réaliser de nombreuses expérimentations en peu de temps, et d'appuyer la proposition avec des nombres produits par un processus auditable.

Cependant, nous n'avons pas encore utilisé l'outil de cette manière. De fait, il est en cours d'industrialisation. Cette industrialisation doit aborder les deux aspects suivants. D'une part, les entreprises conseillées par Stack Labs utilisent un spectre de services infonuagiques très large. Nous devons donc préalablement modéliser ces services dans l'outil. D'autre part, Stack Labs est spécialisé dans deux nuages publics, Google Cloud Platform et Amazon Web Services. Or, pour l'instant, nous n'avons pas encore modélisé ce second fournisseur de services. Ce travail est nécessaire pour pouvoir réaliser des comparatifs, et fait partie des perspectives pour la suite des travaux de cette thèse.

7.4 Conclusion

Dans ce chapitre, nous avons présenté l'outil que nous avons développé afin d'automatiser l'estimation des coûts d'un environnement infonuagique. Cet outil repose sur le modèle conceptuel présenté dans le chapitre 6 et sur la simulation à événements discrets. Nous avons montré un exemple d'utilisation de cet outil ainsi que son état d'utilisation actuel dans l'industrie.

Ce chapitre conclut cette partie dédiée aux contributions de la thèse. Dans le chapitre sui-

vant, nous résumons les principales contributions de ce travail de recherche, présentons nos conclusions ainsi que des perspectives pour de futurs travaux.

Quatrième partie

Conclusion

Chapitre 8

Conclusion et perspectives

Dans ce chapitre, nous faisons la synthèse de ce document. Nous rappelons les enjeux qui ont mené à initier cette thèse et ses contributions, ainsi que les applications industrielles de ces dernières. Enfin, nous présentons des perspectives pour la suite de ces travaux et concluons sur les publications des contributions de cette thèse.

8.1 Synthèse de ce document

L'adoption massive de l'informatique en nuage par l'industrie soulève de nouveaux défis en matière de développement des systèmes d'information et de leur hébergement, un environnement infonuagique.

Dans cette thèse, nous avons étudié la phase de conception des environnements infonuagiques en nous interrogeant, d'abord, quant aux exigences qu'un tel environnement doit satisfaire dans un contexte industriel. Pour cela, nous avons mené une enquête qualitative sous la forme d'entretiens semi-dirigés auprès d'acteurs industriels. Cette enquête, que nous détaillons dans le chapitre 5, a mis en lumière plus d'une dizaine d'exigences de haut niveau et les moyens mis en œuvre dans des migrations pour les satisfaire. Ces exigences diffèrent d'un projet de migration à l'autre ; une méthode de sélection d'un environnement infonuagique doit tenir compte de leur diversité et de leur variabilité afin d'être industrialisable.

Néanmoins, d'autres questions se posent en amont. En effet, nous avons étudié la possibilité d'évaluer la satisfaction de ces exigences dans les phases amont de la conception, avant qu'un investissement important ait été réalisé dans le développement. Nous nous sommes concentré sur un critère : les coûts de l'environnement infonuagique, puisqu'il s'agit d'une préoccupation récurrente dans l'industrie. L'estimation des coûts de l'environnement infonuagique doit être

automatisée pour pouvoir servir dans l'industrie. En effet, de nombreuses estimations pourraient être requises lors de la conception pour évaluer des variantes d'un environnement infonuagique ; les réaliser manuellement pose deux risques : d'une part, de prendre trop de temps à réaliser et, d'autre part, de comporter des erreurs. Par conséquent, nous avons défini, dans le chapitre 6, un modèle conceptuel que devrait implémenter un outil d'estimation des coûts d'un environnement infonuagique adapté à un usage industriel. Constatant qu'un tel outil n'existe pas, nous avons développé un simulateur à événements discrets qui implémente notre modèle conceptuel, Ymir, que nous présentons dans le chapitre 7. Cet outil a été utilisé dans le cadre d'un projet dans le domaine de l'aérospatial et est en cours d'industrialisation au sein de la société de conseil Stack Labs afin d'améliorer la qualité de ses prestations.

8.2 Perspectives

Dans cette section, nous passons en revue les perspectives pour poursuivre les travaux présentés dans ce document. Ces perspectives sont regroupées en deux sous-sections : d'une part, les perspectives pour la recherche, et, d'autre part, celle pour l'industrie.

8.2.1 Recherche

Automatisation de l'estimation de la satisfaction des autres exigences

Dans cette thèse, nous nous sommes concentré sur l'estimation de la satisfaction d'un type d'exigences : celles qui concernent le coût de l'environnement infonuagique. Or, dans le chapitre 5, nous avons recensé onze exigences de haut niveau ; il reste donc dix autres exigences pour lesquelles nous devons étudier s'il est possible d'évaluer leur satisfaction, les moyens de cette estimation et son automatisation.

Dans le chapitre 6, nous avons exposé les buts que doit satisfaire un outil d'estimation des coûts d'un environnement pour satisfaire un usage industriel. Nous avons identifié le besoin pour cet outil de pouvoir être utilisé dans les phases préliminaires de la conception car il est coûteux de remédier à une mauvaise décision de conception de l'environnement tard dans le développement, ainsi que de faciliter la prise en compte d'éléments propres à l'informatique en nuage : la mise à l'échelle automatique des environnements et les conséquences des interactions des ressources de l'environnement. De plus, nous avons identifié deux buts organisationnels : les paramètres de l'outil pour effectuer une estimation doivent évoluer en même temps que le système infonuagique tout au long de son cycle de vie et il doit permettre la coopération des parties prenantes de l'estimation. Ces buts demeurent valables pour tout outil d'estimation d'un environnement infonuagique, en particulier pour évaluer les critères liés aux exigences

restantes. Ainsi, automatiser l'estimation de la satisfaction de ces dix autres exigences devrait nécessiter un travail analogue à celui qui a été effectué dans cette thèse, à savoir analyser le fonctionnement du système au regard du critère que doit évaluer l'outil, afin de définir un modèle conceptuel de cet outil. L'implémentation de ce modèle en un logiciel permettra ensuite d'en faire un usage industriel.

Choix d'une stratégie de migration basé sur les exigences

Dans le chapitre 3, nous avons introduit la notion de stratégie de migration : il s'agit de stéréotypes de migrations infonuagiques. Elles indiquent à très haut niveau le type de système produit (notamment, l'environnement infonuagique) et les activités requises pour y parvenir. Décider d'une stratégie de migration permet aux concepteurs de limiter l'espace des décisions qu'ils doivent prendre pour la sélection de l'environnement. Or, il n'existe pour l'instant pas de méthode pour choisir une stratégie de migration.

Au cours des entretiens que nous avons mené, nous avons recueilli les exigences que l'environnement devait satisfaire, et nous pourrions également identifier la stratégie de migration employée. Une étude approfondie pourrait être menée afin d'établir les relations entre exigences et choix d'une stratégie de migration, et éventuellement aboutir sur un modèle de prédiction de la stratégie de migration utilisable à l'issue de la phase d'élicitation des exigences. Certaines relations nous sont apparues immédiatement. Par exemple, les migrations dans lesquelles les moyens (temps, budget) alloués à la migration étaient faibles ont tous mené à une migration vers des *IaaS*, une stratégie de migration retrouvée dans plusieurs travaux de la littérature. Un autre exemple : nous avons constaté que les migrations dans lesquelles le système devait être agnostique de tous les fournisseurs de services ont abouti à une migration vers des *IaaS*. Ces relations doivent être évaluées et expliquées : le lien entre exigence d'agnosticisme et migration vers des *IaaS* n'est pas évident, car il existe de plus en plus de standards permettant l'usage de *PaaS* (p. ex. Kubernetes, formats de conteneurs, interfaces standardisées pour certains types de services infonuagiques). Un travail d'identification et d'explication de ces liens devraient être menés afin de pouvoir déterminer, dès l'étape d'analyse des exigences, la stratégie de migration adéquate.

Élaboration de compromis entre les exigences d'une migration infonuagique

Dans le chapitre 3, nous avons passé en revue l'état de l'art des méthodes de sélection d'un environnement infonuagique. Notre conclusion était que ces travaux se concentrent sur la configuration de services d'infrastructure à la demande et sur l'optimisation de seulement quelques critères, dont le coût et certains aspects de la qualité de service. Or, pour un usage

dans l'industrie, une méthode de sélection de l'environnement infonuagique doit embrasser l'ensemble des exigences de l'environnement et tenir compte de la multitude des services infonuagiques.

Cependant, comme nous l'avons vu dans les entretiens du chapitre 5, les exigences de l'environnement infonuagique peuvent ne pas être toutes satisfaites en même temps à cause du catalogue de services infonuagique : les usagers ont moins d'options qu'avec, par exemple, une infrastructure localisée dans leurs locaux. De plus, lors d'une migration sur un nuage public, la marge de négociation des usagers est mince : certains peuvent négocier des tarifs contre un engagement à dépenser une certaine somme d'argent, mais nous n'avons pas connaissance d'une négociation ayant abouti à une modification du contrat de niveau de service ou une fonctionnalité déployée pour l'utilisateur. Par conséquent, la négociation doit être réalisée entre les exigences, ce qui doit mener à des compromis entre elles. Or, il n'existe pour le moment de méthode pour élaborer des compromis entre exigences pour l'informatique en nuage, sinon expérimenter plusieurs environnements candidats sélectionnés grâce à l'expertise d'un architecte. Par conséquent, de futurs travaux devraient aborder le problème de la création de compromis entre exigences en reposant sur les exigences que nous avons identifiées grâce aux entretiens.

Ces travaux pourraient inclure la modélisation des conflits entre les buts que de satisfaire un environnement infonuagique, à l'aide d'un langage adapté (tel que i^* ou KAOS). Ce premier travail permettrait de déterminer rapidement quelles sont les exigences qui entrent en conflit, en amont d'une analyse plus approfondie. En outre, une méthode de sélection d'un environnement devrait être l'aboutissement des travaux sur ce sujet. Elle devrait reposer sur les exigences que nous avons identifiées dans le chapitre 5, tout en tenant compte du fait que toutes ces exigences n'interviennent pas simultanément pour une migration donnée. De plus, ces exigences ne demandent pas toutes d'atteindre un optimum. Par exemple, pour les coûts de l'environnement, l'exigence peut être de ne pas dépasser un budget : il n'est pas nécessaire de minimiser le coût en deçà tant que les autres exigences ne sont pas satisfaites.

8.2.2 Industrie

Utilisabilité d'Ymir

Au cours de l'expérimentation au sein de DOMINO-X, nous avons constaté des difficultés liées à l'utilisabilité du logiciel. En effet, l'édition de fichiers *JSON* n'est pas évidente pour tous les acteurs, notamment l'expert fonctionnel qui n'est pas forcément un informaticien. En plus du format, la taille conséquente de ces fichiers peut causer des problèmes de lisibilité. Afin de rendre cet outil accessible à ses utilisateurs-cibles, de futurs travaux devront s'attacher à

élaborer une interface homme-machine adaptée.

En outre, nous pensons que l'outil n'est pas pratique pour l'intégration à un projet existant. Il s'avère que des outils de développement communs manipulent des informations similaires à ce que contiennent les artefacts de l'outil d'estimation des coûts. Par exemple, Terraform comporte une partie des informations de l'architecture et de sa configuration. De futurs travaux pourraient développer l'intégration d'Ymir à ces outils de deux manières. D'une part, en analysant les artefacts de ces autres outils (p. ex. les plans de déploiement de Terraform) afin de générer un modèle à compléter d'artefact d'Ymir. Cela permettrait d'accélérer son adoption. D'autre part, en générant les artefacts des autres outils à partir des artefacts d'Ymir. En effet, cela permet de ne maintenir qu'un petit nombre de documents au long du développement, dans l'idée de fil numérique.

Poursuite du développement d'Ymir

Comme nous l'avons expliqué dans la section précédente, Ymir est actuellement une preuve de concept montrant qu'il est possible d'automatiquement évaluer les coûts de concepts d'environnements infonuagiques, mais quelques développements demeurent nécessaires pour qu'une entreprise telle que Stack Labs puisse pleinement en tirer profit. Ces évolutions nécessaires doivent intégrer de nouveaux types de services afin de pouvoir évaluer le coût de systèmes infonuagiques réellement utilisés dans l'industrie, ainsi que modéliser de nouveaux fournisseurs de services afin de permettre des comparaisons entre eux. Cette dernière évolution permettra de questionner les modèles existants et éventuellement de les mettre à jour afin de rendre le modèle proposé dans le chapitre 7 plus agnostique d'un fournisseur de services en particulier.

8.3 Liste des publications

Les contributions présentées dans ce document ont été publiées dans des conférences nationales et internationales à comité de lecture :

1. ANTOINE AUBÉ. Co-conception de logiciels et de leur environnement d'exécution infonuagique. Actes de la 12^{ème} édition du forum Jeunes Chercheurs Jeunes Chercheuses (JCJC) de la conférence Informatique des Organisations et Systèmes d'Information et de Décision (INFORSID), 2022.
2. ANTOINE AUBÉ, THOMAS POLACSEK ET CLÉMENT DUFFAU. Les exigences pour un choix d'architecture dans le cadre d'une migration dans les nuages. Actes du 40^{ème} congrès de la conférence Informatique des Organisations et Systèmes d'Information et de Décision, pages 43-58, 2022.

3. ANTOINE AUBÉ ET THOMAS POLACSEK. Cloud Migration High-Level Requirements. Actes du 17^{ème} congrès de la conférence *Research Challenges in Information Science (RCIS)*, pages 19-34 2023.

Résumés d'entretiens

Dans le chapitre 5, nous avons enrichi notre explication des exigences identifiées par des résumés d'entretiens que nous avons menés. Afin de ne pas surcharger ce chapitre et éviter de nuire à la lisibilité, nous avons limité le nombre de résumés, quand bien même nous en avons d'autres d'intérêt. Ces autres résumés sont recensés dans cette annexe.

Minimiser les efforts de maintenance opérationnelle (E_1)

Entretien avec P_2

P_2 est intervenu auprès d'une équipe réduite en charge à la fois du développement et de l'exploitation de leur système d'information. La migration devait décharger cette équipe d'autant de tâches de maintenance opérationnelle que possible, afin qu'elle se concentre sur le développement.

Pour cette raison, P_2 a proposé l'utilisation d'un *PaaS* compatible avec les logiciels du système d'information. Ainsi, pour ces composants, aucune adaptation n'a été nécessaire :

« Leurs services étaient écrits en Java et ils les hébergaient sur des serveurs d'application Tomcat, c'était parfait pour utiliser [un PaaS]; donc c'est ce qu'on a fait. [...] en termes de développement ça n'a rien coûté et c'est bien plus pratique [...], donc ça n'avait pas de sens de ne pas s'en servir. »

Entretien avec P_7

L'organisation dans laquelle est intervenu P_7 est une très grande entreprise avec de très nombreux projets informatiques qui ont été construits sans suivre de politique quant à l'hébergement, ce qui entraîné une très grande complexité pour la maintenance de ces systèmes :

« Ils utilisaient plusieurs plateformes, certaines [sur site], d'autres sur [nuages] publics et privés, et en plus c'était à chaque fois des [technologies] différentes [...]. C'était l'enfer pour les équipes Ops [...] »

Par conséquent, l'organisation a décidé de mettre en place une telle politique afin de minimiser la masse salariale dédiée à la maintenance opérationnelle. Elle a donc procédé à la migration de tous ses systèmes pour qu'ils respectent cette politique :

« [...] du coup le but de la migration était de tout rassembler sur une seule plateforme et un seul gestionnaire de conteneurs pour tous les projets [de l'organisation] [...] »

Cela a consisté à utiliser un service de Kubernetes à la demande, une plateforme qui permet « d'automatiser le déploiement, la montée en charge et la mise en oeuvre de conteneurs d'application sur des grappes de serveurs ». Finalement, cette décision a permis de réduire considérablement les effectifs des équipes en charge de la maintenance opérationnelle pour les projets de l'organisation.

Minimiser le coût de l'environnement infonuagique (E_2)

Entretien avec P_5

Au cours de la migration à laquelle il a participé, P_5 devait sélectionner un hébergement pour une forge logicielle, c'est-à-dire un ensemble de logiciels utilisés pour construire d'autres logiciels. Il avait deux contraintes : la performance de calcul, afin d'accélérer la construction des logiciels et les diverses tâches associées telles que de l'entraînement de réseaux neuronaux ou l'exécution de batteries de tests, et le coût de l'environnement. Pour assurer la performance de calcul, il a opté pour des *IaaS*, car cela lui permet de configurer finement l'infrastructure sous-jacente. Par exemple, le fournisseur de services donne des indications quant au matériel utilisé, tel que l'architecture des processeurs, et P_5 a été en mesure d'ajouter des accélérateurs graphiques. En outre, il a préféré cette solution à l'utilisation d'un *PaaS* qui configure un *IaaS* car les configurations possibles d'un tel service aurait sous-approvisionné ou sur-approvisionné l'environnement, et ainsi élevé le coût de l'environnement infonuagique.

Maximiser la fiabilité du système (E_3)

Entretien avec P_9

Les préoccupations concernant la fiabilité sont importantes pour les organisations qui s'engagent à un *SLA*.

Par exemple, c'était une préoccupation importante de l'équipe dans laquelle P_9 est intervenu car ils ont eu une expérience de déni de service suite à un incident, ce qui a entraîné des réclamations de leurs clients. Ils ont dû payer des contreparties à ces clients et certains ont mis terme à la collaboration avec l'organisation.

Minimiser la latence de réponse aux requêtes (E_4)

Entretien avec P_3

Avant la migration, le système d'information qu'a migré P_3 était hébergé dans les locaux, en France, là où se situent les clients historiques de l'organisation. Or, avec l'acquisition de nouveaux clients en Amérique du Sud, l'importante distance causait une grande latence du réseau, et l'insatisfaction de ces clients.

Ainsi, le choix du fournisseur infonuagique a tenu compte du besoin de déployer le système à la fois en Europe de l'Ouest et en Amérique du Sud.

Entretien avec P_9

Comme la latence de réponse du système qu'a migré P_9 était un critère important dans la migration, il a effectué des bancs de tests pour évaluer la latence perçue par un client de l'organisation avant et après la migration :

« [...] Avant, tous les serveurs étaient dans la même pièce, et maintenant ils sont dans des [centres informatiques] gigantesques ; les données passent par le réseau local, l'Internet... Alors, évidemment, on perd en performance. C'est quelque chose que j'ai mesuré [...], et finalement ils ont accepté ma proposition car j'avais prévu des solutions pour compenser la perte de performances. »

Pour compenser la dégradation de la latence, liée aux transferts au sein du réseau du fournisseur de services, P_9 a proposé diverses modernisations des logiciels, telle que l'utilisation d'un protocole de communication plus léger (transferts réduits sur le réseau et messages plus rapide à encoder et décoder par les logiciels).

Minimiser le besoin de nouvelles compétences (E_5)**Entretien avec P_6**

P_6 a indiqué que le choix de fournisseur infonuagique était évident, puisque certaines personnes en charge de la maintenance opérationnelle avait déjà une expérience avec un certain fournisseur de services. Les services infonuagiques de ce fournisseur de services ont donc été choisis : aucune autre comparaison n'a été faite avec les autres fournisseur de services.

Assurer la souveraineté numérique (E_6)**Entretien avec P_8**

Dans la migration qu'il a rapporté, P_8 a indiqué qu'une partie des utilisateurs sont chinois. Or, la Chine protège les données personnelles de ses citoyens : elles ne doivent pas quitter le territoire chinois.

Des adaptations ont donc été nécessaires, puisque le fournisseur de services sélectionné par l'organisation ne possède pas de centre informatique en Chine. Par conséquent, la solution retenue a été de ne migrer que partiellement le système : la base de données contenant les données personnelles des citoyens chinois demeure dans les locaux en Chine de l'organisation.

Bibliographie

- ACHIM, Ovidiu-Marian, Florin POP et Valentin CRISTEA (2011). « Reputation Based Selection for Services in Cloud Environments ». In : *The 14th International Conference on Network-Based Information Systems, NBIS 2011, Tirana, Albania, September 7-9, 2011*. Sous la dir. de Leonard BAROLLI, Fatos XHAFA et Makoto TAKIZAWA. IEEE Computer Society, p. 268-273.
- AL-MASRI, Eyhab et Qusay H. MAHMOUD (2007). « QoS-based Discovery and Ranking of Web Services ». In : *Proceedings of the 16th International Conference on Computer Communications and Networks, IEEE ICCCN 2007, Turtle Bay Resort, Honolulu, Hawaii, USA, August 13-16, 2007*. IEEE, p. 529-534.
- ALVES, Diego Cardoso et coll. (2016). « CM Cloud Simulator : A Cost Model Simulator Module for Cloudsim ». In : *IEEE World Congress on Services*. Sous la dir. de Rami BAHSON et Liang-Jie ZHANG. IEEE Computer Society, p. 99-102.
- AMIRI, Maryam et Leili Mohammad KHANLI (2017). « Survey on prediction models of applications for resources provisioning in cloud ». In : *J. Netw. Comput. Appl.* 82, p. 93-113.
- ANDRIKOPOULOS, Vasilios et coll. (2013). « How to adapt applications for the Cloud environment - Challenges and solutions in migrating applications to the Cloud ». In : *Computing* 95(6), p. 493-535.
- AOSHIMA, Tomohisa et Kenichi YOSHIDA (2020). « Pre-Design Stage Cost Estimation for Cloud Services ». In : *44th IEEE Annual Computers, Software, and Applications Conference, COMPSAC 2020*. IEEE, p. 61-66.
- AOSHIMA, Tomohisa et Kenichi YOSHIDA (2022). « Cost estimates for modern e-business systems ». In : *Knowledge-Based and Intelligent Information & Engineering Systems : Proceedings of the 26th International Conference KES-2022, Verona, Italy and Virtual Event, 7-9 September 2022*. Sous la dir. de Matteo CRISTANI et coll. T. 207. Procedia Computer Science. Elsevier, p. 664-673. DOI : [10.1016/j.procs.2022.09.121](https://doi.org/10.1016/j.procs.2022.09.121). URL : <https://doi.org/10.1016/j.procs.2022.09.121>.
- ARDAGNA, Danilo et coll. (2012). « MODAClouds : a model-driven approach for the design and execution of applications on multiple clouds ». In : *Proceedings of the 4th International Work-*

- shop on Modeling in Software Engineering, MiSE 2012, Zurich, Switzerland, June 2-3, 2012.* Sous la dir. de Joanne M. ATLEE et coll. IEEE Computer Society, p. 50-56.
- AUBÉ, Antoine et Thomas POLACSEK (2023). « Cloud Migration High-Level Requirements ». In : *Research Challenges in Information Science : Information Science and the Connected World - 17th International Conference, RCIS 2023, Corfu, Greece, May 23-26, 2023, Proceedings*. Sous la dir. de Selmin NURCAN et coll. T. 476. Lecture Notes in Business Information Processing. Springer, p. 19-34. URL : https://doi.org/10.1007/978-3-031-33080-3%5C_2.
- AUBÉ, Antoine, Thomas POLACSEK et Clément DUFFAU (2022). « Les exigences pour un choix d'architecture dans le cadre d'une migration dans les nuages ». In : *Actes du XLème Congrès INFORSID, Dijon, France, May 31 - June 3, 2022*. Sous la dir. de Nathalie VALLÈS-PARLANGÉAU et Lylia ABROUK, p. 43-58. URL : http://inforsid.fr/actes/2022/INFORSID%5C_2022%5C_p43-58.pdf.
- AVETISYAN, Arutyun et coll. (2010). « Open Cirrus : A Global Cloud Computing Testbed ». In : *Computer* 43(4), p. 35-43. DOI : 10.1109/MC.2010.111. URL : <https://doi.org/10.1109/MC.2010.111>.
- BABU, AJG et Nalina SURESH (1996). « Project management with time, cost, and quality considerations ». In : *European journal of operational research* 88(2), p. 320-327.
- BABULAK, Eduard et Ming WANG (2008). « Discrete Event Simulation : State of the Art ». In : *Int. J. Online Eng.* 4(2), p. 60-63.
- BELLI, Olivier, Charles LOOMIS et Nabil ABDENNADHER (2016). « Towards a Cost-Optimized Cloud Application Placement Tool ». In : *2016 IEEE International Conference on Cloud Computing Technology and Science, CloudCom 2016*. IEEE Computer Society, p. 43-50.
- BELOGLAZOV, Anton, Jemal H. ABAWAYJ et Rajkumar BUYYA (2012). « Energy-aware resource allocation heuristics for efficient management of data centers for Cloud computing ». In : *Future Gener. Comput. Syst.* 28(5), p. 755-768.
- BEYER, Betsy et coll. (2016). *Site reliability engineering : How Google runs production systems*. "O'Reilly Media, Inc."
- BINNIG, Carsten et coll. (2009). « How is the weather tomorrow? : towards a benchmark for the cloud ». In : *Proceedings of the 2nd International Workshop on Testing Database Systems, DBTest 2009, Providence, Rhode Island, USA, June 29, 2009*. Sous la dir. de Benoît DAGEVILLE et Carsten BINNIG. ACM. DOI : 10.1145/1594156.1594168. URL : <https://doi.org/10.1145/1594156.1594168>.
- BINZ, Tobias, Frank LEYMAN et David SCHUMM (2011). « CMotion : A framework for migration of applications into and between clouds ». In : *IEEE International Conference on Service-Oriented Computing and Applications*. Sous la dir. de Kwei-Jay LIN et coll. IEEE Computer Society, p. 1-4.

- BOEHM, Barry W. (2006). « A view of 20th and 21st century software engineering ». In : *28th International Conference on Software Engineering (ICSE 2006), Shanghai, China, May 20-28, 2006*. Sous la dir. de Leon J. OSTERWEIL, H. Dieter ROMBACH et Mary Lou SOFFA. ACM, p. 12-29.
- BOGDAN, Robert et Steven J TAYLOR (1975). *Introduction to qualitative research methods : A phenomenological approach to the social sciences*. Wiley New York.
- BRANS, J.P., Ph. VINCKE et B. MARESCHAL (1986). « How to select and how to rank projects : The Promethee method ». In : *European Journal of Operational Research* 24(2). Mathematical Programming Multiple Criteria Decision Making, p. 228-238. ISSN : 0377-2217. DOI : [https://doi.org/10.1016/0377-2217\(86\)90044-5](https://doi.org/10.1016/0377-2217(86)90044-5). URL : <https://www.sciencedirect.com/science/article/pii/0377221786900445>.
- BREMER, Martin et coll. (2021). « A Systematic Literature Review On The Suitability Of Cloud Migration Methods For Small And Medium-Sized Enterprises ». In : *ESSN : 2701-6277*.
- BUYA, Rajkumar, Rajiv RANJAN et Rodrigo N. CALHEIROS (2009). « Modeling and simulation of scalable Cloud computing environments and the CloudSim toolkit : Challenges and opportunities ». In : *2009 International Conference on High Performance Computing & Simulation, HPCS 2009, Leipzig, Germany, June 21-24, 2009*. Sous la dir. de Waleed W. SMARI et John P. McINTIRE. IEEE, p. 1-11. DOI : [10.1109/HPCSIM.2009.5192685](https://doi.org/10.1109/HPCSIM.2009.5192685). URL : <https://doi.org/10.1109/HPCSIM.2009.5192685>.
- CALHEIROS, Rodrigo N., Marco Aurélio Stelmar NETTO et coll. (2013). « EMUSIM : an integrated emulation and simulation environment for modeling, evaluation, and validation of performance of Cloud computing applications ». In : *Softw. Pract. Exp.* 43(5), p. 595-612. DOI : [10.1002/spe.2124](https://doi.org/10.1002/spe.2124). URL : <https://doi.org/10.1002/spe.2124>.
- CALHEIROS, Rodrigo N., Rajiv RANJAN, Anton BELOGLAZOV et coll. (2011). « CloudSim : a toolkit for modeling and simulation of cloud computing environments and evaluation of resource provisioning algorithms ». In : *Softw. Pract. Exp.* 41(1), p. 23-50.
- CALHEIROS, Rodrigo N., Rajiv RANJAN, César A. F. De ROSE et coll. (2009). « CloudSim : A Novel Framework for Modeling and Simulation of Cloud Computing Infrastructures and Services ». In : *CoRR* abs/0903.2525. arXiv : [0903.2525](https://arxiv.org/abs/0903.2525).
- CAMPBELL, Roy H. et coll. (2009). « Open Cirrus™ Cloud Computing Testbed : Federated Data Centers for Open Source Systems and Services Research ». In : *Workshop on Hot Topics in Cloud Computing, HotCloud'09, San Diego, CA, USA, June 15, 2009*. Sous la dir. de Sam-bit SAHU et Prashant J. SHENOY. USENIX Association. URL : <https://www.usenix.org/conference/hotcloud-09/open-cirrus%5C%E2%84%A2-cloud-computing-testbed-federated-data-centers-open-source>.

- CHASIRI, Sivadon, Bu-Sung LEE et Dusit NIYATO (2012). « Optimization of Resource Provisioning Cost in Cloud Computing ». In : *IEEE Trans. Serv. Comput.* 5(2), p. 164-177.
- CHANGCHIT, Chuleeporn et Chat CHUCHUEN (2018). « Cloud Computing : An Examination of Factors Impacting Users' Adoption ». In : *J. Comput. Inf. Syst.* 58(1), p. 1-9.
- CHARD, Ryan et coll. (2017). « Cost-Aware Cloud Profiling, Prediction, and Provisioning as a Service ». In : *IEEE Cloud Comput.* 4(4), p. 48-59.
- CHAUHAN, Muhammad Afeef et Muhammad Ali BABAR (2012). « Towards Process Support for Migrating Applications to Cloud Computing ». In : *2012 International Conference on Cloud and Service Computing, CSC 2012, Shanghai, China, November 22-24, 2012*. IEEE Computer Society, p. 80-87.
- CHELLAPPA, R. (1997). « Cloud computing—emerging paradigm for computing ». In : *INFORMS 1997, Dallas, TX*. URL : <https://cir.nii.ac.jp/crid/1573668924800020864>.
- CHEN, Adela J., Marie-Claude BOUDREAU et Richard T. WATSON (2008). « Information systems and ecological sustainability ». In : *J. Syst. Inf. Technol.* 10(3), p. 186-201.
- CIAVOTTA, Michele et coll. (2021). « DFaaS : Decentralized Function-as-a-Service for Federated Edge Computing ». In : *10th IEEE International Conference on Cloud Networking, CloudNet 2021, Cookeville, TN, USA, November 8-10, 2021*. IEEE, p. 1-4. DOI : [10.1109/CloudNet53349.2021.9657141](https://doi.org/10.1109/CloudNet53349.2021.9657141). URL : <https://doi.org/10.1109/CloudNet53349.2021.9657141>.
- DALPIAZ, Fabiano, Xavier FRANCH et Jennifer HORKOFF (2016). « iStar 2.0 Language Guide ». In : *CoRR abs/1605.07767*. arXiv : [1605.07767](https://arxiv.org/abs/1605.07767). URL : <http://arxiv.org/abs/1605.07767>.
- DAVIS, Fred D., Richard P. BAGOZZI et Paul R. WARSHAW (1989). « User Acceptance of Computer Technology : A Comparison of Two Theoretical Models ». In : *Management Science* 35(8), p. 982-1003. ISSN : 00251909, 15265501. URL : <http://www.jstor.org/stable/2632151> (visité le 26/04/2023).
- DI, Sheng et Franck CAPPELLO (2015). « GloudSim : Google trace based cloud simulator with virtual machines ». In : *Softw. Pract. Exp.* 45(11), p. 1571-1590. DOI : [10.1002/spe.2303](https://doi.org/10.1002/spe.2303). URL : <https://doi.org/10.1002/spe.2303>.
- DiCICCO-BLOOM, Barbara et Benjamin CRABTREE (mai 2006). « The qualitative research interview ». In : *Medical education* 40, p. 314-21. DOI : [10.1111/j.1365-2929.2006.02418.x](https://doi.org/10.1111/j.1365-2929.2006.02418.x).
- DOE, John (1998). « IEEE Recommended Practice for Software Requirements Specifications ». In : *IEEE Std 830-1998*, p. 1-40. DOI : [10.1109/IEEESTD.1998.88286](https://doi.org/10.1109/IEEESTD.1998.88286).
- DUAN, Qiang (2017). « Cloud service performance evaluation : status, challenges, and opportunities - a survey from the system modeling perspective ». In : *Digit. Commun. Networks* 3(2), p. 101-111. DOI : [10.1016/j.dcan.2016.12.002](https://doi.org/10.1016/j.dcan.2016.12.002). URL : <https://doi.org/10.1016/j.dcan.2016.12.002>.

- EL KARADAWY, Ahmed I., Ahmed A. MAWGOUD et Hussein M. RADY (2020). « An Empirical Analysis on Load Balancing and Service Broker Techniques using Cloud Analyst Simulator ». In : *2020 International Conference on Innovative Trends in Communication and Computer Engineering (ITCE)*, p. 27-32. DOI : [10.1109/ITCE48509.2020.9047753](https://doi.org/10.1109/ITCE48509.2020.9047753).
- ELAHI, Bukhtawar et coll. (2020). « Toward scalable cloud data center simulation using high-level architecture ». In : *Softw. Pract. Exp.* 50(6), p. 827-843. DOI : [10.1002/spe.2769](https://doi.org/10.1002/spe.2769). URL : <https://doi.org/10.1002/spe.2769>.
- ELSHAMY, Ahmed et Amr ELSSAMADISY (2006). « Divide After You Conquer : An Agile Software Development Practice for Large Projects ». In : *Extreme Programming and Agile Processes in Software Engineering, 7th International Conference, XP 2006, Oulu, Finland, June 17-22, 2006, Proceedings*. Sous la dir. de Pekka ABRAHAMSSON, Michele MARCHESI et Giancarlo SUCCI. T. 4044. Lecture Notes in Computer Science. Springer, p. 164-168.
- EVANS, Eric (2004). *Domain-driven design : tackling complexity in the heart of software*. Addison-Wesley Professional.
- FAHMIDEH, Mahdi, Farhad DANESHGAR, Graham LOW et coll. (2016). « Cloud migration process - A survey, evaluation framework, and open challenges ». In : *J. Syst. Softw.* 120, p. 31-69.
- FAHMIDEH, Mahdi, Farhad DANESHGAR et Fethi A. RABHI (2016). « Cloud Migration Methodologies : Preliminary Findings ». In : *Advances in Service-Oriented and Cloud Computing - Workshops*. Sous la dir. d'Alexander LAZOVIK et Stefan SCHULTE. T. 707. Communications in Computer and Information Science. Springer, p. 112-122.
- FAHMIDEH, Mahdi, Farhad DANESHGAR, Fethi A. RABHI et Ghassan BEYDOUN (2019). « A generic cloud migration process model ». In : *Eur. J. Inf. Syst.* 28(3), p. 233-255.
- FAHMIDEH, Mahdi, John GRUNDY et coll. (2022). « A model-driven approach to reengineering processes in cloud computing ». In : *Inf. Softw. Technol.* 144, p. 106795.
- FARLEY, Jennifer, Kristin Duppong HURLEY et A Angelique AITKEN (2020). « Monitoring implementation in program evaluation with direct audio coding ». In : *Evaluation and Program Planning* 83, p. 101854.
- FAROKHI, Soodeh et coll. (2014). « HS4MC - Hierarchical SLA-based Service Selection for Multi-Cloud Environments ». In : *CLOSER 2014 - Proceedings of the 4th International Conference on Cloud Computing and Services Science, Barcelona, Spain, April 3-5, 2014*. Sous la dir. de Markus HELFERT et coll. SciTePress, p. 722-734.
- FERRETTI, Luca et coll. (2014). « Performance and Cost Evaluation of an Adaptive Encryption Architecture for Cloud Databases ». In : *IEEE Trans. Cloud Comput.* 2(2), p. 143-155.
- FERRY, Nicolas, Alessandro ROSSINI et coll. (2013). « Towards Model-Driven Provisioning, Deployment, Monitoring, and Adaptation of Multi-cloud Systems ». In : *2013 IEEE Sixth Inter-*

- national Conference on Cloud Computing, Santa Clara, CA, USA, June 28 - July 3, 2013*. IEEE Computer Society, p. 887-894.
- FERRY, Nicolas, Hui SONG et coll. (2014). « CloudMF : Applying MDE to Tame the Complexity of Managing Multi-cloud Applications ». In : *Proceedings of the 7th IEEE/ACM International Conference on Utility and Cloud Computing, UCC 2014, London, United Kingdom, December 8-11, 2014*. IEEE Computer Society, p. 269-277. URL : <https://doi.org/10.1109/UCC.2014.36>.
- FISHBEIN, Martin et Icek AJZEN (1974). « Attitudes towards objects as predictors of single and multiple behavioral criteria. » In : *Psychological review* 81(1), p. 59.
- FISHMAN, George S (2001). *Discrete-event simulation : modeling, programming, and analysis*. T. 537. Springer.
- FITTKAU, Florian, Sören FREY et Wilhelm HASSELBRING (2012a). « CDOSim : Simulating cloud deployment options for software migration support ». In : *6th IEEE International Workshop on the Maintenance and Evolution of Service-Oriented and Cloud-Based Systems, MESOCA 2012, Trento, Italy, September 24, 2012*. IEEE Computer Society, p. 37-46. DOI : [10.1109/MESOCA.2012.6392599](https://doi.org/10.1109/MESOCA.2012.6392599). URL : <https://doi.org/10.1109/MESOCA.2012.6392599>.
- FITTKAU, Florian, Sören FREY et Wilhelm HASSELBRING (2012b). « Cloud User-Centric Enhancements of the Simulator CloudSim to Improve Cloud Deployment Option Analysis ». In : *Service-Oriented and Cloud Computing - First European Conference, ESOC 2012, Bertinoro, Italy, September 19-21, 2012. Proceedings*. Sous la dir. de Flavio De PAOLI, Ernesto PIMENTEL et Gianluigi ZAVATTARO. T. 7592. Lecture Notes in Computer Science. Springer, p. 200-207. DOI : [10.1007/978-3-642-33427-6_15](https://doi.org/10.1007/978-3-642-33427-6_15). URL : https://doi.org/10.1007/978-3-642-33427-6_15.
- FREY, Sören et Wilhelm HASSELBRING (2010). « Model-Based Migration of Legacy Software Systems into the Cloud : The CloudMIG Approach ». In : *Softwaretechnik-Trends* 30(2).
- FREY, Sören et Wilhelm HASSELBRING (2011). « The CloudMIG approach : Model-based migration of software systems to cloud-optimized applications ». In : *International Journal on Advances in Software* 4(3 and 4), p. 342-353.
- FREY, Sören, Wilhelm HASSELBRING et Benjamin SCHNOOR (2013). « Automatic conformance checking for migrating software systems to cloud infrastructures and platforms ». In : *J. Softw. Evol. Process*. 25(10), p. 1089-1115.
- GARG, Saurabh Kumar et Rajkumar BUYYA (2011). « NetworkCloudSim : Modelling Parallel Applications in Cloud Simulations ». In : *IEEE 4th International Conference on Utility and Cloud Computing, UCC 2011, Melbourne, Australia, December 5-8, 2011*. IEEE Computer Society, p. 105-113. DOI : [10.1109/UCC.2011.24](https://doi.org/10.1109/UCC.2011.24). URL : <https://doi.org/10.1109/UCC.2011.24>.

- GARTNER (2010). *Migrating Applications to the Cloud : Rehost, Refactor, Revise, Rebuild, or Replace ?* <https://www.gartner.com/en/documents/1485116>. [Online ; accessed 07-June-2023].
- GARTNER (2023). *Gartner Forecasts Worldwide Public Cloud End-User Spending to Reach Nearly \$600 Billion in 2023*. <https://www.gartner.com/en/newsroom/press-releases/2023-04-19-gartner-forecasts-worldwide-public-cloud-end-user-spending-to-reach-nearly-600-billion-in-2023>. [Online ; accessed 21-November-2023].
- GESVINDR, David et Barbora BUHNOVA (2019). « PaaSArch : Quality Evaluation Tool for PaaS Cloud Applications Using Generated Prototypes ». In : *IEEE International Conference on Software Architecture Companion, ICSA Companion 2019, Hamburg, Germany, March 25-26, 2019*. IEEE, p. 170-173.
- GESVINDR, David, Barbora BUHNOVA et Ondrej GASIOR (2017). « Quality Evaluation of PaaS Cloud Application Design Using Generated Prototypes ». In : *2017 IEEE International Conference on Software Architecture, ICSA 2017, Gothenburg, Sweden, April 3-7, 2017*. IEEE Computer Society, p. 31-40.
- GILBERT, Seth et Nancy A. LYNCH (2002). « Brewer's conjecture and the feasibility of consistent, available, partition-tolerant web services ». In : *SIGACT News* 33(2), p. 51-59.
- GLASS, Robert L. (2006). « The Standish report : does it really describe a software crisis ? » In : *Commun. ACM* 49(8), p. 15-16.
- GONZÁLEZ, Luis Miguel Vaquero et coll. (2009). « A break in the clouds : towards a cloud definition ». In : *Comput. Commun. Rev.* 39(1), p. 50-55.
- GROSSMAN, Robert L. et coll. (2009). « The Open Cloud Testbed : A Wide Area Testbed for Cloud Computing Utilizing High Performance Network Services ». In : *CoRR* abs/0907.4810. arXiv : 0907.4810. URL : <http://arxiv.org/abs/0907.4810>.
- GUNKA, Alexander, Stepan SEYCEK et Harald KÜHN (2013). « Moving an application to the cloud : an evolutionary approach ». In : *Proceedings of the 2013 international workshop on Multi-cloud applications and federated clouds, MultiCloud@ICPE 2013, Prague, Czech Republic, April 22, 2013*. Sous la dir. de Danilo ARDAGNA et Lutz SCHUBERT. ACM, p. 35-42.
- GUPTA, Sandeep K. S., Ayan BANERJEE et coll. (2014). « GDCSim : A simulator for green data center design and analysis ». In : *ACM Trans. Model. Comput. Simul.* 24(1), 3 :1-3 :27. DOI : 10.1145/2553083. URL : <https://doi.org/10.1145/2553083>.
- GUPTA, Sandeep K. S., Rose Robin GILBERT et coll. (2011). « GDCSim : A tool for analyzing Green Data Center design and resource management techniques ». In : *2011 International Green Computing Conference and Workshops, IGCC 2012, Orlando, FL, USA, July 25-28, 2011*. IEEE Computer Society, p. 1-8. DOI : 10.1109/IGCC.2011.6008612. URL : <https://doi.org/10.1109/IGCC.2011.6008612>.

- HAYYOLALAM, Vahideh et Ali Asghar Pourhaji KAZEM (2018). « A systematic literature review on QoS-aware service composition and selection in cloud environment ». In : *J. Netw. Comput. Appl.* 110, p. 52-74.
- HERBST, Nikolas Roman, Samuel KOUNEV et Ralf H. REUSSNER (2013). « Elasticity in Cloud Computing : What It Is, and What It Is Not ». In : *10th International Conference on Autonomic Computing, ICAC'13, San Jose, CA, USA, June 26-28, 2013*. Sous la dir. de Jeffrey O. KEPHART, Calton Pu et Xiaoyun ZHU. USENIX Association, p. 23-27.
- INSEE (2022). *Préoccupations environnementales des Français - Synthèse des connaissances en 2021*. <https://www.statistiques.developpement-durable.gouv.fr/preoccupations-environnementales-des-francais-synthese-des-connaissances-en-2021>. [Site Web ; consulté le 12 mai 2023].
- JAMSHIDI, Pooyan, Aakash AHMAD et Claus PAHL (2013). « Cloud Migration Research : A Systematic Review ». In : *IEEE Trans. Cloud Comput.* 1(2), p. 142-157.
- JARARWEH, Yaser et coll. (2013). « TeachCloud : a cloud computing educational toolkit ». In : *Int. J. Cloud Comput.* 2(2/3), p. 237-257. DOI : [10.1504/IJCC.2013.055269](https://doi.org/10.1504/IJCC.2013.055269). URL : <https://doi.org/10.1504/IJCC.2013.055269>.
- JEON, Hongseok et coll. (2019). « A CloudSim-Extension for Simulating Distributed Functions-as-a-Service ». In : *20th International Conference on Parallel and Distributed Computing, Applications and Technologies, PDCAT 2019, Gold Coast, Australia, December 5-7, 2019*. IEEE, p. 386-391. DOI : [10.1109/PDCAT46702.2019.00076](https://doi.org/10.1109/PDCAT46702.2019.00076). URL : <https://doi.org/10.1109/PDCAT46702.2019.00076>.
- JIN, Hai et coll. (2021). « DSEOM : A Framework for Dynamic Security Evaluation and Optimization of MTD in Container-Based Cloud ». In : *IEEE Trans. Dependable Secur. Comput.* 18(3), p. 1125-1136. DOI : [10.1109/TDSC.2019.2916666](https://doi.org/10.1109/TDSC.2019.2916666). URL : <https://doi.org/10.1109/TDSC.2019.2916666>.
- JØRGENSEN, Magne et Kjetil MOLØKKEN-ØSTVOLD (2006). « How large are software cost overruns? A review of the 1994 CHAOS report ». In : *Inf. Softw. Technol.* 48(4), p. 297-301.
- KAZMAN, Rick, Steven S. WOODS et S. Jeromy CARRIÈRE (1998). « Requirements for Integrating Software Architecture and Reengineering Models : CORUM II ». In : *5th Working Conference on Reverse Engineering, WCRE '98, Honolulu, Hawaii, USA, October 12-14, 1998*. IEEE Computer Society, p. 154-163.
- KECSKEMETI, Gabor (2015). « DISSECT-CF : A simulator to foster energy-aware scheduling in infrastructure clouds ». In : *Simul. Model. Pract. Theory* 58, p. 188-218. DOI : [10.1016/j.simpat.2015.05.009](https://doi.org/10.1016/j.simpat.2015.05.009). URL : <https://doi.org/10.1016/j.simpat.2015.05.009>.

- KEHRER, Stefan et Wolfgang BLOCHINGER (2019). « A survey on cloud migration strategies for high performance computing ». In : *Proceedings of the 13th Symposium and Summer School on Service-Oriented Computing (SummerSoc19)*. IBM Research Division, p. 57-69.
- KLIAZOVICH, Dzmitry, Pascal BOUVRY et Samee Ullah KHAN (2012). « GreenCloud : a packet-level simulator of energy-aware cloud computing data centers ». In : *J. Supercomput.* 62(3), p. 1263-1283. DOI : [10.1007/s11227-010-0504-1](https://doi.org/10.1007/s11227-010-0504-1). URL : <https://doi.org/10.1007/s11227-010-0504-1>.
- KOTONYA, Gerald et Ian SOMMERVILLE (1998a). *Requirements Engineering : Processes and Techniques*. 1st. Wiley Publishing. ISBN : 0471972088.
- KOTONYA, Gerald et Ian SOMMERVILLE (1998b). *Requirements engineering : processes and techniques*. Wiley Publishing.
- LAMSWEERDE, Axel van (2001). « Goal-Oriented Requirements Engineering : A Guided Tour ». In : *5th IEEE International Symposium on Requirements Engineering (RE 2001), 27-31 August 2001, Toronto, Canada*. IEEE Computer Society, p. 249.
- LAMSWEERDE, Axel van (2004). « Goal-Oriented Requirements Engineering : A Roundtrip from Research to Practice ». In : *12th IEEE International Conference on Requirements Engineering*. IEEE Computer Society, p. 4-7.
- LIU, Wenqiang et coll. (2019). « A Novel Algorithm for Optimizing Selection of Cloud Instance Types in Multi-Cloud Environment ». In : *25th IEEE International Conference on Parallel and Distributed Systems, ICPADS 2019, Tianjin, China, December 4-6, 2019*. IEEE, p. 167-170.
- Low, Chinyao, Ychsueh CHEN et Mingchang WU (2011). « Understanding the determinants of cloud computing adoption ». In : *Ind. Manag. Data Syst.* 111(7), p. 1006-1023.
- MARTENS, Benedikt, Marc WALTERBUSCH et Frank TEUTEBERG (2012). « Costing of Cloud Computing Services : A Total Cost of Ownership Approach ». In : *45th Hawaii International International Conference on Systems Science, Proceedings*. IEEE Computer Society, p. 1563-1572.
- MAZREKAJ, Artan, Isak SHABANI et Besmir SEJDIU (2016). « Pricing Schemes in Cloud Computing : An Overview ». In : *International Journal of Advanced Computer Science and Applications* 7(2). DOI : [10.14569/IJACSA.2016.070211](https://doi.org/10.14569/IJACSA.2016.070211). URL : <http://dx.doi.org/10.14569/IJACSA.2016.070211>.
- MCCRACKEN, G. (1988). *The Long Interview*. Qualitative Research Methods. SAGE Publications. ISBN : 9780803933538. URL : <https://books.google.fr/books?id=3N01cl2gtoMC>.
- McKINSEY et COMPANY (2021). *Cloud-migration opportunity : Business value grows, but missteps abound*. <https://www.mckinsey.com/~media/mckinsey/industries/technology%20media%20and%20telecommunications/high%20tech/our%20insights/cloud%20migration%20opportunity%20business%20value%20grows%20but%20missteps%20abound/cloud->

- [migration-opportunity-business-value-grows-but-missteps-abound_final.pdf](#). [Online; accessed 21-November-2023].
- MELL, Peter et Timothy GRANCE (sept. 2011). *The NIST Definition of Cloud Computing*. Rapp. tech. 800-145. Gaithersburg, MD : National Institute of Standards et Technology (NIST). URL : <http://csrc.nist.gov/publications/nistpubs/800-145/SP800-145.pdf>.
- NITTO, Elisabetta Di et coll. (2013). « Supporting the Development and Operation of Multi-cloud Applications : The MODAClouds Approach ». In : *15th International Symposium on Symbolic and Numeric Algorithms for Scientific Computing, SYNASC 2013, Timisoara, Romania, September 23-26, 2013*. Sous la dir. de Nikolaj S. BJØRNER et coll. IEEE Computer Society, p. 417-423.
- NORTHROP, Linda M. (2002). « SEI's Software Product Line Tenets ». In : *IEEE Softw.* 19(4), p. 32-40.
- NUÑEZ, Alberto, Javier FERNÁNDEZ et coll. (2008). « SIMCAN : a SIMulator framework for computer architectures and storage networks ». In : *Proceedings of the 1st International Conference on Simulation Tools and Techniques for Communications, Networks and Systems & Workshops, SimuTools 2008, Marseille, France, March 3-7, 2008*. Sous la dir. de Sándor MOLNÁR et coll. ICST/ACM, p. 73. DOI : [10.4108/ICST.SIMUTOOLS2008.3025](https://doi.org/10.4108/ICST.SIMUTOOLS2008.3025). URL : <https://doi.org/10.4108/ICST.SIMUTOOLS2008.3025>.
- NUÑEZ, Alberto, José Luis VÁZQUEZ-POLETTI, Agustín C. CAMINERO, Jesús CARRETERO et coll. (2011). « Design of a New Cloud Computing Simulation Platform ». In : *Computational Science and Its Applications - ICCSA 2011 - International Conference, Santander, Spain, June 20-23, 2011. Proceedings, Part III*. Sous la dir. de Beniamino MURGANTE et coll. T. 6784. Lecture Notes in Computer Science. Springer, p. 582-593. DOI : [10.1007/978-3-642-21931-3_45](https://doi.org/10.1007/978-3-642-21931-3_45). URL : https://doi.org/10.1007/978-3-642-21931-3_45.
- NUÑEZ, Alberto, José Luis VÁZQUEZ-POLETTI, Agustín C. CAMINERO, Gabriel G. CASTAÑÉ et coll. (2012). « iCanCloud : A Flexible and Scalable Cloud Infrastructure Simulator ». In : *J. Grid Comput.* 10(1), p. 185-209. DOI : [10.1007/s10723-012-9208-5](https://doi.org/10.1007/s10723-012-9208-5). URL : <https://doi.org/10.1007/s10723-012-9208-5>.
- OSTERMANN, Simon et coll. (2010). « GroudSim : An Event-Based Simulation Framework for Computational Grids and Clouds ». In : *Euro-Par 2010 Parallel Processing Workshops - HeteroPar, HPCC, HiBB, CoreGrid, UCHPC, HPCF, PROPER, CCPI, VHPC, Ischia, Italy, August 31-September 3, 2010, Revised Selected Papers*. Sous la dir. de Mario R. GUARRACINO et coll. T. 6586. Lecture Notes in Computer Science. Springer, p. 305-313. DOI : [10.1007/978-3-642-21878-1_38](https://doi.org/10.1007/978-3-642-21878-1_38). URL : https://doi.org/10.1007/978-3-642-21878-1_38.
- PETCU, Dana (2013). « Multi-Cloud : expectations and current approaches ». In : *Proceedings of the 2013 international workshop on Multi-cloud applications and federated clouds, Multi-*

- Cloud@ICPE 2013, Prague, Czech Republic, April 22, 2013*. Sous la dir. de Danilo ARDAGNA et Lutz SCHUBERT. ACM, p. 1-6.
- PIRAGHAJ, Sareh Fotuhi et coll. (2016). « ContainerCloudSim : An environment for modeling and simulation of containers in cloud data centers ». In : *Software : Practice and Experience* 47(4), p. 505-521.
- POPE, Catherine et Nick MAYS (1995). « Qualitative research : reaching the parts other methods cannot reach : an introduction to qualitative methods in health and health services research ». In : *bmj* 311(6996), p. 42-45.
- QIAN, Ling et coll. (2009). « Cloud Computing : An Overview ». In : *Cloud Computing, First International Conference, CloudCom 2009, Beijing, China, December 1-4, 2009. Proceedings*. Sous la dir. de Martin Gilje JAATUN, Gansen ZHAO et Chunming RONG. T. 5931. Lecture Notes in Computer Science. Springer, p. 626-631.
- QUINTON, Clément (2014). « Cloud Environment Selection and Configuration : A Software Product Lines-Based Approach ». Thèse de doct. Lille University of Science et Technology, France.
- RAMAMURTHY, Arun et coll. (2020). « Selection of Cloud Service Providers for Hosting Web Applications in a Multi-cloud Environment ». In : *2020 IEEE International Conference on Services Computing, SCC 2020, Beijing, China, November 7-11, 2020*. IEEE, p. 202-209.
- RAZAVIAN, Maryam et Patricia LAGO (2015). « A systematic literature review on SOA migration ». In : *J. Softw. Evol. Process*. 27(5), p. 337-372.
- ROSS, Douglas T. et Kenneth E. Schoman JR. (1977). « Structured Analysis for Requirements Definition ». In : *IEEE Trans. Software Eng.* 3(1), p. 6-15.
- RYAN, Gery W et H Russell BERNARD (2003). « Techniques to identify themes ». In : *Field methods* 15(1), p. 85-109.
- SABI, Humphrey M. et coll. (2016). « Conceptualizing a model for adoption of cloud computing in education ». In : *Int. J. Inf. Manag.* 36(2), p. 183-191.
- SCHWARTZ, Howard et Jerry JACOBS (1979). *Qualitative sociology*. Simon et Schuster.
- SHAHBAZ, Muhammad et Rimsha ZAHID (2022). « Probing the factors influencing cloud computing adoption in healthcare organizations : A three-way interaction model ». In : *Technology in Society* 71, p. 102139.
- SHARMA, Sujeet Kumar et coll. (2016). « Predicting motivators of cloud computing adoption : A developing country perspective ». In : *Comput. Hum. Behav.* 62, p. 61-69.
- SIGSOFT, ACM (2022). *Qualitative Surveys (Interview Studies)*. <https://github.com/acmsigsoft/EmpiricalStandards/blob/master/docs/QualitativeSurveys.md>. [Online ; accessed 07-July-2022].

- SINGH, Victor et Karen E WILLCOX (2018). « Engineering design with digital thread ». In : *AIAA Journal* 56(11), p. 4515-4528.
- SOMMERVILLE, Ian (2011). « Software engineering (ed.) » In : *America : Pearson Education Inc.*
- SOTIRIADIS, Stelios, Nik BESSIS et Nick ANTONOPOULOS (2013). « Towards Inter-cloud Simulation Performance Analysis : Exploring Service-Oriented Benchmarks of Clouds in SimIC ». In : *27th International Conference on Advanced Information Networking and Applications Workshops, WAINA 2013*. Sous la dir. de Leonard BAROLLI et coll. IEEE Computer Society, p. 765-771.
- SRIRAM, Ilango (2009). « SPECI, a Simulation Tool Exploring Cloud-Scale Data Centres ». In : *Cloud Computing, First International Conference, CloudCom 2009, Beijing, China, December 1-4, 2009. Proceedings*. Sous la dir. de Martin Gilje JAATUN, Gansen ZHAO et Chunming RONG. T. 5931. Lecture Notes in Computer Science. Springer, p. 381-392. DOI : [10.1007/978-3-642-10665-1_35](https://doi.org/10.1007/978-3-642-10665-1_35). URL : https://doi.org/10.1007/978-3-642-10665-1_35.
- STECKLEIN, Jonette M et coll. (2004). « Error cost escalation through the project life cycle ». In : *14th Annual International Symposium*. Conference paper JSC-CN-8435.
- STIENINGER, Mark et coll. (2014). « Impacts on the organizational adoption of cloud computing : A reconceptualization of influencing factors ». In : *Procedia technology* 16, p. 85-93.
- TIAN, Wenhong et coll. (2015). « A Toolkit for Modeling and Simulation of Real-Time Virtual Machine Allocation in a Cloud Data Center ». In : *IEEE Trans Autom. Sci. Eng.* 12(1), p. 153-161. DOI : [10.1109/TASE.2013.2266338](https://doi.org/10.1109/TASE.2013.2266338). URL : <https://doi.org/10.1109/TASE.2013.2266338>.
- TIGHE, Michael et coll. (2012). « DCSim : A data centre simulation tool for evaluating dynamic virtualized resource management ». In : *8th International Conference on Network and Service Management, CNSM 2012, Las Vegas, NV, USA, October 22-26, 2012*. IEEE, p. 385-392. URL : <https://ieeexplore.ieee.org/document/6380046/>.
- VONDRA, T. et Jan SEDIVÝ (2017). « Cloud autoscaling simulation based on queueing network model ». In : *Simul. Model. Pract. Theory* 70, p. 83-100.
- WEBER, Andreas et coll. (2014). « Towards a Resource Elasticity Benchmark for Cloud Environments ». In : *Proceedings of the 2nd International Workshop on Hot Topics in Cloud service Scalability, HotTopiCS 2014, Dublin, Ireland, March 22, 2014*. ACM, 5 :1-5 :8. DOI : [10.1145/2649563.2649571](https://doi.org/10.1145/2649563.2649571). URL : <https://doi.org/10.1145/2649563.2649571>.
- WICKREMASINGHE, Bhathiya, Rodrigo N. CALHEIROS et Rajkumar BUYYA (2010). « CloudAnalyst : A CloudSim-Based Visual Modeller for Analysing Cloud Computing Environments and Applications ». In : *24th IEEE International Conference on Advanced Information Networking and Applications, AINA 2010, Perth, Australia, 20-13 April 2010*. IEEE Computer Society, p. 446-452. DOI : [10.1109/AINA.2010.32](https://doi.org/10.1109/AINA.2010.32). URL : <https://doi.org/10.1109/AINA.2010.32>.

- XU, Minxian et coll. (2015). « FlexCloud : A Flexible and Extendible Simulator for Performance Evaluation of Virtual Machine Allocation ». In : *2015 IEEE International Conference on Smart City/SocialCom/SustainCom/DataCom/SC2 2015, Chengdu, China, December 19-21, 2015*. IEEE Computer Society, p. 649-655. DOI : [10.1109/SmartCity.2015.143](https://doi.org/10.1109/SmartCity.2015.143). URL : <https://doi.org/10.1109/SmartCity.2015.143>.
- YOUNAS, Muhammad et coll. (2018). « Agile development in the cloud computing environment : A systematic review ». In : *Inf. Softw. Technol.* 103, p. 142-158.
- ZHANG, Miranda et coll. (2012). « An ontology-based system for Cloud infrastructure services' discovery ». In : *8th International Conference on Collaborative Computing : Networking, Applications and Worksharing, CollaborateCom 2012*. Sous la dir. de Calton Pu, James JOSHI et Surya NEPAL. ICST / IEEE, p. 524-530.
- ZHANG, Qian, Armin HALLER et Qing WANG (2019). « CoCoOn : Cloud Computing Ontology for IaaS Price and Performance Comparison ». In : *The Semantic Web - ISWC 2019 - 18th International Semantic Web Conference, Proceedings, Part II*. Sous la dir. de Chiara GHIDINI et coll. T. 11779. Lecture Notes in Computer Science. Springer, p. 325-341.
- ZHANG, Weiqing et coll. (oct. 2009). « Migrating Legacy Applications to the Service Cloud ». In : *ACM Object-Oriented Programming, Systems, Languages and Applications (OOPSLA)*.
- ZHAO, Jun-Feng et Jian-Tao ZHOU (2014). « Strategies and Methods for Cloud Migration ». In : *Int. J. Autom. Comput.* 11(2), p. 143-152.
- ZHAO, Zhuo, Ying JIANG et Xin ZHAO (2015). « SLA-oriented service selection in cloud environment : A PROMETHEE-based approach ». In : *2015 4th International Conference on Computer Science and Network Technology (ICCSNT)*. T. 01, p. 872-875. DOI : [10.1109/ICCSNT.2015.7490879](https://doi.org/10.1109/ICCSNT.2015.7490879).
- ZINK, Michael et coll. (2021). « The Open Cloud Testbed (OCT) : A Platform for Research into new Cloud Technologies ». In : *10th IEEE International Conference on Cloud Networking, CloudNet 2021, Cookeville, TN, USA, November 8-10, 2021*. IEEE, p. 140-147. DOI : [10.1109/CloudNet53349.2021.9657109](https://doi.org/10.1109/CloudNet53349.2021.9657109). URL : <https://doi.org/10.1109/CloudNet53349.2021.9657109>.